分类号　　密级

中国地质大学（北京）

本 科 毕 业 设 计

题　　目　基于稳健主成分分析的地震数据噪音压制

英文题目　Suppression of Erratic Noise in Seismic Data Based on Robust Principal Component Analysis

学生姓名　贾昊　　**学　　号**　1010163122

学　　院　地球物理与信息技术学院　**专　　业**　勘查技术与工程

指导教师　高建军　　**职　　称**　副教授

2020 年 6 月

中国地质大学（北京）
本科毕业设计（论文）原创性声明和使用授权的说明

学院	地球物理与信息技术学院	专业	勘查技术与工程	班级	10101631
学号	101063122	姓名	贾昊	指导教师	高建军
设计（论文）题目	基于稳健主成分分析的地震数据噪音压制				

原创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国地质大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学生签名：贾昊　　日　期：2020.5.28

关于论文使用授权的说明

本人完全了解中国地质大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

☑公开　□保密（____年）（保密的论文在解密后应遵守此规定）

学生签名：贾昊　　导师签名：高建军　　日　期：2020.5.28

中国地质大学（北京）本科毕业设计（论文）任务书

学院	地球物理与信息技术学院	专业	勘查技术与工程	班级	10101631
学号	1010163122	姓名	贾昊	指导教师	高建军
设计（论文）题目	基于稳健主成分分析的地震数据噪音压制				

毕业设计（论文）主要内容和要求：

1. 通过文献调研了解地震数据中噪声的种类；

2. 调研国内外发展近况，理解稳健主成分分析去噪的处理流程；

3. 实现稳健主成分分析算法处理异常值数据；

4. 结合地球物理知识，将该算法运用于理论模型和实际数据探究其去噪效果。

毕业设计（论文）主要参考资料：

[1] Chen.K and M.D.Sacchi, Robust reduced-rank filtering for erratic seismic noise attenuation. 2015, 80(1):V1 – V11.

[2] Oropeza, V. E., and M. D. Sacchi. Simultaneous seismic data de-noising and reconstruction via multichannel singular spectrum analysis.Geophysics, 2011, 76(3):V25–V32.

[3] Sacchi M. F-X Singular Spectrum Analysis. CSPG CSEG CWLS Convention, 2009, 392-395.

[4] Trickett S., Burroughs, L., Milton, A. Robust rank-reduction filtering for erratic noise: SEG Annual Meeting Abstract ,2012 ,1-4.

[5] Chen. Y., W. Huang, D. Zhang, et al. An open-source Matlab code package for improved rank-reduction 3D seismic data denoising and reconstruction, Computer and Geoscience, 2016, 95, 59-66.

毕业设计（论文）应完成的主要工作：

1. 阅读文献，了解地震数据中噪声的种类并了解异常值噪声的压制方法；

2. 翻译一篇英文文献。

3. 理解稳健主成分分析算法的实现原理，并编程实现该方法。

4. 结合理论模型和实际数据测试稳健主成分分析的去噪效果，分析该方法的优缺点。

毕业设计（论文）进度安排：

序号	毕业设计（论文）各阶段内容	时间安排	备注

1	文献调研，英文文献翻译，文献综述	2019.12.25-2020.1.19	
2	开题报告	2020.1.6	开题答辩
3	学习基于奇异值分解的稳健主成分分析方法原理	2020.1.20-2020.3.15	
4	学习 MATLAB 合成理想地震模型和含噪声的地震数据，并对稳健主成分分析算法进行编程	2020.3.16-2020.4.16	
5	中期检查	2020.4.16	中期检查
6	研究稳健主成分分析算法压制异常值噪声的效果并结合实际数据进行测试，撰写论文初稿	2020.4.16-2020.5.10	
7	完善论文，完成报告，制作答辩 PPT	2020.5.10-2020.5.31	
8	论文答辩	2020.5.30	终期答辩

课题信息：

课题性质： √设计　　论文

课题来源： 教学　　√科研　　生产　　其它

发出任务书日期：2019 年 12 月 24 日

指导教师签名：高建军

2019 年 12 月 24 日

教研室意见：

教研室主任签名：

年　　月　　日

学生签名：贾昊

摘　要

地震数据常含有噪声。因此，增强地震数据的信噪比在地震数据处理中起着重要作用。传统的去噪方法虽然可以有效压制随机噪声，但对不符合高斯分布的异常值噪声压制效果不佳。本论文阐述了一种基于稳健主成分分析的地震数据异常值噪声压制方法。该方法在频率-空间域对地震数据体实施稳健的低秩近似来实现。采用核范数最小化约束模型求取理想的低秩近似数据，使用 L1 范数约束来估计异常值噪声。然后运用具有两步软阈值的一阶梯度迭代方法解决该反演问题。本文中使用理论数据和实际数据进行对稳健主成分分析算法进行测试，并采用品质因子来衡量方法的去噪效果。最终测试后结果表明稳健主成分分析算法可以有效地压制地震异常值噪声和随机噪声，与比传统的预测滤波方法相比，去噪效果更好。

关键词:异常值噪声；　稳健主成分分析；　质量因子；　低秩矩阵

ABSTRACT

Seismic data is often contaminated by noise. Therefore, enhancing the signal-to-noise ratio of seismic data plays an important role in seismic data processing. Although the traditional denoising method can effectively suppress random noise, it has poor suppression effect on erratic noise that do not conform to the Gaussian distribution. This paper describes a denoising method based on robust principal component analysis to suppress erratic noise in seismic data. This method operates in the frequency-space domain by implementing a robust low-rank approximation of the seismic data volume. Here, nuclear norm constraint is used to generate ideal low-rank approximate data, while L1 norm constraints are used to estimate outlier noise. Then the first-order gradient iterative method with two-step soft threshold is used to solve the problem. In this paper, the synthetic data and real data are used to test the robust principal component analysis algorithm, and the quality factor is calculated to measure its denoising effect. The test results show that the robust principal component analysis algorithm can effectively suppress both outlier noise and random noise, which has a better performance than the traditional denoising method.

Keywords: erratic noise; robust principal component analysis; quality factor； low rank matrix

目　　录

第一章 绪论.....1
1.1　研究目的及意义..... 1
1.2　国内外研究现状..... 2
1.2.1 基于小波变换的异常值噪声压制..... 2
1.2.2 基于中值滤波的异常值噪声压制..... 2
1.2.3 基于降秩滤波的异常值噪声压制..... 3
1.3　论文主要内容及成果..... 3
1.3.1　论文主要研究工作..... 3
1.3.2　论文主要成果..... 3
1.3.3　论文主要章节安排..... 4
第二章 稳健主成分分析方法的噪音压制原理.....5
2.1 方法原理 5
2.1.1 主成分分析（Principal Component Analysis, PCA） 5
2.1.2 稳健主成分分析（Robust Principal Component Analysis, RPCA） 5
2.2　算法及其流程..... 8
2.2.1　软硬件环境..... 8
2.2.2　算法流程..... 8
第三章 数据测试与分析.....14
3.1　模型数据测试..... 14
3.1.1 线性同相轴实验 14
3.1.2 弯曲同相轴实验 28
3.2 实际数据处理 34
结　论 37
致　谢 38
参考文献.....39

第一章 绪论

1.1 研究目的及意义

地震勘探数据常含有噪声，因此，提高信噪比在提升地震数据处理品质中起到了重要作用。为提高地震数据信噪比，国内外许多学者根据噪声与有效信号的在频率、振幅等方面特征的不同而设计了不同的去噪方法。虽然各个方法都有各自优缺点，但是在实际数据处理中均能对噪声压制产生良好效果。

根据地震数据中噪声特征，可以将噪声分为相干噪声和随机噪声两类，相干噪声被可为规则干扰波，随机噪声可称为不规则干扰波，前者在地震记录上具有规律性，后者具有随机性。相干噪声通常存在于相邻地震道中且由源或主波场与地面的相互作用产生，例如底波，多次波，面波，声波等。而随机噪声的记录方式是由每个检波器独立记录的，即不会在相邻地震道中产生关联。随机噪声的成因可能与环境因素有关，例如人的行走，风吹草动等外部因素产生的振动。这些随机扰动的能量非常小，所以只能被附近的检波器记录而不能被远处的检波器记录到，因此在地震记录中随机噪声表现往往不连续，检波器周围的其他各种形式的扰动也可能产生随机噪声。常见的噪声类型如下表：

表 1 常见噪声及其特点

	名称	特点
相干噪声	声波	频率高，延续时间长，速度约为 340m/s，在地震记录上呈现强而尖锐的波至
	面波	频率低，延续时间长，能量强，在地震记录上呈扫帚状（即具有频散现象）
	工业电干扰	频率恒定为 50Hz
	重复冲击	井中和水中放炮时容易出现，波的视速度与一次波速度相同
	浅层折射	浅层界面形成的折射波，地震记录上为较强的线性同相轴
	多次波	与一次反射波波形相似，但传播速度一般略低，时距曲线斜率大
	侧面波	视速度为海水中的波速，约 1500m/s
	底波	常见于浅海地震勘探，频率低，视速度小，横向衰减慢，延续时间长。
非相干噪声	随机噪声	形成原理复杂，强度不一，频带宽
	异常值噪声	能量强，产生原因复杂

除此之外，陆上采集到的实际数据常含有不稳定的异常值噪声。数学上异常值（outlier）是指一组测定值中与平均值的偏差超过两倍标准差的测定值，与平均值的偏差超过三倍标准差的测定值称为高度异常的异常值。在数据处理中应剔除高度异常的异常值。地震勘探中的异常值噪声可能由空气冲击、输电线和其他人为因素、记录和奇偶校验误差、未修正的极性逆转、孤立的噪声脉冲（通常由于卷积峰值、0 值和截断）、哑炮、散射噪声、较差的地表条件、有缺陷或不耦合的地震检波器、风、雨等许多的其他影响造成。压制叠前地震数据中

的噪音有利于去除多次波、AVO 分析和改善叠加效果。一般通过滤波或者道剔除的方法来去除异常值噪声，现代三维地震数据的数据量巨大，手工地震道编辑变得不切实际。而一般的滤波方法要么对噪音的压制效果不佳，要么压制过度，会损失一些有效的地震信号。

稳健主成分分析（RPCA）是近些年兴起的一种用于去除地震数据异常值噪声的方法，它是对主成分分析算法的改进，可以较好地恢复和重构有效信号，压制离群的异常值信号。传统的 F-XY 预测滤波法对不符合高斯分布的异常值噪声的压制效果欠佳且会伤害一部分有效信号。国内外许多专家和学者对传统的去噪算法进行研究和改进，使之可以有效地压制异常值噪声：如 Chen 等提出的稳健主成分分析算法就可以有效压制地震数据中的异常值噪声。本文合成了三个模型数据进行算法测试，并使用稳健主成分分析算法对实际地震数据进行了去噪处理。

1.2 国内外研究现状

随着现代地震数据的数据量以及处理难度的不断增大，最初采用手动剔除、人工道编辑等方法去除异常值噪声的方法已不再适用。随着计算机科学技术的发展，使用计算机进行去噪处理成为替代手工处理的最佳途径。中外学者将地球物理知识、数学及计算机技术相结合，创造出一系列用于压制异常值噪声的方法，如小波变换法、预测滤波法、稳健主成分分析等。

1.2.1 基于小波变换的异常值噪声压制

小波变换最早应用于信号和图像的处理，它自上个世纪的应用数学分支发展而来，一定程度上继承并发展了傅里叶变换的思想。这种方法可以聚焦到信号的细枝末节，且多分辨率、多尺度。随着其进一步发展，后期开始逐渐用于地震资料的处理。

Donoho 和 Johnston 等（1997）对小波变换进行了研究，提出两种信号去噪方法，即软阈值和硬阈值，并进而给出了通用阈值的计算公式，也在理论上证明此阈值是最优结果。

Chang 等（2000）提出一种将自适应阀值和平移不变去噪思想结合在一起的自适应小波阀值去噪方法，该方法主要用于图像空域的处理，其阀值可根据图像特征的改变而自行改变。

郝雪等（2006）提出一种新的处理方法，它基于奇异值分解和小波阀值，先使用混沌振子法找到有效信号，然后通过线性时移将同相轴校正到同一方位，再使用奇异值分解滤波，然后反线性时移将同相轴变回原始位置，最后用小波逆变换重构信号。

1.2.2 基于中值滤波的异常值噪声压制

中值滤波的特点是可以在有效压制脉冲噪声同时保护信号的边缘且实现方式比较简单。中值滤波方法通过观察一定的窗口的数据，用其中几个采样点的中值对原来某个采样点的值进行替代，属于低通滤波器。

陈志德等（2010）提出了一种基于中值滤波的异常振幅噪声分频压制技术，根据异常值振幅噪声集中分布于检波点集而随机分布于炮集的特点，通过将炮集数据划分为不同的频率子集，在每个频率子集上使用中值滤波进行噪声压制。

潘军等（2016）提出了一种基于插值方法的异常振幅衰减技术的应用，在给定的某个频率范围内，当某道信号的振幅大于给定的阈值时，该道被认定为异常道，采用相邻道的插值来代替。

1.2.3 基于降秩滤波的异常值噪声压制

降秩滤波是奇异谱分析（SSA）在地震数据处理领域的应用。奇异谱分析通过对一维时间序列的研究构造出轨迹矩阵，并对轨迹矩阵进行分解、重构，从而提取出代表原时间序列不同成分的信号。

奇异谱分析通过在给定的单一频率将时间域的数据嵌入到轨迹矩阵中从而在频域中操作。因为异常值噪声会使矩阵的秩增加，所以可以从噪声观测的轨迹矩阵的低秩近似（Oropeza 和 Sacchi，2011）中估计理想无噪声的轨迹矩阵。奇异谱分析（SSA）重建也可以通过形成多层次的轨迹矩阵压制多维地震数据中的噪声。在这种情况下产生了基于奇异值分解（SVD）、Lanczos 双对角化和随机 QR 分解等通过矩阵降秩的去噪方法。

由于传统多道奇异谱分析处理后，地震数据异常值噪声得不到有效的压制。Trickett（2012）提出了一种基于截断奇异值分解（TSVD）的稳健降秩滤波方法，设计了一个双平方重加权因子，通过降秩后的频率切片和原始频率切片加权迭代降秩来压制异常值噪声，并用该方法对模型数据和实际数据进行测试，压制效果良好。

Chen 和 Sacchi（2014）认为奇异值分解（SVD）这种矩阵分解技术是非稳健的，当地震数据中混有不符合高斯分布的异常值噪声时，SVD 无法有效压制不稳定的异常值噪声，于是提出了一种基于随机 QR 分解的稳健奇异谱分析方法，以在有效压制随机噪声的同时压制不稳定的异常值噪声。

陈阳康等（2016）认为截断奇异值分解（TSVD）的原理是将数据投影到一个信号-噪声域和一个噪声域，得到的结果是信号-噪声域中的数据，因此提出了一种阻尼多道奇异谱分析（DMSSA）的方法。该方法在 TSVD 的基础上加入一个阻尼矩阵来进一步压制残留的噪声，并用改进的多道奇异谱分析方法同时进行缺失道重建和去噪。

1.3 论文主要内容及成果

1.3.1 论文主要研究工作

（1）第一阶段：通过阅读文献，了解地震数据中噪声的种类、形成机制和特点，了解地震数据去噪方法的发展历程和研究现状。

（2）第二阶段：整理思路并查阅资料，结合数学公式使用 MATLAB 进行稳健主成分分析算法的程序编写。

（3）第三阶段：学习使用地震软件包 SeismicLab，并编写程序生成理想模型数据和异常值数据。

（4）第四阶段：使用基于稳健主成分分析算法的去噪程序对合成的模型数据进行去噪处理，得到去噪结果和差剖面，并计算品质因子，分析品质因子与截断误差和最大迭代次数的关系。

（5）第五阶段：处理含有异常值噪声的实际数据，并画图分析去噪的结果。

1.3.2 论文主要成果

（1）掌握稳健主成分分析的公式及原理，通过查阅文献理解稳健主成分分析的数学分析过程，学习相关数值分析知识。

（2）使用 MATLAB 生成线性同相轴、弯曲同相轴的三维地震数据以及生成异常值噪声，再合成只含异常值噪声的模型数据和既含异常值噪声又含随机噪声的模型数据。

（3）使用 MATLAB 编写基于稳健主成分分析算法的去噪程序，包含以下几个小模块：将时间域的三维地震数据通过傅里叶变换转换到频率域、在频率域进行切片处理、对每个切片进行去噪处理、将处理后的数据通过反傅里叶变换返回时间域、计算品质因子并绘制图件。

（4）比较最大迭代次数、截断误差不同时噪音压制的效果，并绘制品质因子随最大迭代次数、截断误差改变的变化曲线，以提高算法的性能。相比传统去噪方法，稳健主成分分析算法可以有效的去除地震数据中的异常值噪声。

（5）处理实际数据，结果表明本文方法对异常值噪声和随机噪声都能进行有效压制。

1.3.3 论文主要章节安排

论文第一章首先介绍了本次毕业设计的目的与意义、异常值噪声压制问题的研究现状及论文的主要内容和成果；第二章讲述稳健主成分分析的数学原理，编程的硬软件环境和算法流程；第三章展示了稳健主成分分析算法对模型数据和实际数据的处理效果并对方法的优缺点及使用前提条件进行了分析。

2.稳健主成分分析方法的噪音压制原理

2.1 方法原理

2.1.1 主成分分析（Principal Component Analysis，PCA）

主成分分析（PCA）是统计中进行多元分析的重要工具。这个想法是在减少数据体的维数的同时保留尽可能多的数据变量的可变性（Jolliffe，2010）。让我们考虑从观测数据中恢复低秩矩阵 L，

$$\mathbf{D} = \mathbf{L} + \mathbf{E} \tag{1}$$

其中，矩阵 **E** 代表额外误差。我们假设 **E** 由小的随机扰动组成，则可以通过以下优化问题获得 L 的最优估计

$$\min \|\mathbf{E}\|_F^2$$

$$\text{s.t.} \quad \text{rank}(L)=k, \quad \mathbf{D} = \mathbf{L} + \mathbf{E} \tag{2}$$

该问题可以通过奇异值分解（SVD）有效地解决。奇异值分解是矩阵分析中正规矩阵酉对角化的推广。假设 **M** 是一个 m×n 阶矩阵，其中的元素全部属于域 **K**，**K** 可以是实数域或复数域。如此则存在一个分解使得：

$$\mathrm{M} = \mathrm{U} \sum \mathrm{V}^* \tag{3}$$

其中，**U** 是 m×m 阶酉矩阵；Σ 是半正定 m×n 阶对角矩阵；而 V*，即 V 的共轭转置，是 n×n 阶酉矩阵。这样的分解就称作 **M** 的奇异值分解。**Σ** 对角线上的元素 Σ_i 为 **M** 的奇异值，通常奇异值由大而小排列。

2.1.2 稳健主成分分析（Robust Principal Component Analysis，RPCA）

由于主成分分析算法对不符合高斯分布的异常值噪声的压制效果不佳，学者们便提出了一种可以有效压制异常值噪声的稳健主成分分析算法。该方法的基本思想是在频率-空间域中通过对数据体实施稳健低秩近似来实现。其中采用核范数最小化约束来产生理想的低秩近似数据，同时使用 L1 范数约束来估计异常值（稀疏）噪声。然后运用具有两步软阈值的一阶梯度迭代方法解决该数学问题。

假设稀疏矩阵 **S** 来表示异常值噪声。**S** 中仅有少数项是非零元素并且振幅是可以任意大（Zhou 等，2010）。 稳健主成分分析提出了以下优化问题：

$$\min \|\mathbf{S}\|_0$$

$$\text{s.t.} \quad \text{rank}(\mathbf{L})=k, \quad \mathbf{D}=\mathbf{L}+\mathbf{S} \tag{4}$$

其中，$\|\mathbf{S}\|_0$ 表示 S 的 L0 范数，即 S 中非零元素的个数。等式（4）是一个 NP-hard 问题。为使问题可解，我们使用由矩阵 S 中所有元素绝对值之和定义的 L1 范数来代替 L0 范数。同时，我们考虑用 L 的核范数代替低秩约束，其中 L 的核模定义为矩阵 L 的所有非零奇异值的和。可以证明 L1 范数是 L0 范数最严格的凸松弛。（Donoho，2006）。同理，核范数是对低秩约束的紧凸松弛（Fazel，2002）。我们还引入了 Frobenius 范数约束，$\|\mathbf{D}-\mathbf{L}-\mathbf{S}\|_F^2$ 来约束高斯噪声。产生的目标函数可以写成如下形式，

$$\min J = \frac{1}{2\mu}\left\|\mathbf{D}-\mathbf{L}-\mathbf{S}\right\|_F^2 + \lambda\left\|S\right\|_1 + \left\|\mathbf{L}\right\|_* \quad (5)$$

λ为平衡稀疏性和低阶约束的折衷因子。μ是一个取值较小的常数，用来控制高斯噪声。

我们考虑用迭代法来求取在最小化等式（5）时的低秩数据 L 以及稀疏异常值噪声矩阵 S。基于子梯度方法我们将目标函数分为两个子问题。等式（5）的解等价于以下目标函数的解，

$$\min J_S = \lambda\left\|\mathbf{S}\right\|_1 + \left\|\mathbf{S}-\hat{\mathbf{S}}^{\mathrm{k}}\right\|_F^2 \quad (6a)$$

$$\min J_L = \left\|\mathbf{L}\right\|_* + \left\|\mathbf{L}-\hat{\mathbf{L}}^{\mathrm{k}}\right\|_F^2 \quad (6b)$$

仅当$\hat{\mathbf{L}}^k$和$\hat{\mathbf{S}}^k$收敛于，

$$\min J_0 = \frac{1}{2\mu}\left\|\mathbf{D}-\mathbf{L}-\mathbf{S}\right\|_F^2 \quad (7)$$

因此，我们可以通过在 J0 梯度的相反方向上更新当前估计来计算$\hat{\mathbf{L}}^k$和$\hat{\mathbf{S}}^k$

$$\hat{\mathbf{S}}^k = \mathbf{S}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$$

$$\hat{\mathbf{L}}^k = \mathbf{L}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D}) \quad (8)$$

等式（6a）在压缩感应领域中十分常见。它通过对$\hat{\mathbf{S}}^k$的所有元素项实施软阈值操作来更新解（Beck 和 Teboulle，2009）。 方程（6b）的解也可以利用最新的矩阵补全研究进展来找到。在这里，不是将软阈值直接应用于输入项，而是对矩阵$\hat{\mathbf{L}}^k$的奇异值实施软阈值操作来实现（Cai 等，2010; Recht 等，2010）（参见算法（1））。

算法 1 RPCA

输入：

观测数据 D，权衡参数λ和截断误差ε

初始化：

$\mathbf{L}^0 = 0; \mathbf{S}^0 = 0; k = 1$

重复

$$\hat{\mathbf{S}}^k = \mathbf{S}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$$

$$\hat{\mathbf{L}}^k = \mathbf{L}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$$

$$\mathbf{S}^{k+1} = \max(\left|\hat{S}_k(i,j)\right| - \frac{\lambda\mu}{2}, 0)$$

$$\left[\mathbf{U}, \Sigma, \mathbf{V}\right] = \mathrm{svd}\left[\hat{\mathbf{L}}^k\right]$$

$$\hat{\Sigma} = \max(\left|\Sigma(i,i)\right| - \frac{\lambda\mu}{2}, 0)$$

$\mathbf{L}^{k+1} = \mathbf{U}\hat{\sum}\mathbf{V}^{*}$

$k = k+1$

until $\left\|\mathbf{D}-\mathbf{L}^{k}-\mathbf{S}^{k}\right\|_{F}^{2} < \varepsilon$

输出：

低秩近似 $\mathbf{L}^{k+1}$;

估测异常值噪声 $\mathbf{S}^{k+1}$.

RPCA 方法的实现过程如算法（1）所示。在每次迭代中，我们都会根据二次项的梯度，在反方向上修改低秩矩阵与异常值噪声的当前估计值。然后，我们应用软阈值二步法得到修改后的估算值。Zhou 等（2010 年）证明选择 $\lambda = 1/\max(m,n)$ 可以保证高质量的恢复矩阵 L，其中 m 和 n 是输入矩阵 D 的大小。可以根据下式计算参数 μ：$\mu = 0.1\sqrt{\max(m,n)} + 8\sigma\sqrt{\max(m,n)}$（Tao and Yuan，2011），其中，σ 是数据中噪声标准差的估计值。

采用稳健主成分分析来压制地震数据中存在的异常值噪声。我们考虑将 RPCA 算法应用于从高维地震数据集中提取的 3D 数据 $D(t,x,y)$。我们注意的是，将数据从 t-x-y 域映射到 f-x-y 域的傅里叶变换可以表示为，

$$\tilde{D}(\omega,x,y) = \int D(t,x,y)e^{i\omega t}d\omega \qquad (9)$$

在给定的频率 ω，空间数据可以通过频谱矩阵 $\mathbf{D}_{\omega}$ 表示。所需信号沿两个空间方向是相干的，因此，$\mathbf{D}_{\omega}$ 是一个低阶矩阵（Trickett，2003；Cheng 和 Sacchi，2014）。应用于 f-x-y 域三维数据体频率切片的稳健矩阵降秩去噪算法如算法（2）所示。

算法 2 RPCA 去噪

输入：

三维地震数据体 $\boldsymbol{\mathcal{D}}$

权衡参数 λ

$\tilde{D}(\omega,x,y) \leftarrow D(t,x,y)$

for $\omega = \omega_{\min} : \omega_{\max}$ do

$\mathbf{D}_{\omega} \leftarrow \tilde{D}(\omega,:,:)$

$[\mathbf{L},\mathbf{S}] = \mathrm{RPCA}[\mathbf{D}_{\omega}]$

$\tilde{\tilde{D}}(\omega,:,:) \leftarrow \mathbf{L}$

end for

$\tilde{D}(t,x,y) \leftarrow \tilde{\tilde{D}}(\omega,x,y)$

由此可见，使用稳健主成分分析（RPCA）会在有效压制稀疏异常值噪声数据的同时能较好的保留低秩有效信号。

2.2 算法及其流程

2.2.1 软硬件环境

（1）硬件环境：

内存：16G；

处理器：Intel(R) Core(TM) i7-6700HQ CPU @ 2.60GHz　2.60GHz；

显卡：NVIDIA GeForce GTX 970M；

硬盘：1T；

（2）软件环境：

操作系统：Windows 10 家庭版；

开发环境：MATLAB R2018b；

工具包：SeismicLab

2.2.2 算法流程

本文首先使用常用的地震数据处理软件包 SeismicLab 建立理想数据模型和异常值噪声模型，然后采用基于稳健主成分分析算法的程序进行去噪处理。我们通过模型数据和实际数据测试了稳健主成分分析的压制效果，并用品质因子 Q 来评估该算法的性能。

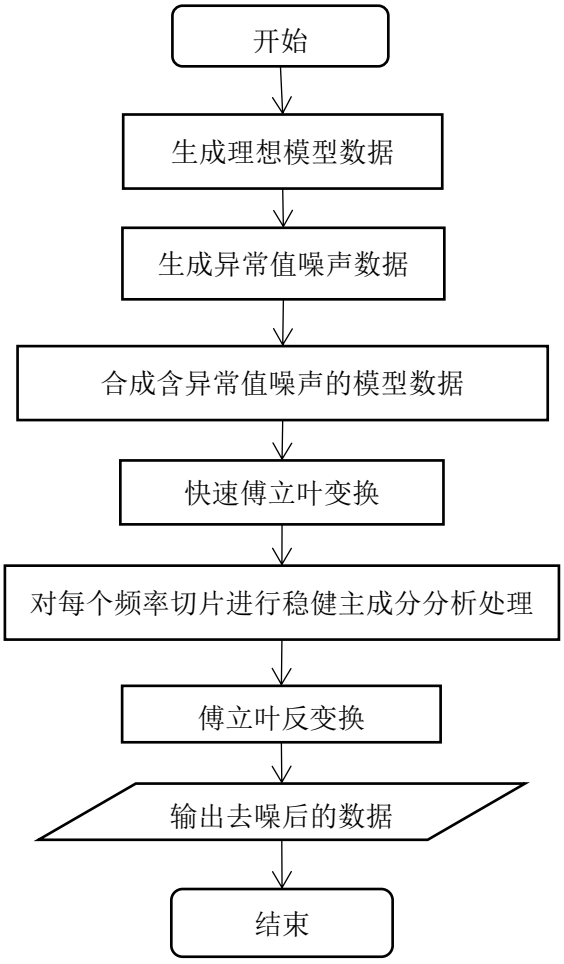


图 1 RPCA 去噪算法流程图

基于稳健主成分分析去噪的主程序包含了三维地震模型生成的程序（使用软件包 SeimicLab 中的函数进行生成）、异常值噪声生成的程序、合成含噪声模型的程序和稳健主成分分析去噪的程序。其中稳健主成分分析去噪的程序又包含了两个子程序，第一个子程序是稳健主成分分析算法，第二个子程序是去除地震数据中噪声的去噪算法，功能是将时间域的地震数据通过傅里叶变换转换到频率域并对每个切片进行稳健主成分分析处理，然后在使用傅里叶反变换转换回时间域。本节将详细介绍本次毕业设计的程序代码，并给出变量说明表和流程图。

（1）异常值噪声生成程序

该程序通过 Ricker 子波与反射系数序列褶积来生成异常值噪声，首先初始化一个与模型数据维度相同的矩阵，并通过随机数的概念随机生成不同反射系数序列，然后生成 Ricker 子波将二者褶积，以某一设定的比例插入到初始化矩阵中，生成三维异常值噪声矩阵。异常值噪声合成算法变量说明见表 2，算法流程如图 2 所示。

表 2 异常值噪声合成算法变量说明表

名称	变量类型	作用/意义
f	浮点型变量	输入 Ricker 子波的主频
nx	整形变量	输入模型数据 X 方向的道数
ny	整形变量	输入模型数据 Y 方向的道数
nt	整形变量	输入模型数据的时间采样点数
dt	浮点型变量	输入时间采样间隔
r	浮点型变量	地震道中异常值道的比例
s	浮点型变量	一个反射系数序列中存在反射系数的比例
ntr	整形变量	生成反射系数序列的数量
ref	ntr×nt 的矩阵	生成 ntr 个反射系数序列
wavelet	nt×num 的矩阵	生成的 Ricker 子波
yy	ntr×nt 的矩阵	储存生成的异常值道
erratic	nt×nx×ny 的矩阵	初始化异常值噪声矩阵
q	整形变量	将第 q 个异常值道添加在矩阵中

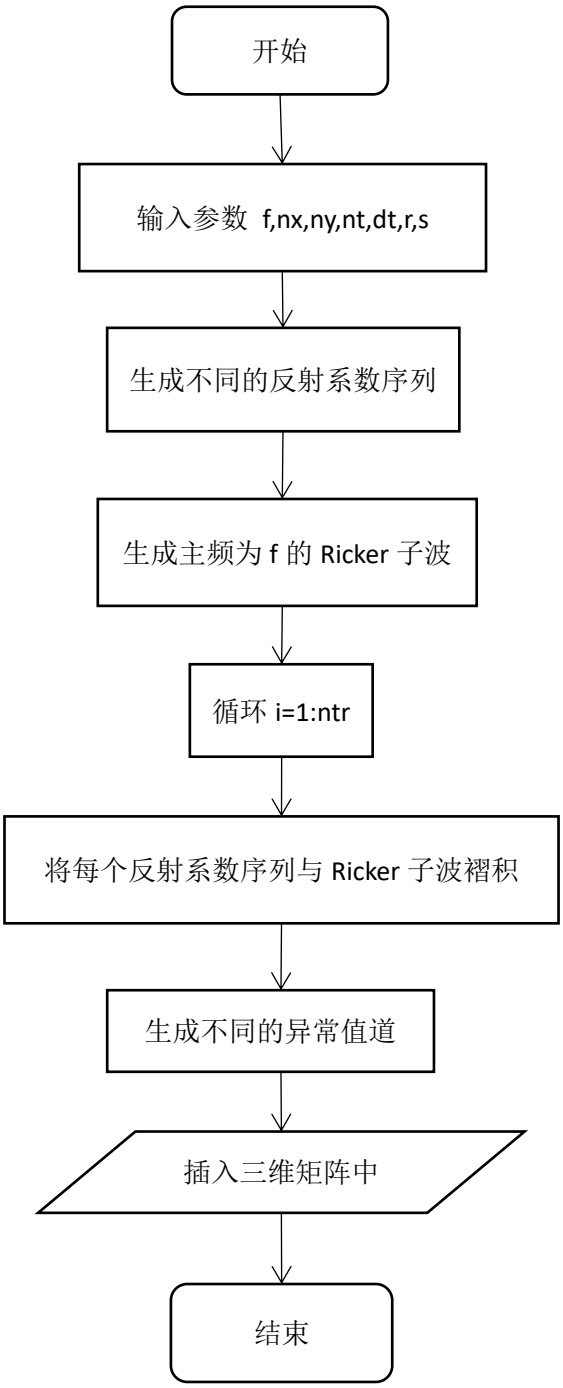


图 2 异常值噪声合成算法流程

（2）稳健主成分分析去噪程序

稳健主成分分析去噪程序的主要功能是对时间域的三维地震数据进行快速傅里叶变换转换到频率域，并使用一个循环结构对每个频率切片进行去噪处理，再对处理后的数据进行反傅里叶变换转换回时间域。此外还可以设置和计算用于稳健主成分分析算法的截断误差、最大迭代次数和正则化参数、调优参数等参数。算法变量说明见表 3，算法流程图见图 3。

表 3 稳健主成分分析去噪程序变量说明表

名称	变量类型	作用/意义
D	三维矩阵	输入的需要去噪的地震数据体
LMD	浮点型变量	平衡参数
YBSL	浮点型变量	截断误差
MIU	浮点型变量	调优参数
f_min	整形变量	去噪频带的最低频率值
f_max	整形变量	去噪频带的最高频率值
dt	整形变量	采样间隔
Niter	整形变量	最大迭代次数
STD	二维矩阵	计算得到数据的标准差
OMG_min	整形变量	去噪频带最低频率值对应的频率切片序号
OMG_max	整形变量	去噪频带最高频率值对应的频率切片序号
D_rec	三维矩阵	用于储存去噪后空间域数据的矩阵
D_recFXY	三维矩阵	用于储存去噪后频率域数据的矩阵
D_FXY	三维矩阵	对 D 进行快速傅里叶变化之后的结果
D_FXYk	二维矩阵	对频率域的三维地震数据进行切片
L1	二维矩阵	经稳健主成分分析处理后的频率切片
Q	浮点型变量	用于计算品质因子 Q

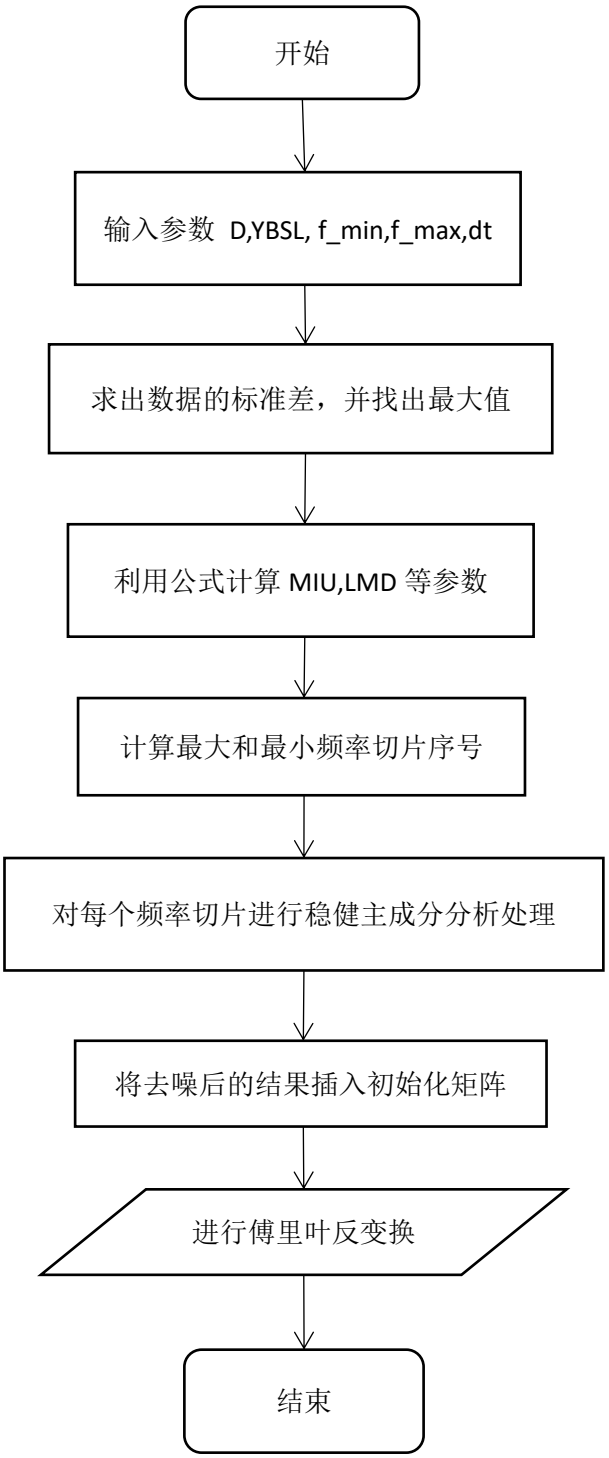


图 3 稳健主成分分析去噪子程序流程图

（3）稳健主成分分析算法

稳健主成分分析算法是去异常值噪声主程序的核心，主要功能是将合成数据或实际数据恢复成一个无噪声的理想矩阵和一个仅含噪声的噪声矩阵。算法变量说明见表 4，算法流程图为图 4。

表 4 稳健主成分分析算法变量说明表

名称	变量类型	作用/意义
D	二维矩阵	输入需要去噪的数据
LMD	浮点型变量	输入正则化参数
MIU	浮点型变量	输入调优参数
YBSL	浮点型变量	输入迭代的截断误差
Niter	整形变量	输入迭代的最大迭代次数
normX	浮点型变量	对输入数据数据求 F 范数
L	二维矩阵	初始化理想数据矩阵
S	二维矩阵	初始化噪声数据矩阵
err	浮点型变量	计算迭代误差

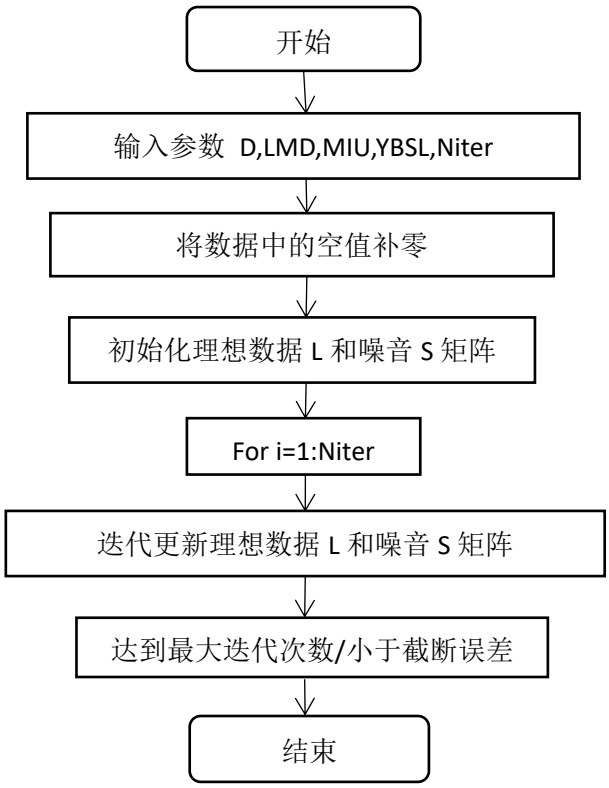


图 4 稳健主成分分析算法流程图

3.数据测试与分析

3.1 模型数据测试

合成的模型数据分为两类，第一类是含线性同相轴的三维地震数据，第二类是含弯曲同相轴的三维地震数据。第一类线性同相轴的数据中又分为仅含有异常值噪声的数据和既含有异常值噪声又含有高斯分布的随机噪声的数据（更接近于实际情况）。其中添加异常值噪声的振幅值约为地震数据最大振幅的三倍。通过品质因子 Q 来评估算法的性能来研究其去噪效果，Q 定义为：

$$Q = 10\lg \frac{\|D\|_F^2}{\|\tilde{D} - D\|_F^2}$$

其中，D 是无噪声数据，而 $\tilde{D}$ 表示去噪后的数据。其中 Q 越大表示去噪效果越明显。

3.1.1 线性同相轴实验

本节主要讲述稳健主成分分析算法对三维地震数据（线性同相轴）中异常值噪音的压制效果。

首先生成一个不含随机噪声的三维地震数据，再向其中加入随机生成的异常值数据进行稳健主成分分析算法的测试。此外又对含高频异常值噪声的数据进行测试。最后由于实际地震数据往往存在随机噪声，所以又在三维地震数据中加入了随机噪声来模拟实际采集的地震数据，然后再次使用稳健主成分分析算法进行测试。

（1）不含随机噪声的数据

首先生成一个（301x64x64）三维地震数据，其中 x、y 方向的维数 nx=ny=64，时间采样点数 nt=301，采样间隔 dt=0.002s，子波主频 f=20Hz。选取其中 x=5 的切片，其切片图和 F-K 谱图如图 5 所示。

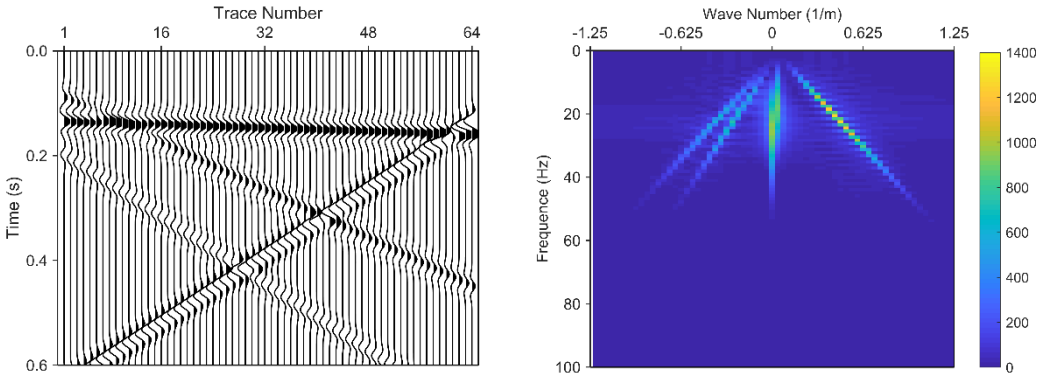


图 5 三维地震数据的切片图及其 F-K 谱图

以 r=15%（单道中存在反射系数的比例），s=1%（存在异常值道的比例）随机生成反射系数序列，Ricker 子波主频为 20Hz，二者褶积后得到异常值噪声数据（301x64x64）。选取 x=5 的切片，其切片图和 F-K 谱图如图 6 所示。

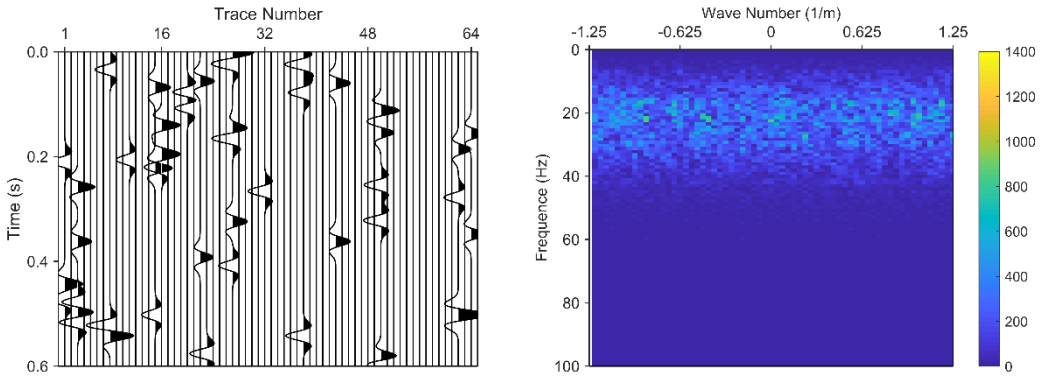


图 6 异常值噪声数据切片图及其 F-K 谱图

将异常值噪声添加到三维地震数据中得到含异常值噪声的数据。此时由含异常值噪声的三维地震数据和不含噪声的三维地震数据计算得到的品质因子 Q=-1.46。选取其中 x=5 的切片，其切片图和 F-K 谱图如图 7 所示。

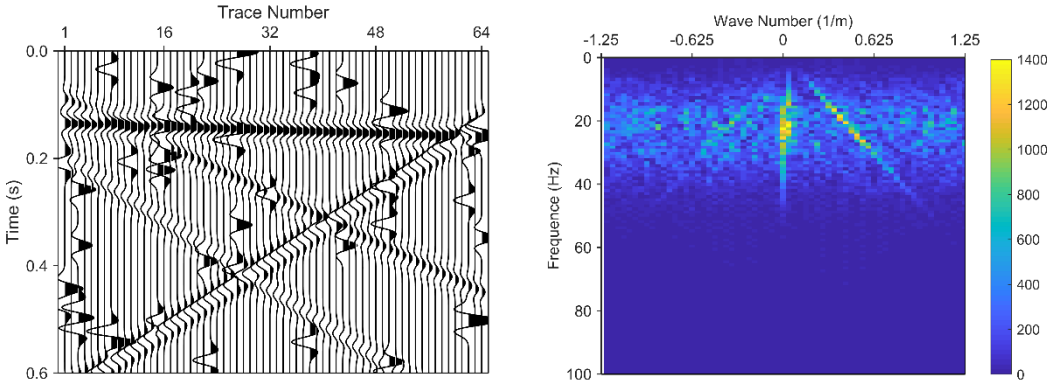


图 7 含异常值噪声的三维地震数据切片图及其 F-K 谱图

首先，使用传统 F-XY 预测滤波方法进行异常值噪声的压制，计算的到的品质因子为 Q=1.58。选取其中 x=5 的切片，去噪结果的切片图和 F-K 谱图如图 8 所示。

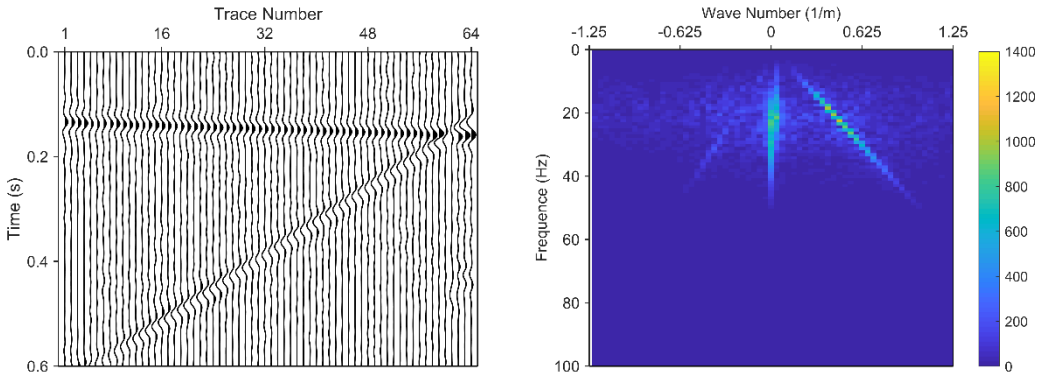


图 8 F-XY 预测滤波去噪后数据的切片图及其 F-K 谱

使用传统 F-XY 预测滤波压制掉的异常值噪声剖面。选取其中 nx=5 的切片，其切片图和 F-K 谱图如图 9 所示：

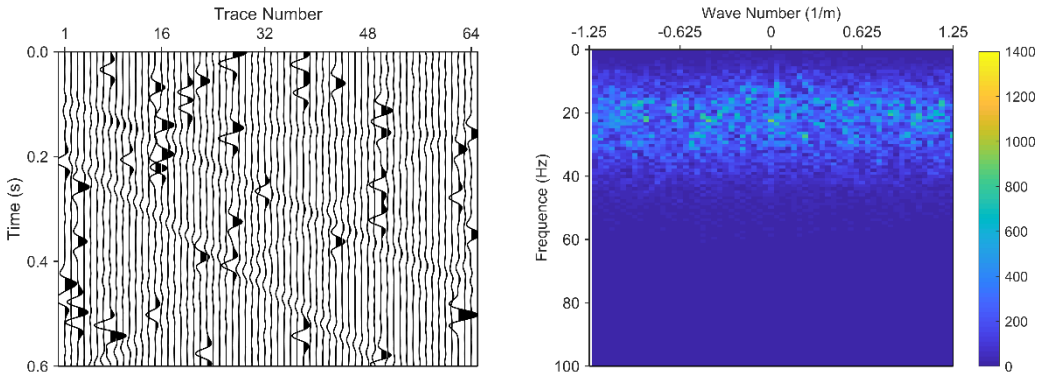


图 9 F-XY 预测滤波压制掉的异常值噪声剖面切片图及其 F-K 谱

F-XY 预测滤波结果与原始无噪声数据的差剖面。选取其中 x=5 的切片，其切片图和 F-K 谱图如图 10 所示。

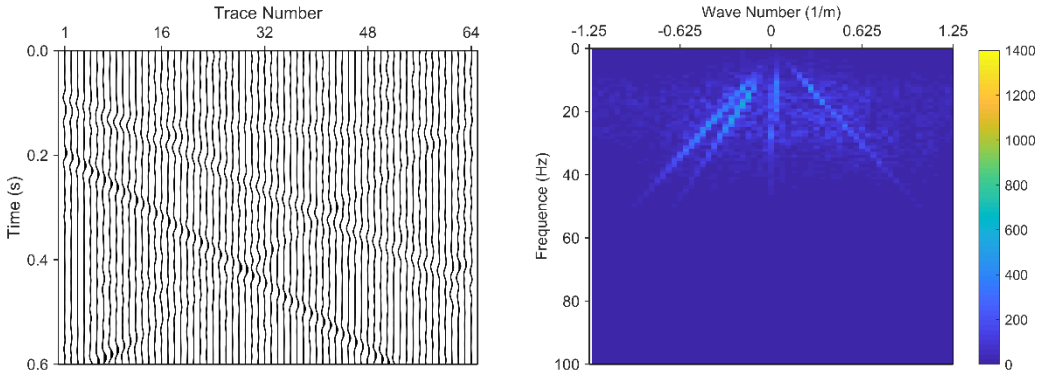


图 10 F-XY 预测滤波去噪结果的差剖面及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差$\varepsilon=10^{-8}$，当最大迭代次数 Niter=500 时，品质因子为 Q=7.44。选取 x=5 的切片，去噪结果的切片图和 F-K 谱图如图 11 所示。保持其他参数不变，当最大迭代次数 Niter=1000 和 Niter=1500 时的去噪结果切片及其 F-K 谱分别如图 12 和 13 所示，对应的 Q 值分别为 18.05 和 22.13。

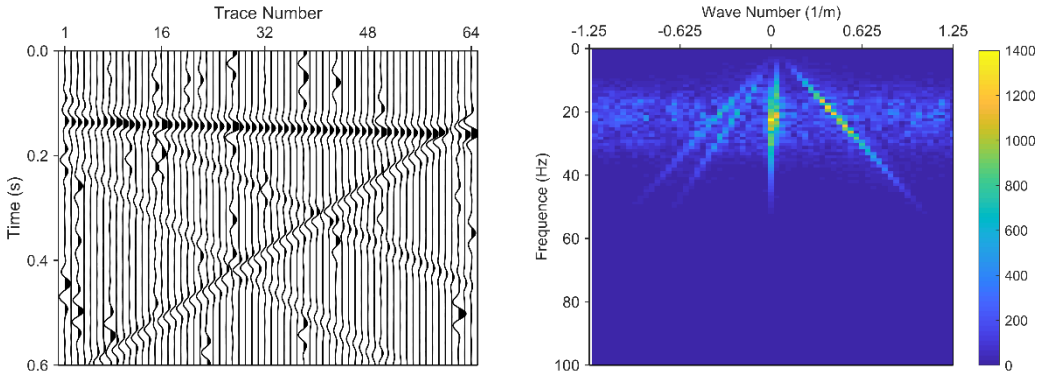


图 11 Niter=500 时 RPCA 去噪结果的切片图及其 F-K 谱

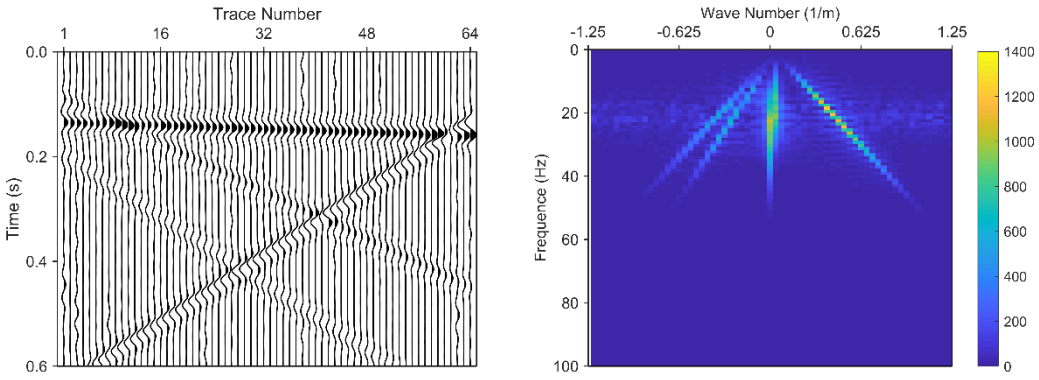


图 12 Niter=1000 时 RPCA 去噪结果的切片图及其 F-K 谱

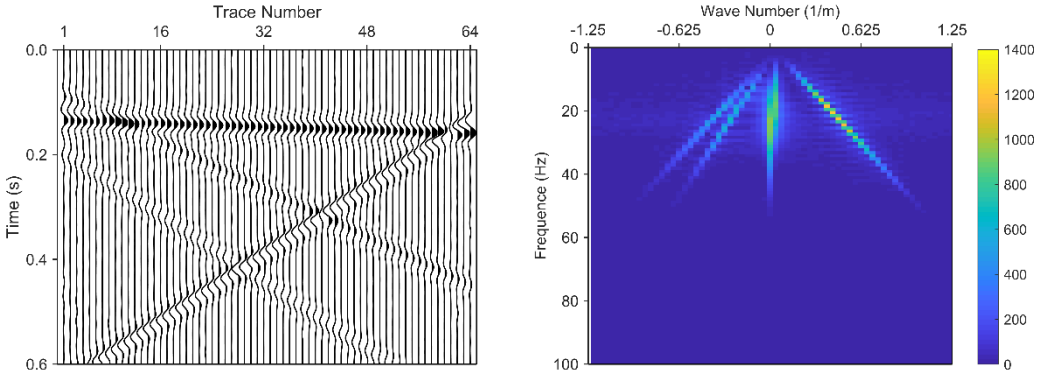


图 13 Niter=1500 时 RPCA 去噪结果的切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差ε=10^{-8}，当最大迭代次数 Niter=500 时，选取 x=5 的切片，压制掉的异常值噪声剖面切片图及其 F-K 谱如图 14 所示。保持其它参数不变，当最大迭代次数 Niter=1000 和 1500 时压制掉的异常值噪声剖面切片图及其 F-K 谱如图 15 和图 16 所示。

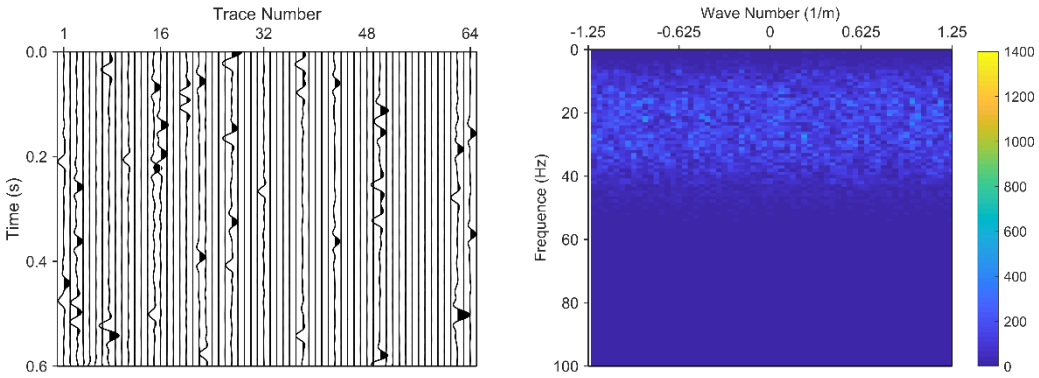


图 14 Niter=500 时压制掉的异常值噪声剖面切片图及其 F-K 谱

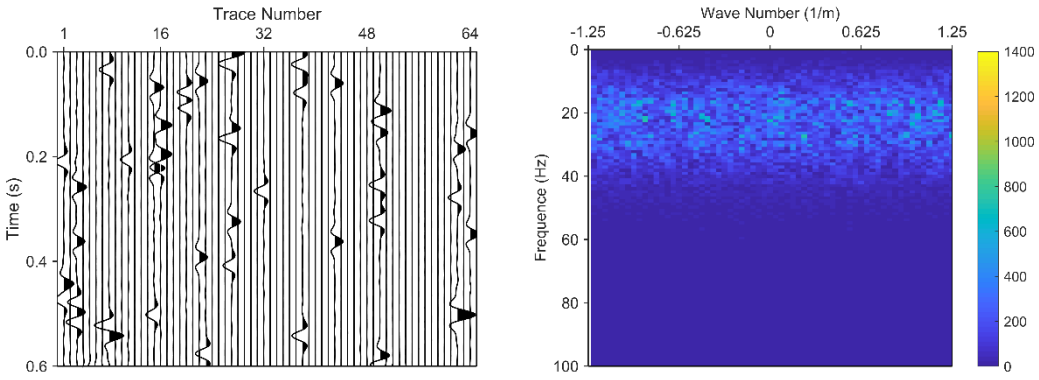


图 15 Niter=1000 时压制掉的异常值噪声剖面切片图及其 F-K 谱

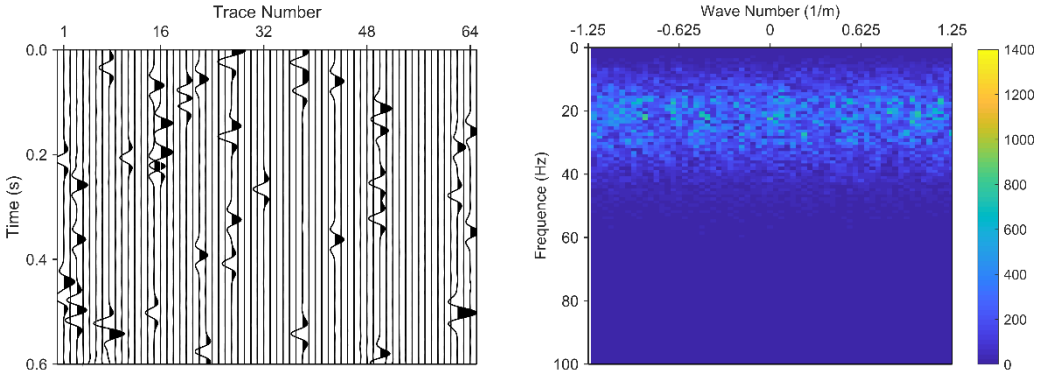


图 16 Niter=1500 时压制掉的异常值噪声剖面切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差ε=10^{-8}，当最大迭代次数 Niter=500 时，选取 x=5 的切片，去噪结果与原始无噪数据的差剖面切片及其 F-K 谱如图 17 所示。保持其它参数不变，当最大迭代次数 Niter=1000 和 1500 时去噪结果与原始无噪数据的差剖面切片及其 F-K 谱如图 18 和 19 所示。

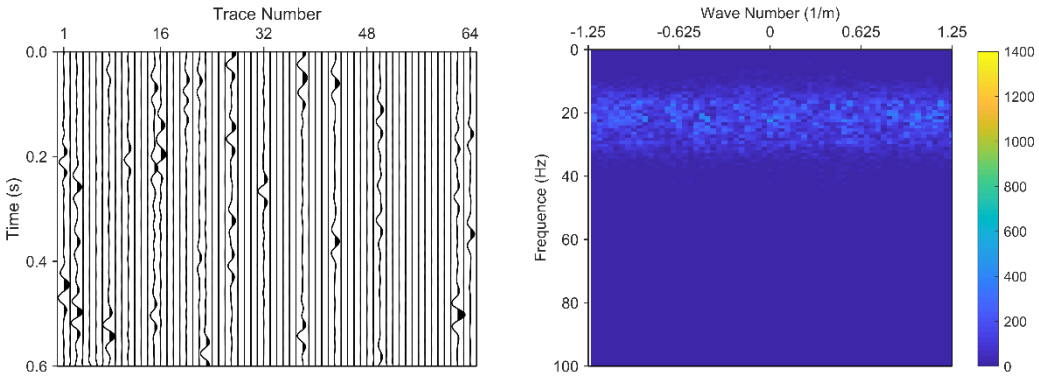


图 17 Niter=500 时 RPCA 去噪结果的差剖面及其 F-K 谱

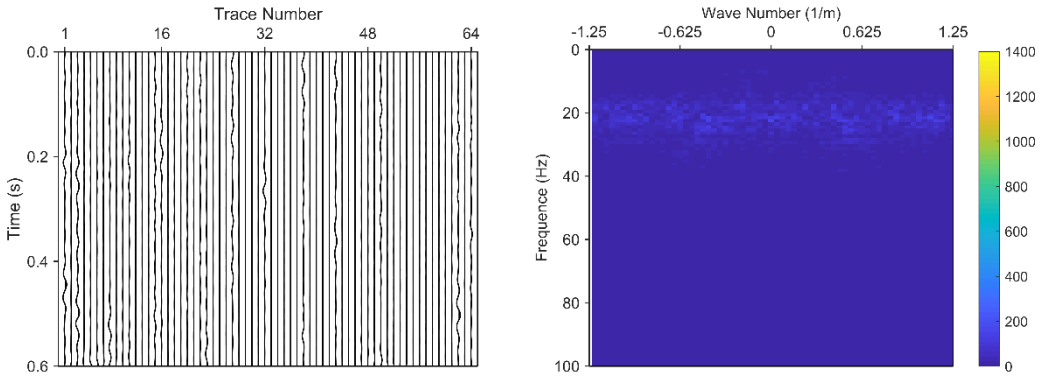


图 18 Niter=1000 时 RPCA 去噪结果的差剖面及其 F-K 谱

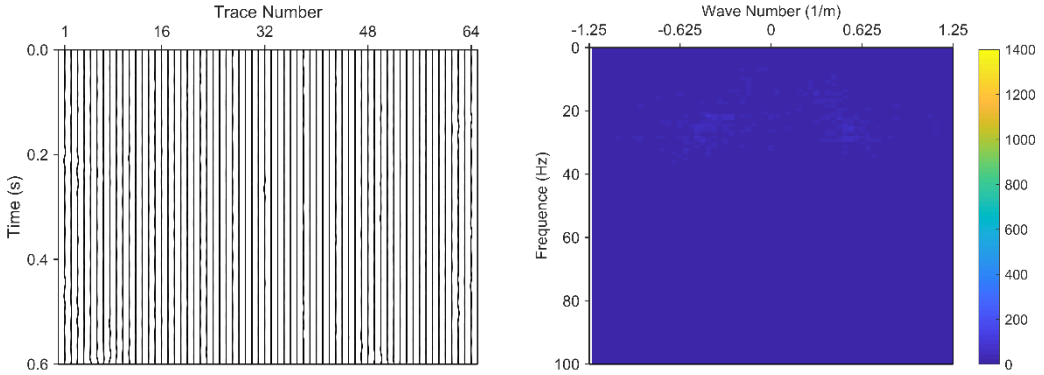


图 19 Niter=1500 时 RPCA 去噪结果的差剖面及其 F-K 谱

本节合成了一个含有线性平面波的三维数据体用来检验稳健主成分分析算法的异常值噪声压制效果。图 5-图 7 显示了合成的三维无噪声地震数据、异常值噪声数据和两者混合的含噪数据。图 8-图 10 显示了 F-XY 预测滤波算法对仅含有异常值噪声的三维地震数据的去噪结果，试验结果表明 F-XY 预测滤波方法虽然可以去除异常值噪声，但同时也会伤害有效信号的能量。图 11-图 13 显示了稳健主成分分析算法对仅含有异常值噪声的三维地震数据的去噪结果，其中可以看出随着最大迭代次数 Niter 的增大，去噪效果越来越明显。当 Niter=0、500、1000、1500 时对应的品质因子 Q 分别为-1.46、7.44、18.05、22.13。图 14-图 16 显示了用 RPCA 方法压制掉的异常值噪声，从图上可以看出随着最大迭代次数 Niter 的增大，去掉的异常值剖面及其 F-K 谱与原始生成的异常值剖面及其 F-K 谱越来约接近。图 17-图 19 显示了去噪后数据与原始无噪数据之间的差剖面。从差剖面上可以看出，随着最大迭代次数 Niter 的增大，异常值噪声逐渐被压制，残留的异常值噪声明显减弱，这表明稳健主成分分析算法可以有效的压制线性平面波地震数据中的异常值噪声。为了进一步研究最大迭代次数 Niter 与截断误差ε对去噪效果的影响，本文绘制了品质因子 Q 随最大迭代次数 Niter 和截断误差ε变化的关系曲线，如图 20 所示。

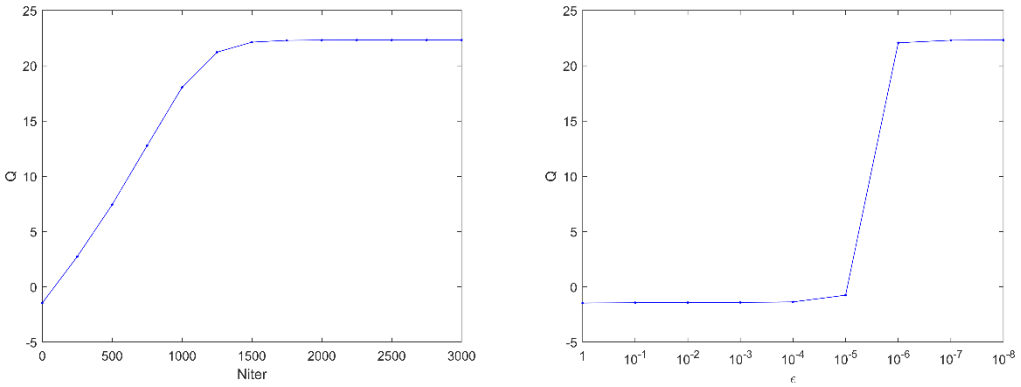


图 20 Q 值随最大迭代次数 Niter 和截断误差ε变化的关系曲线

由图 20 可知，当最大迭代次数 Niter<1500 时，品质因子 Q 随最大迭代次数 Niter 的增大明显上升，当 Niter>1500 时，品质因子 Q 的变化不再明显；当截断误差$\varepsilon<10^{-5}$时品质因子 Q 随截断误差ε的减小变化不明显，当$\varepsilon>10^{-6}$时品质因子 Q 的变化不再明显，而由$\varepsilon=10^{-5}\rightarrow\varepsilon=10^{-6}$时，品质因子 Q 显著增大。

（2）高频异常值噪声

由于上例加入的异常值噪声的主频 f=20Hz 与三维地震数据的主频相近，但实际数据中往往异常值噪声的主频高于地震数据的主频，故本文继续研究当异常值噪声的主频大于三维地震数据的主频时稳健主成分分析算法的去噪效果。

以 r=15%（单道中存在反射系数的比例）, s=1%（存在异常值道的比例）随机生成反射系数序列，Ricker 子波主频为 50Hz，二者褶积后得到异常值噪声数据（301x64x64）。选取其中 x=5 的切片，其切片图和 F-K 谱图如图 21 所示。

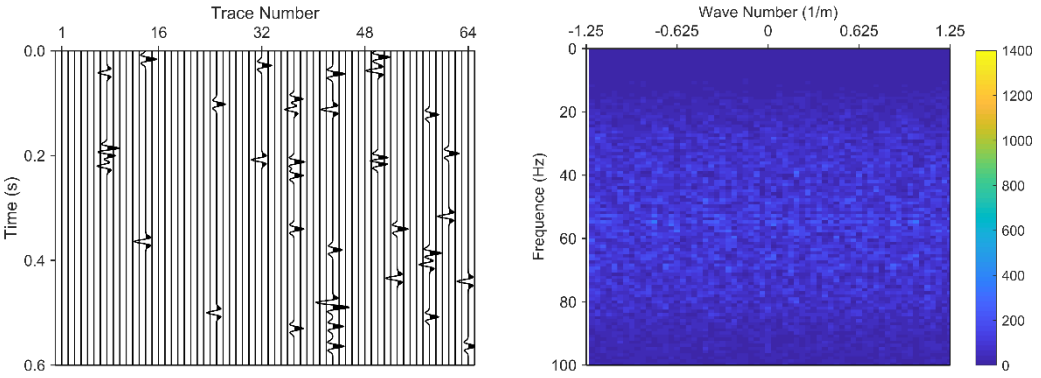


图 21 高频异常值噪声数据切片图及其 F-K 谱

将异常值噪声添加到三维地震数据中得到含异常值噪声的数据。此时由含异常值噪声的三维地震数据和不含噪声的三维地震数据计算得到的品质因子 Q=2.62。选取其中 x=5 的切片，其切片图和 F-K 谱图如图 22 所示。

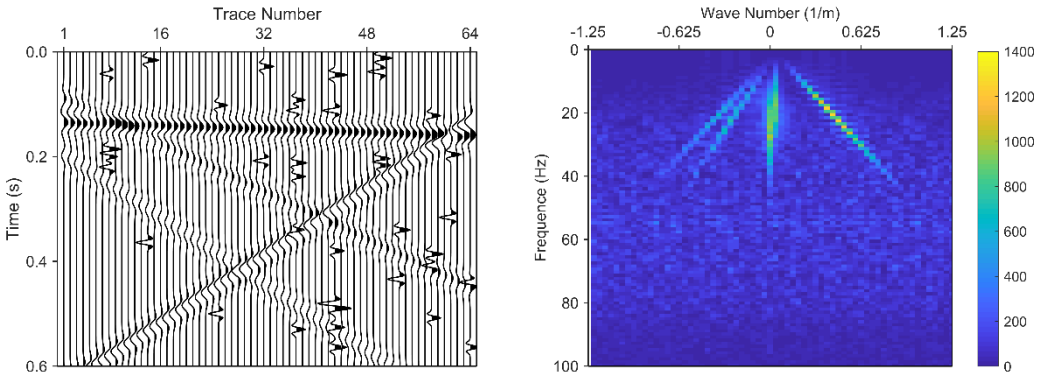


图 22 含高频异常值噪声的三维地震数据切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差ε=10^{-8}，当最大迭代次数 Niter=3000 时，品质因子为 Q=23.35。选取 x=5 的切片，去噪结果的切片图和 F-K 谱图如图 23 所示

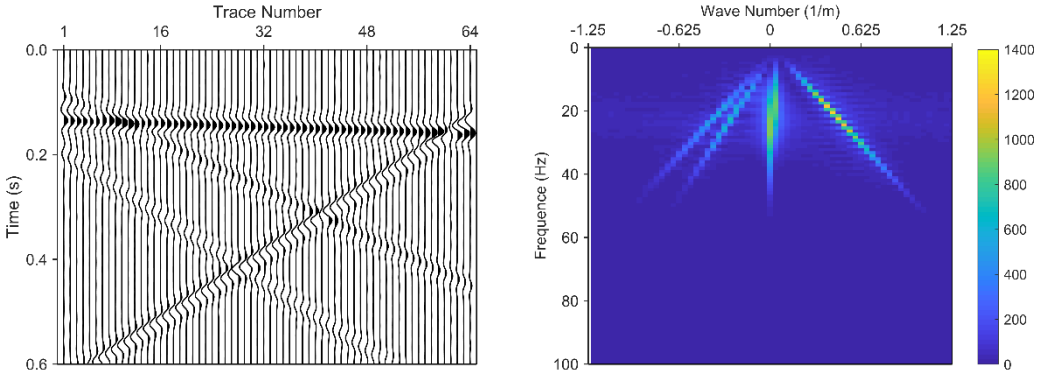


图 23 Niter=3000 时 RPCA 去噪结果的切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差ε=10^{-8}，当最大迭代次数 Niter=3000 时，选取 x=5 的切片，压制掉的异常值噪声剖面及其 F-K 谱如图 24 所示。

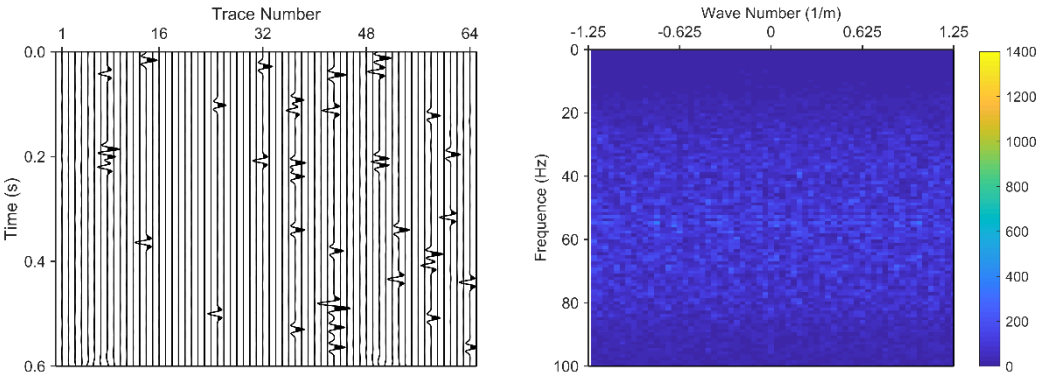


图 24 Niter=3000 时去掉的异常值噪声剖面的切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差ε=10^{-8}，当最大迭代次数 Niter=3000 时，选取 x=5 的切片，去噪结果与原始无噪数据的差剖面切片及其 F-K 谱如图 25 所示。

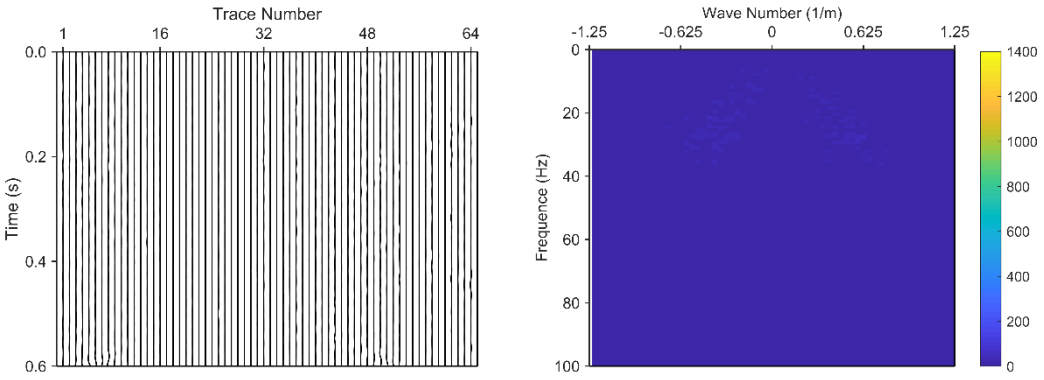


图 25 Niter=3000 时 RPCA 去噪结果的差剖面及其 F-K 谱

本节我们合成了一个含高频异常值噪声的数据体用来测试稳健主成分分析去噪的效果。图 21 显示了高频的异常值噪声，图 22 显示了合成的三维地震数据体。图 23 显示了稳健主成分分析算法对含有高频异常值噪声的三维地震数据体的去噪效果，可以看出当最大迭代次数较大时，稳健主成分分析算法对高频异常值噪声的压制效果明显。这表明稳健主成分分析算法可以有效的压制线性同相轴三维地震数据中的高频异常值噪声。图 24 显示了用 RPCA 方法压制掉的高频异常值噪声，从图上可以看出去掉的高频异常值剖面及其 F-K 谱与原始生成的高频异常值剖面及其 F-K 谱基本相同。图 25 显示了去噪后数据与原始无噪数据之间的差剖面。从差剖面上可以看出，异常值噪声基本被压制，残留的异常值噪声明显减弱，这表明稳健主成分分析算法可以有效的压制线性平面波地震数据中的高频异常值噪声。

（3）含随机噪声的数据

在实际地震勘探中，地震数据体不仅只含有异常值噪声，还普遍夹杂着随机噪声。因此，我们在纯异常值噪声压制模型的基础上继续添加随机噪声来检验 RPCA 方法的去噪效果。首先生成一个（301x64x64）三维地震数据，其中 x、y 方向的维数 nx=ny=64，时间采样点数 nt=301，采样间隔 dt=0.002s，子波主频 f=20Hz，信号和随机噪声的信噪比 SNR=2.0。选取其中 x=5 的切片，其切片图和 F-K 谱如图 26 所示。

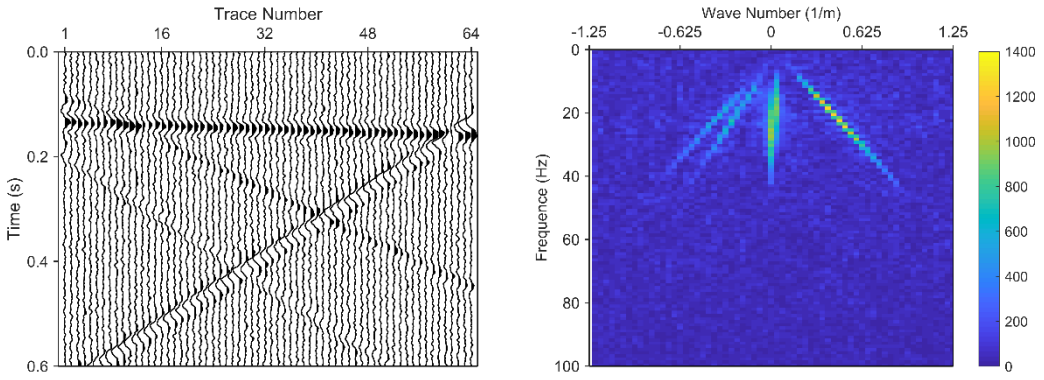


图 26 含随机噪声的三维地震数据的切片图及其 F-K 谱

将与（1）中图 6 相同的异常值噪声添加到含有随机噪声的三维地震数据中得到既含有异常值噪声又含有随机噪声的数据。此时由含噪声的三维地震数据和不含噪声的三维地震数据计算得到的品质因子 Q=-2.63。选取 x=5 的切片，其切片图和 F-K 谱如图 27 所示。

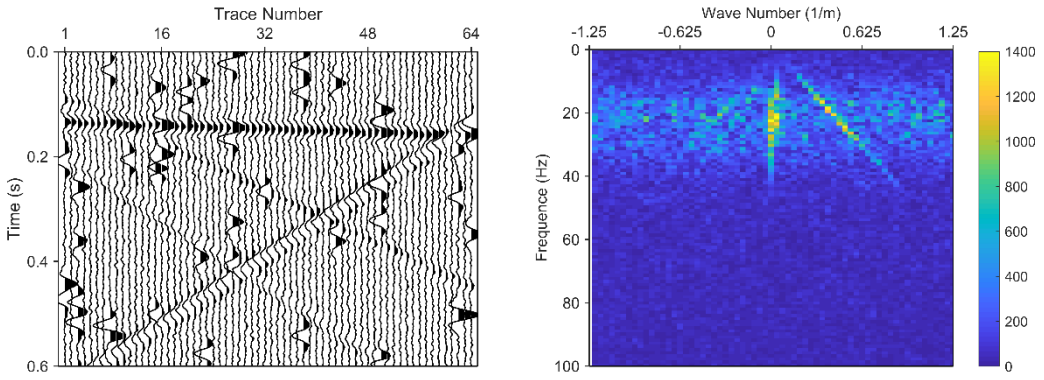


图 27 既含异常值噪声又含随机噪声的三维地震数据切片图及其 F-K 谱

首先，使用传统的 F-XY 预测滤波方法进行异常值噪声的压制，计算的到的品质因子为 Q=1.98。选取 x=5 的切片，其切片图和 F-K 谱如图 28 所示。

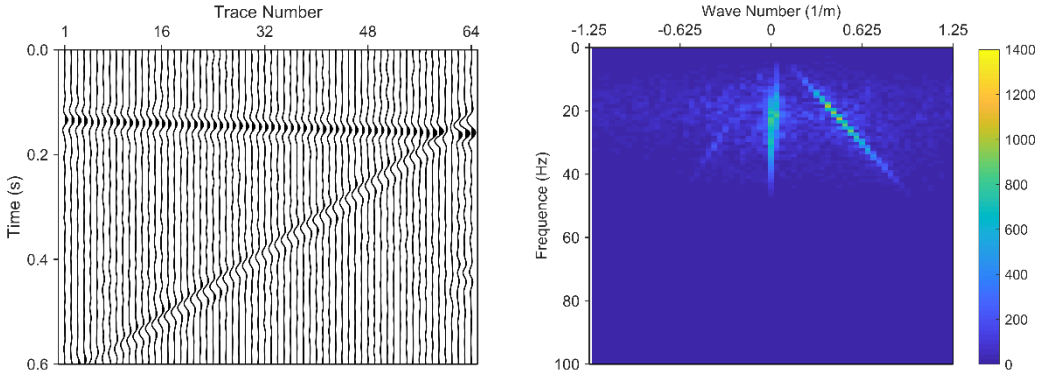


图 28 F-XY 预测滤波去噪后数据的切片图及其 F-K 谱

使用传统 F-XY 预测滤波压制掉的异常值噪声剖面。选取其中 nx=5 的切片，其切片图和 F-K 谱图如图 29 所示：

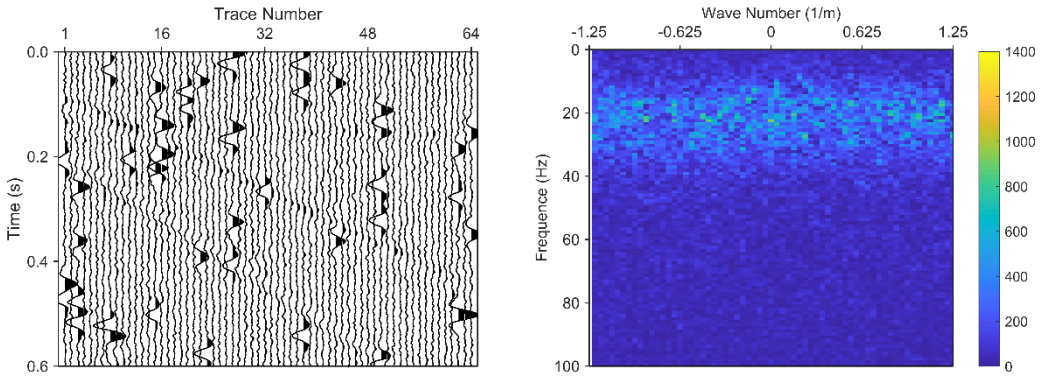


图 29 F-XY 预测滤波压制掉的异常值噪声剖面切片图及其 F-K 谱

F-XY 预测滤波结果与原始无噪声数据的差剖面。选取其中 x=5 的切片，其切片图和 F-K 谱图如图 30 所示。

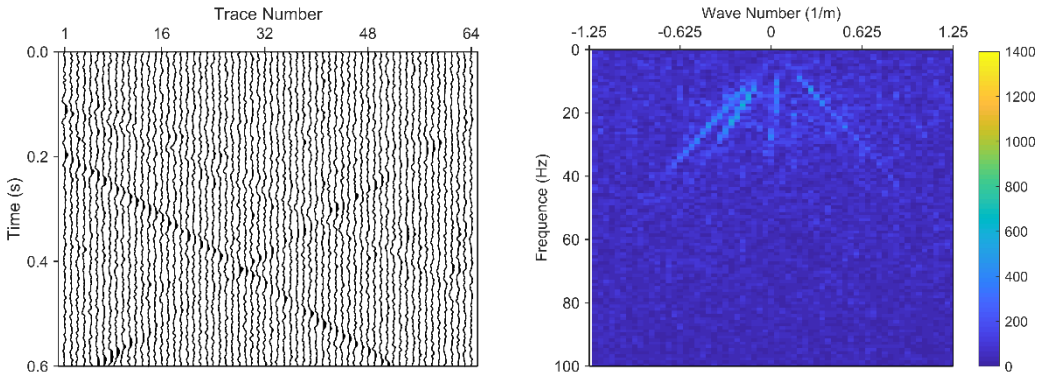


图 30 F-XY 预测滤波去噪结果的差剖面及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差$\varepsilon=10^{-8}$，当最大迭代次数 Niter=500 时，品质因子为 Q=2.99。选取 x=5 的切片，去噪结果的切片图和 F-K 谱图如图 31 所示。保持其他参数不变，当最大迭代次数 Niter=1000 和 Niter=1500 时的去噪结果切片及其 F-K 谱分别如图 32 和 33 所示，对应的 Q 值分别为 5.49 和 6.11。

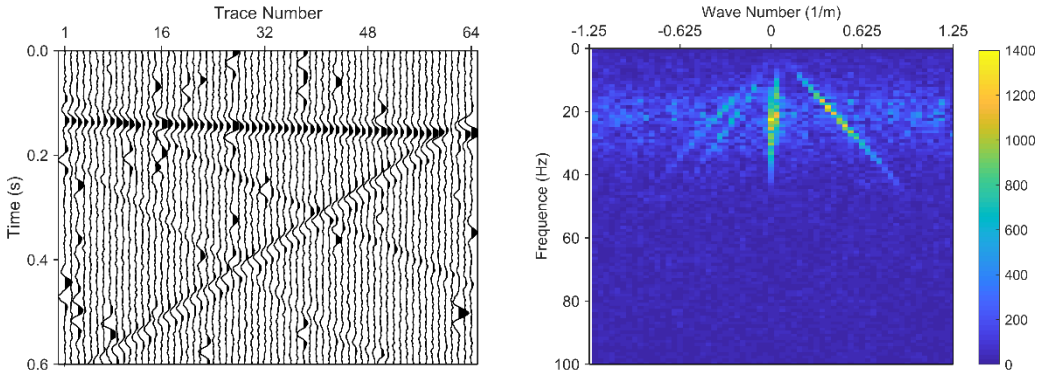


图 31 Niter=500 时 RPCA 去噪结果的切片图及其 F-K 谱

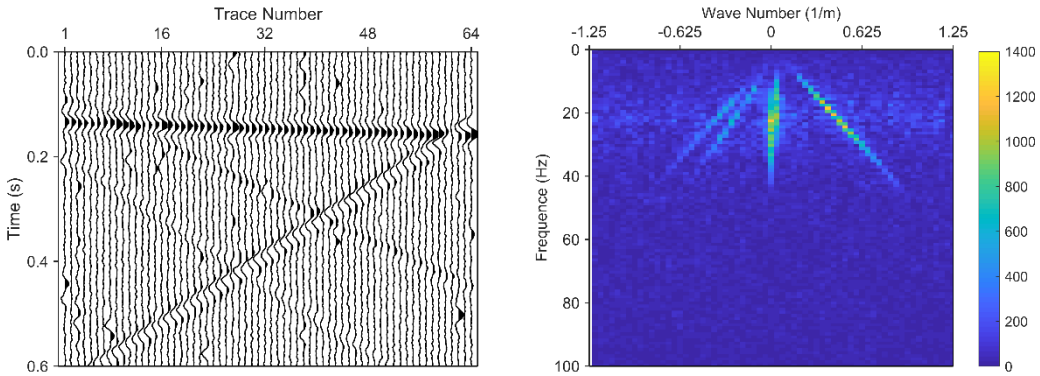


图 32 Niter=1000 时 RPCA 去噪结果的切片图及其 F-K 谱

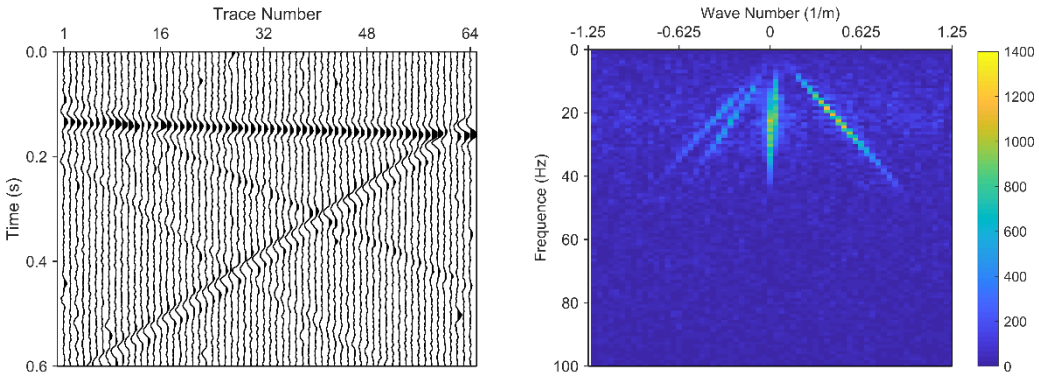


图 33 Niter=1500 时 RPCA 去噪结果的切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差$\varepsilon=10^{-8}$，当最大迭代次数 Niter=500 时，选取 x=5 的切片，压制掉的异常值噪声剖面切片图及其 F-K 谱如图 34 所示。保持其它参数不变，当最大迭代次数 Niter=1000 和 1500 时压制掉的异常值噪声剖面切片图及其 F-K 谱如图 35 和图 36 所示。

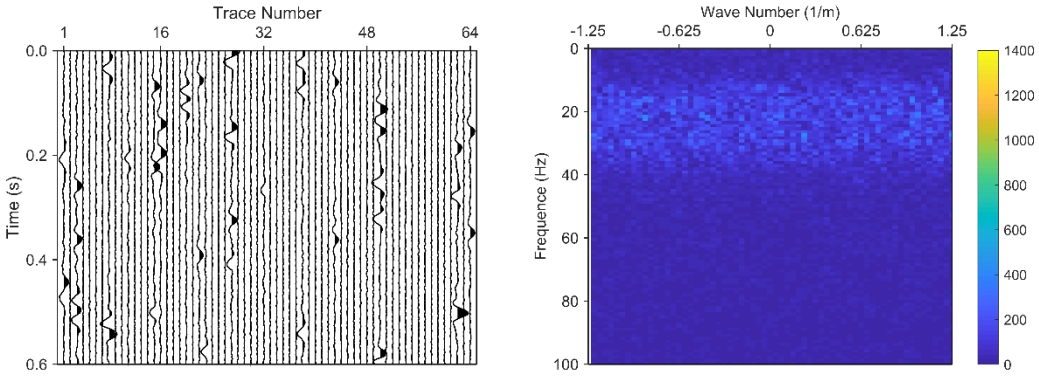


图 34 Niter=500 时压制掉的异常值噪声剖面切片图及其 F-K 谱图

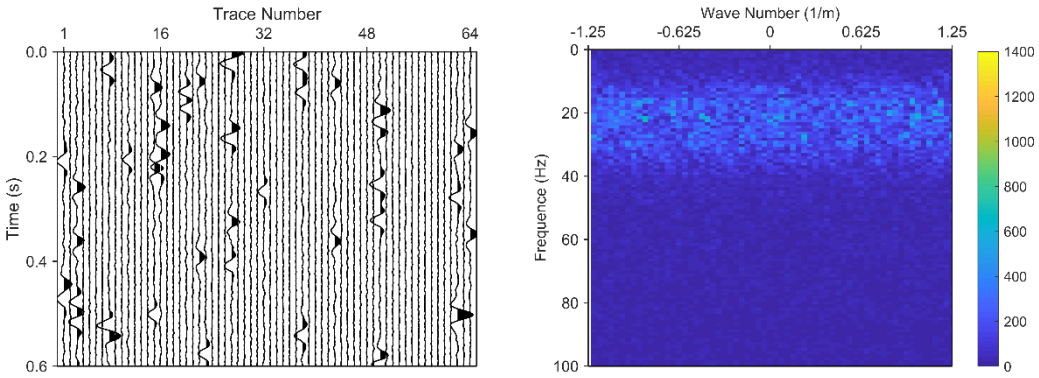


图 35 Niter=1000 时压制掉的异常值噪声剖面切片图及其 F-K 谱

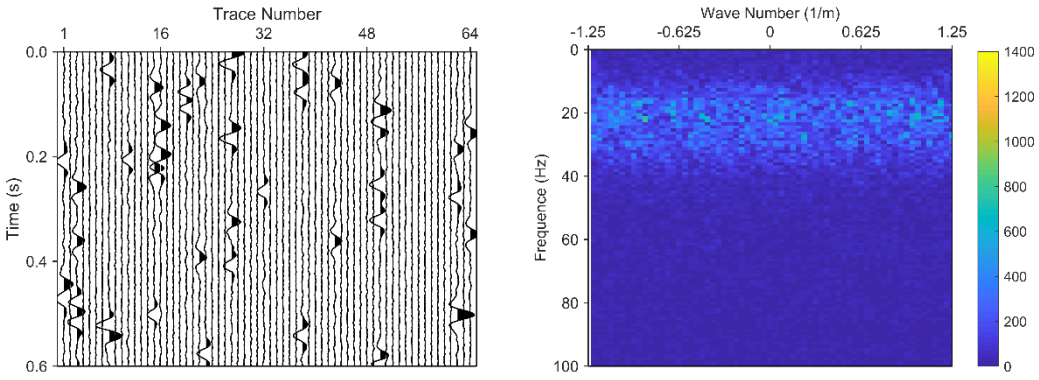


图 36 Niter=1500 时压制掉的异常值噪声剖面切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差$\varepsilon=10^{-8}$，当最大迭代次数 Niter=500 时，选取 x=5 的切片，去噪结果与原始无噪数据的差剖面切片及其 F-K 谱如图 37 所示。保持其它参数不变，当最大迭代次数 Niter=1000 和 1500 时去噪结果与原始无噪数据的差剖面切片及其 F-K 谱如图 38 和 39 所示。

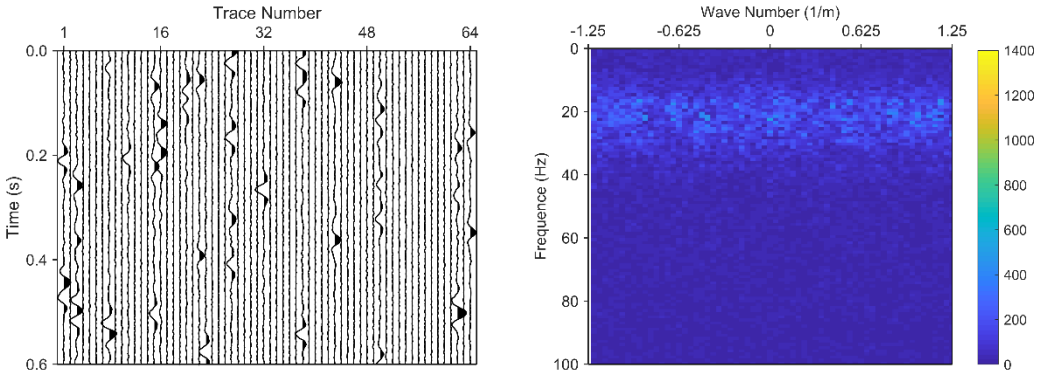


图 37 Niter=500 时 RPCA 去噪结果的差剖面及其 F-K 谱

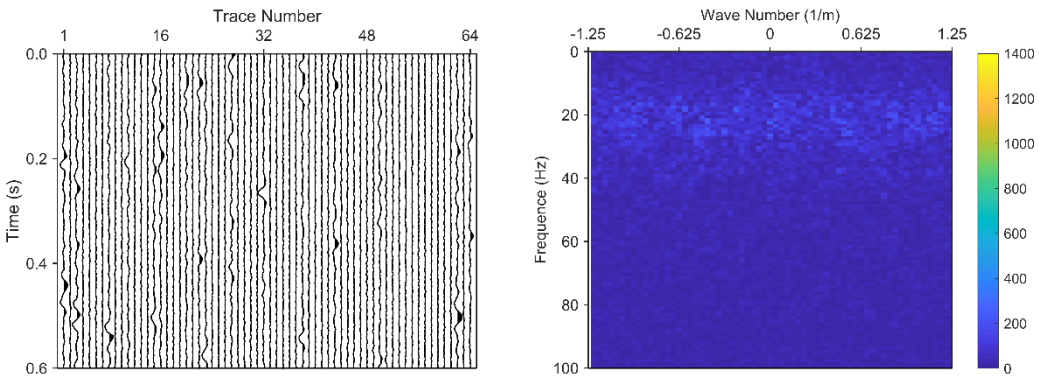


图 38 Niter=1000 时 RPCA 去噪结果的差剖面及其 F-K 谱

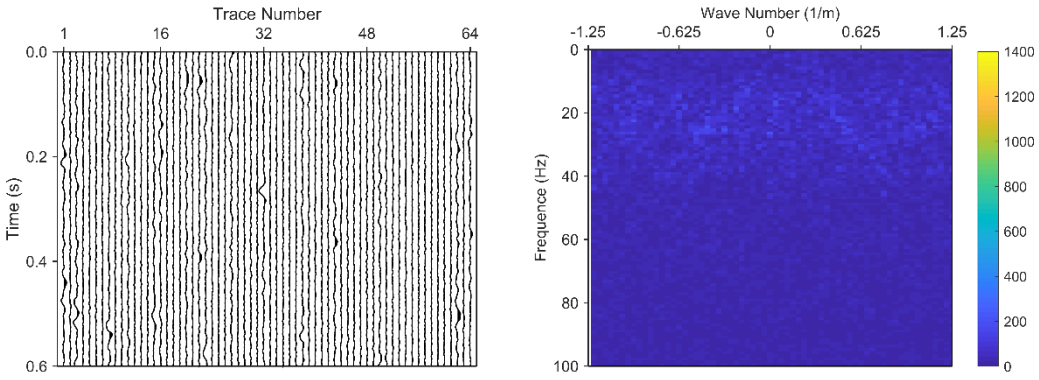


图 39 Niter=1500 时 RPCA 去噪结果的差剖面及其 F-K 谱

本节合成了一个既含有异常值噪声又含有高斯型分布的随机噪声的数据体来检测稳健主成分分析去噪的效果。图 26 和图 27 显示了合成的三维地震数据。图 28-图 30 显示了 F-XY 预测滤波算法对既含有异常值噪声又含有随机噪声的三维地震数据的去噪效果，结果表明该算法虽然可以去除异常值噪声，但同时也很大程度上伤害了有效信号。图 31-图 33 显示了稳健主成分分析算法对既含有异常值噪声又含有随机噪声的三维地震数据的去噪效果。其中，可以看出随着最大迭代次数 Niter 的增大，去噪效果越来越明显。当 Niter=0、500、1000、1500 时对应的品质因子 Q 分别为-2.63、2.99、5.49、6.11。图 34-图 36 显示了压制掉的异常值噪声，可以看出随着最大迭代次数 Niter 的增大，去掉的异常值剖面与生成的异常值剖面越来越接近。图 37-图 39 显示了去噪结果与原始真实数据之间的差剖面，从差剖面上可以看出，随着最大迭代次数 Niter 的增大，异常值噪声逐渐被压制，残留的异常值噪声明显减弱，这表明稳健主成分分析算法可以有效的压制线性同相轴三维地震数据中的异常值噪声和随机噪声。由于此模型更加符合实际数据，故推断稳健主成分分析算法可以有效压制实际数据中的异常值噪声和随机噪声。为了进一步研究最大迭代次数 Niter 与截断误差ε对去噪效果的影响，本文绘制了品质因子 Q 随最大迭代次数 Niter 和截断误差ε变化的关系曲线，如图 40 所示。

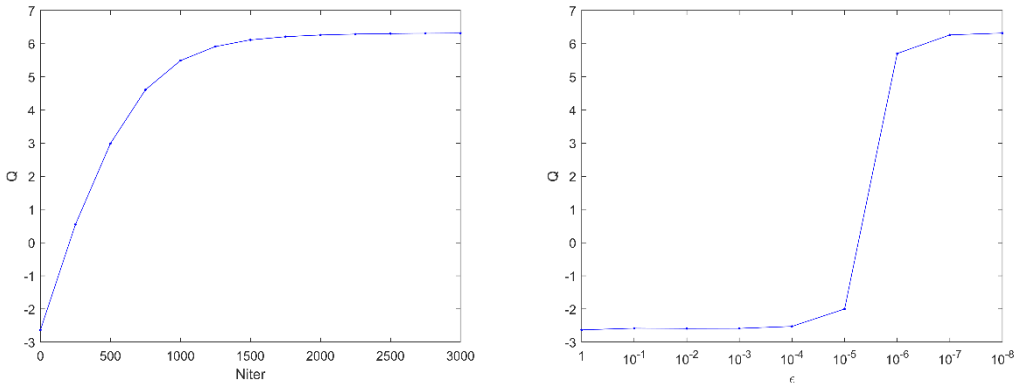


图 40 Q 值随最大迭代次数 Niter 和截断误差ε变化的关系曲线

由图 40 可知，当最大迭代次数 Niter<1500 时，品质因子 Q 随最大迭代次数 Niter 的增大明显上升，当 Niter>1500 时，品质因子 Q 的变化不再明显；当截断误差$\varepsilon<10^{-4}$时品质因子 Q 随截断误差ε的减小变化不明显，当$\varepsilon>10^{-7}$时品质因子 Q 的变化不明显，而$\varepsilon=10^{-5}\rightarrow\varepsilon=10^{-6}$时，Q 值显著增大。

3.1.2 弯曲同相轴实验

本节主要将稳健主成分分析算法应用于弯曲同相轴的三维地震数据异常值噪声的压制实验。首先合成一个大小（501x100x100）的三维地震数据，其中 x、y 方向的维数 nx=ny=100，时间采样点数 nt=501，采样间隔 dt=0.002s，子波主频 f=20Hz。选取 x=5 的切片，其切片图和 F-K 谱如图 41 所示。

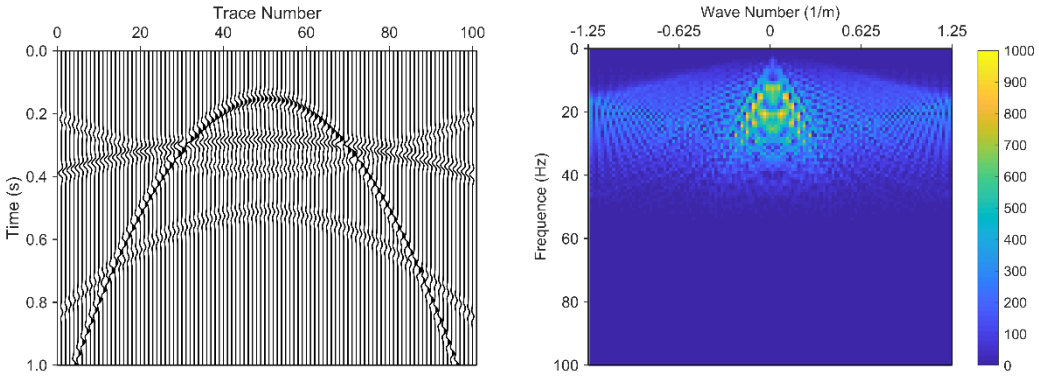


图 41 三维地震数据的切片图及其 F-K 谱

以 r=15%（单道中存在反射系数的比例），s=1%（存在异常值道的比例）随机生成反射系数序列，Ricker 子波主频为 20Hz，二者褶积后得到异常值噪声数据（501x100x100）。选取 x=5 的切片，其切片图和 F-K 谱如图 42 所示。

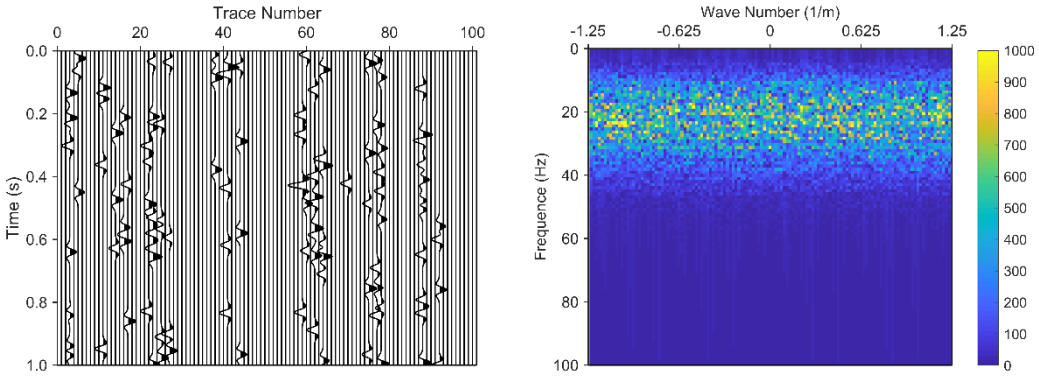


图 42 异常值噪声数据切片图及其 F-K 谱

将异常值噪声添加到三维地震数据中得到含异常值噪声的数据。此时由含异常值噪声的三维地震数据和不含噪声的三维地震数据计算得到的品质因子 Q=-3.34。选取其中 x=5 的切片，其波形图和 F-K 谱图如图 43 所示。

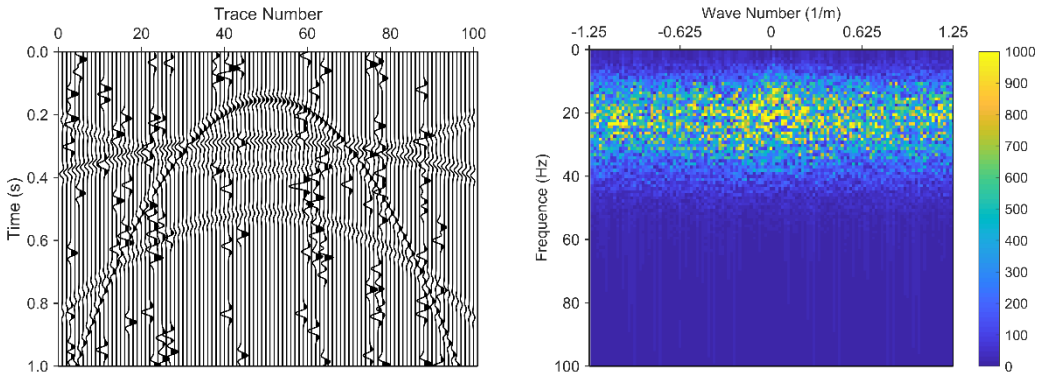


图 43 含异常值噪声的三维地震数据切片图及其 F-K 谱

首先，使用传统 F-XY 预测滤波方法进行异常值噪声的压制，计算的到的品质因子为 Q=1.33。选取其中 x=5 的切片，去噪结果的切片图和 F-K 谱图如图 44 所示。

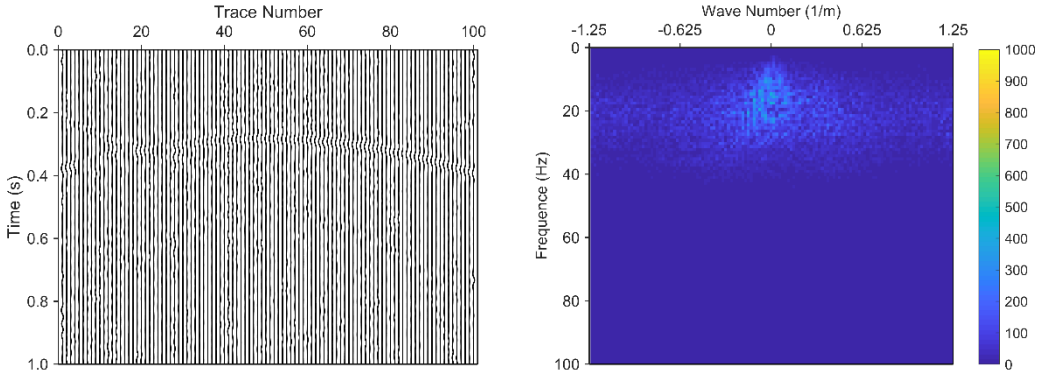


图 44 F-XY 预测滤波去噪后数据的切片图及其 F-K 谱

使用传统 F-XY 预测滤波压制掉的异常值噪声剖面。选取其中 nx=5 的切片，其切片图和 F-K 谱图如图 45 所示：

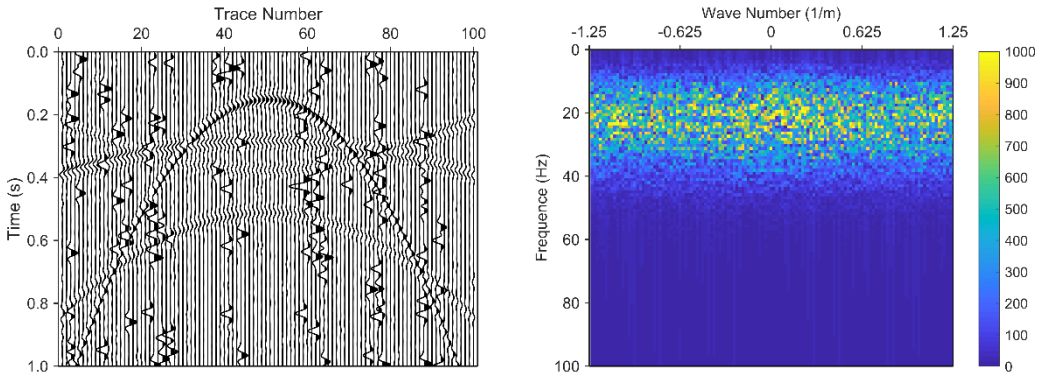


图 45 F-XY 预测滤波压制掉的异常值噪声剖面切片图及其 F-K 谱

F-XY 预测滤波结果与原始无噪声数据的差剖面。选取其中 x=5 的切片，其切片图和 F-K 谱图如图 46 所示。

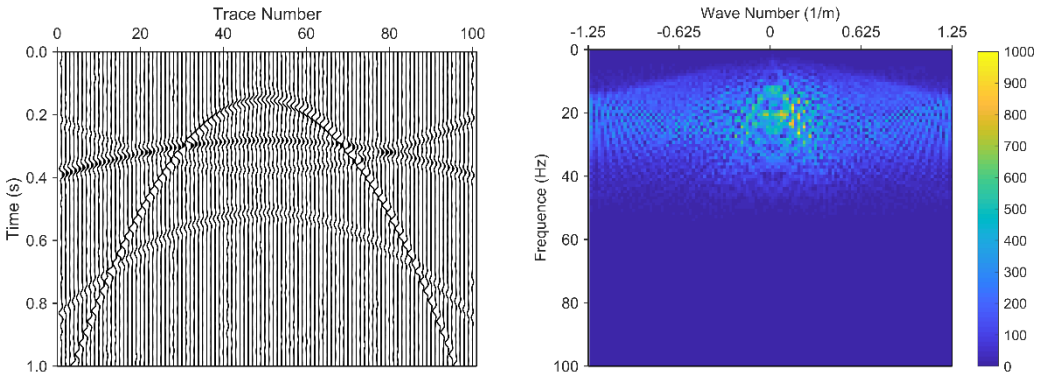


图 46 F-XY 预测滤波去噪结果的差剖面及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差$\varepsilon=10^{-8}$，当最大迭代次数 Niter=500 时，品质因子为 Q=2.28。选取 x=5 的切片，去噪结果的切片图和 F-K 谱图如图 47 所示。保持其他参数不变，当最大迭代次数 Niter=1000 和 Niter=1500 时的去噪结果切片及其 F-K 谱分别如图 48 和 49 所示，对应的 Q 值分别为 9.91 和 21.03。

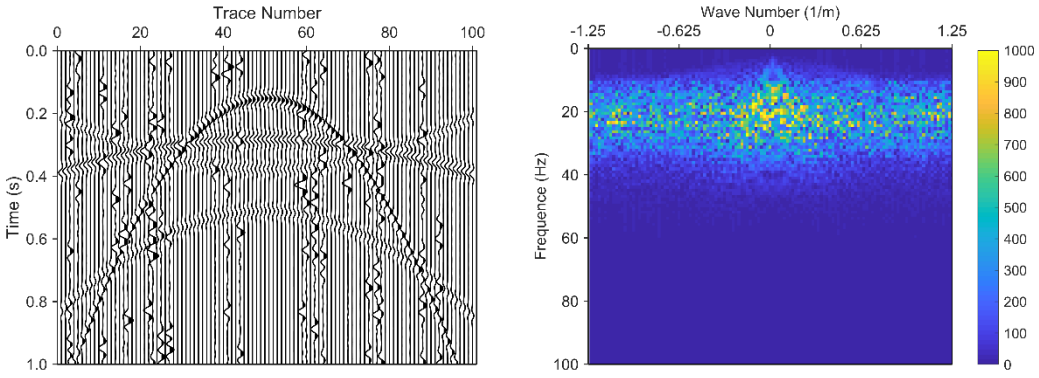


图 47 Niter=500 时 RPCA 去噪结果的切片图及其 F-K 谱

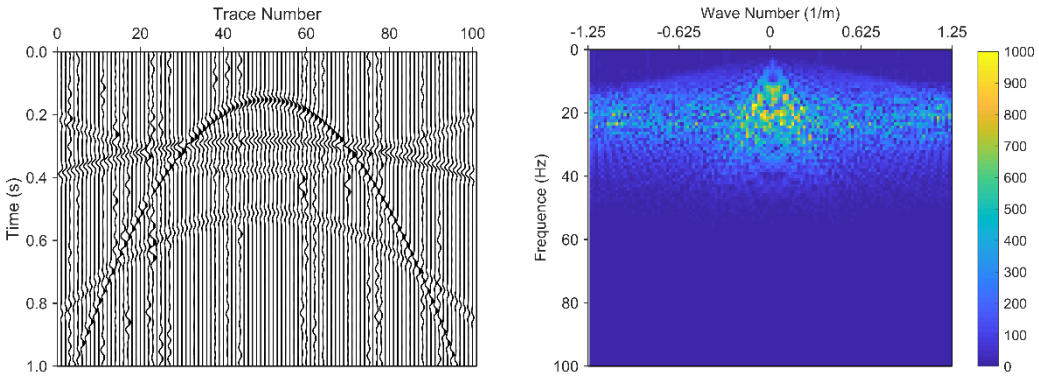


图 48 Niter=1000 时 RPCA 去噪结果的切片图及其 F-K 谱

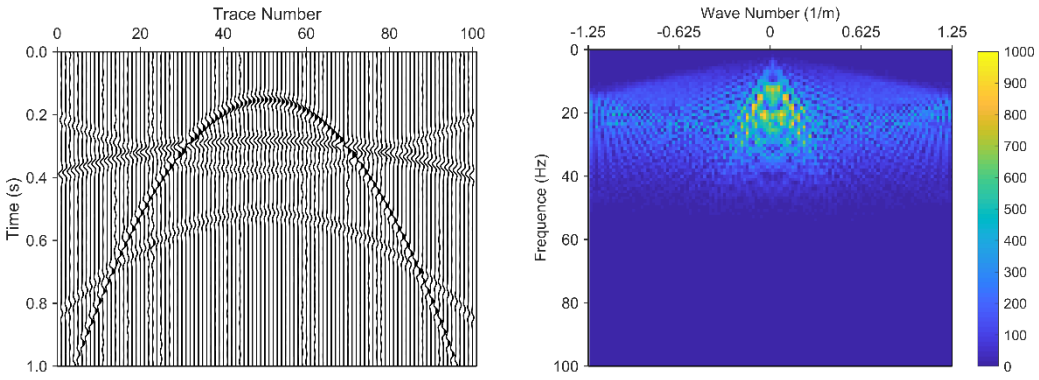


图 49 Niter=1500 时 RPCA 去噪结果的切片图及其 F-K 谱

运用 RPCA 方法进行去噪处理，设置截断误差$\varepsilon=10^{-8}$，当最大迭代次数 Niter=500 时，选取 x=5 的切片，压制掉的异常值噪声剖面切片图及其 F-K 谱如图 50 所示。保持其它参数不变，当最大迭代次数 Niter=1000 和 1500 时压制掉的异常值噪声剖面切片图及其 F-K 谱如图 51 和图 52 所示。

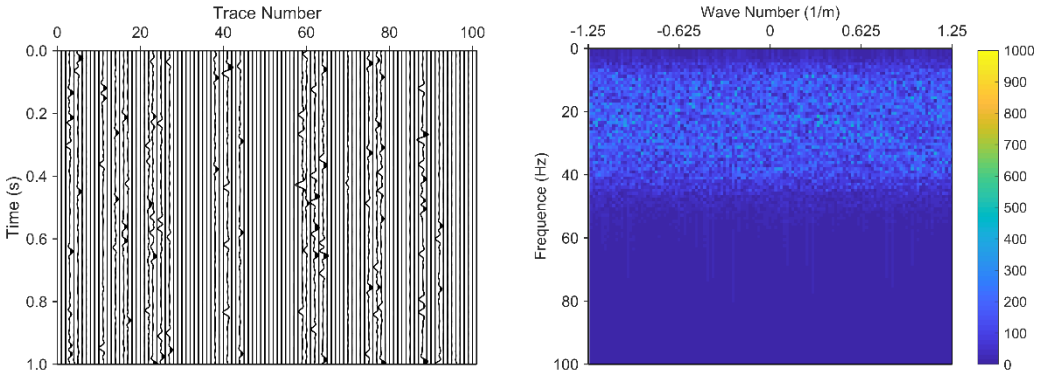


图 50 Niter=500 时压制掉的异常值噪声剖面切片图及其 F-K 谱

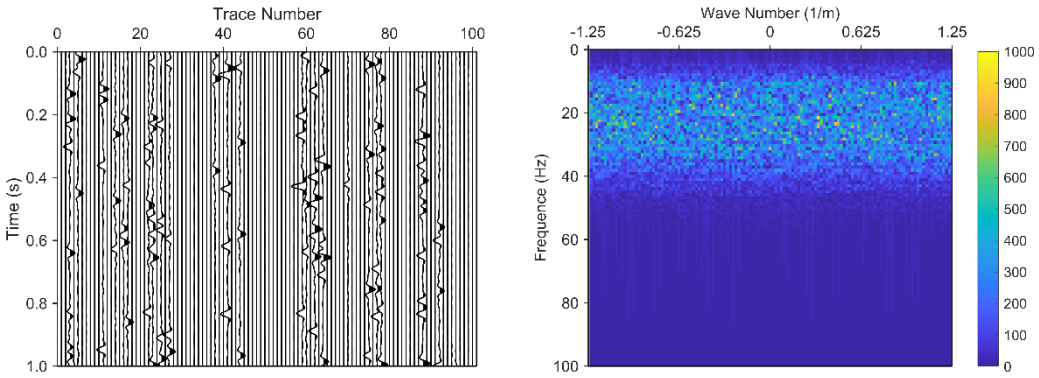


图 51 Niter=1000 时压制掉的异常值噪声剖面切片图及其 F-K 谱图

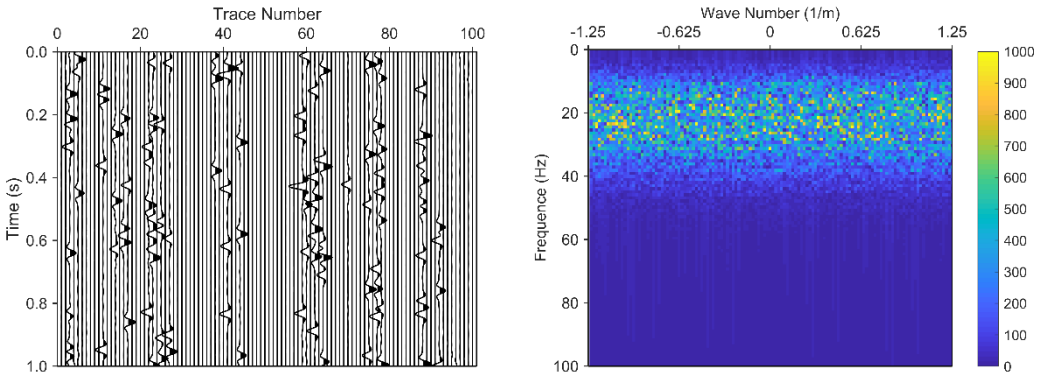


图 52 Niter=1500 时压制掉的异常值噪声剖面切片图及其 F-K 谱图

运用 RPCA 方法进行去噪处理，设置截断误差$\varepsilon=10^{-8}$，当最大迭代次数 Niter=500 时，选取 x=5 的切片，去噪结果与原始无噪数据的差剖面切片及其 F-K 谱如图 53 所示。保持其它参数不变，当最大迭代次数 Niter=1000 和 1500 时去噪结果与原始无噪数据的差剖面切片及其 F-K 谱如图 54 和 55 所示。

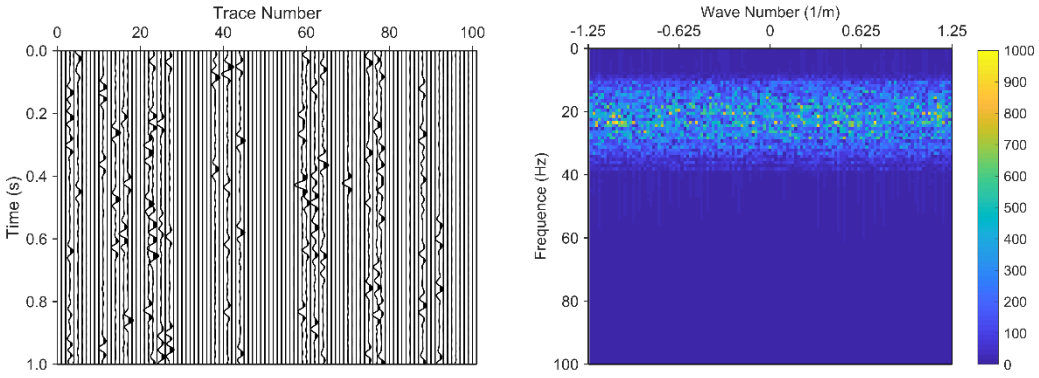


图 53 Niter=500 时 RPCA 去噪结果的差剖面及其 F-K 谱

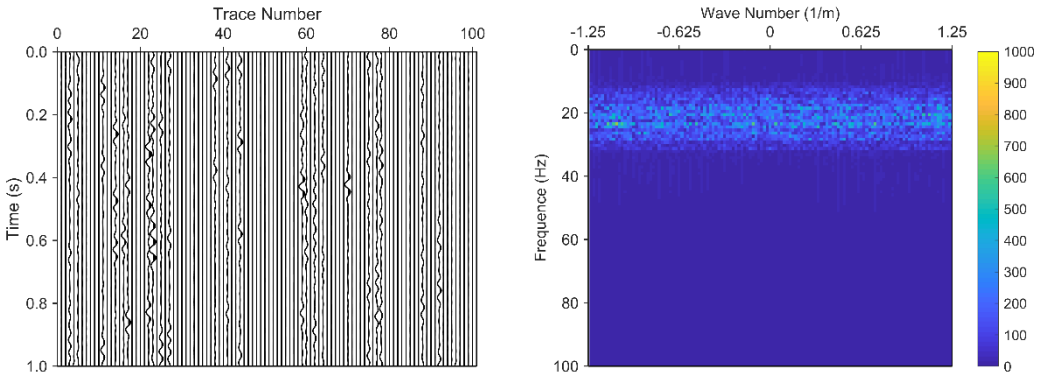


图 54 Niter=1000 时 RPCA 去噪结果的差剖面及其 F-K 谱

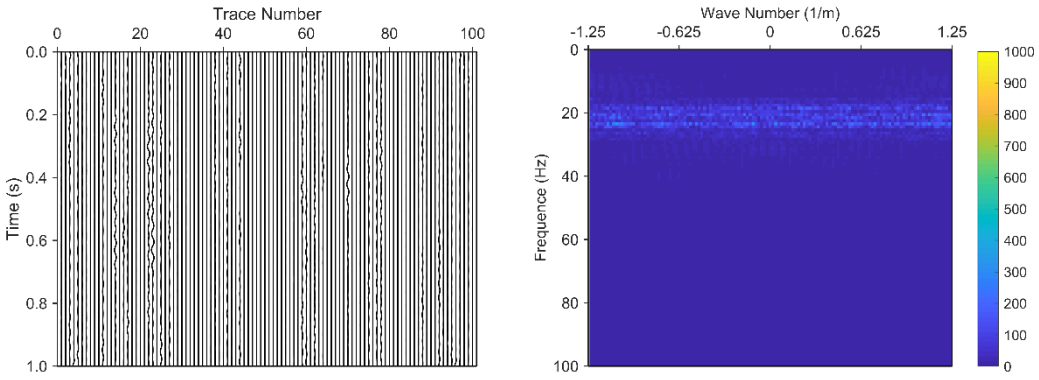


图 55 Niter=1500 时 RPCA 去噪结果的差剖面及其 F-K 谱

本小节合成了一个含有弯曲轴模型和异常值噪声的三维地震数据体来检测稳健主成分分析方法的去噪效果。图 41-图 43 显示了合成的弯曲轴三维地震数据。图 44-图 46 显示了 F-XY 预测滤波算法的去噪结果，实验表明异常值得到了压制，但同时严重伤害了有效信号的能量，差剖面上有效信号残留严重，所以该方法不能直接用于弯曲轴地震数据的异常值噪声压制。图 47-图 49 显示了稳健主成分分析算法的去噪效果。通过实验可以发现随着最大迭代次数 Niter 的增大，去噪效果逐渐变好。当 Niter=0、500、1000、1500 时对应的品质因子 Q 分别为-3.34、2.28、9.92、21.03。图 50-图 52 显示了被压制掉的异常值噪声，从上可以看出随着最大迭代次数 Niter 的增大，去掉的异常值剖面与原始异常值剖面越来越接近。图 56-图 55 显示了去噪后数据与真实数据之间的差异。从差剖面可以看出，随着最大迭代次数 Niter 的增大，异常值噪声逐渐被压制，残留的异常值噪声明显减弱，这表明稳健主成分分析算法同样适用于含异常值的弯曲轴模型数据的噪声压制。为了进一步研究最大迭代次数 Niter 与截断误差ε对去噪效果的影响，此处也绘制了品质因子 Q 随最大迭代次数 Niter 和截断误差ε变化的关系曲线，如图 56 所示。

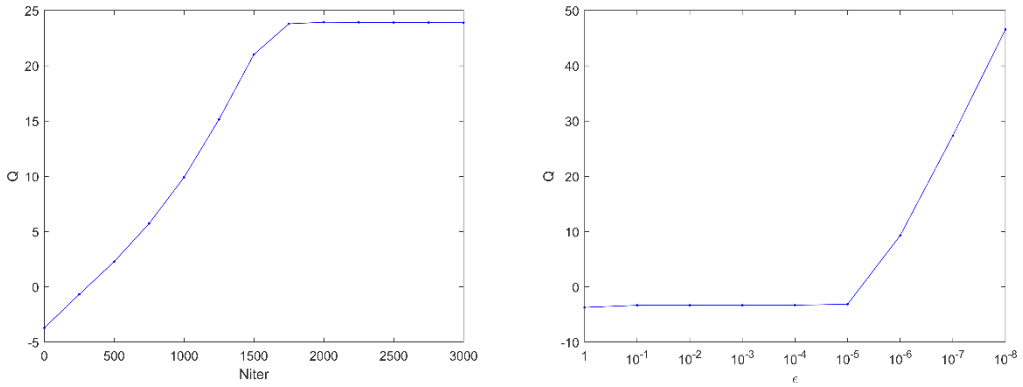


图 56 Q 值随最大迭代次数 Niter 和截断误差ε变化的关系曲线

由图 56 知，当最大迭代次数 Niter<1750 时，品质因子 Q 随最大迭代次数 Niter 的增大明显上升，当 Niter>1750 时，品质因子 Q 的变化不再明显；当截断误差$\varepsilon<10^{-4}$时品质因子 Q 随截断误差ε的减小而变化不明显，但当$\varepsilon=10^{-5}\rightarrow\varepsilon=10^{-8}$时，Q 值显著增大。

3.2 实际数据处理

选取某煤田的叠前 2D CDP 道集进行异常值噪声压制实验。该数据包含 30 个 CDP 道集，每道有 750 个时间采样点，时间采样间隔 dt=0.002s。在 0.05s-0.4s 区间内含有较强的异常值噪声，整块数据如图 57 所示。采用 RPCA 算法进行异常值噪声压制，去噪结果如图 58 所示，去噪结果与原始数据的差剖面如图 59 所示。从差剖面的黄色矩形框中可以看出异常值噪声都得到一定的压制。为了进一步显示去噪效果，抽取前 5 个 CDP 道集进行放大显示。图 60 为 CDP1-CDP5 的原始道集放大显示。图 61 为去噪结果显示，图 62 为压制掉的噪声剖面。从图 62 上可以看出，异常值噪声和部分随机噪声得到了有效压制，但是在 0.3s 附近的水平轴方向有微弱的有效信号残留，下一步还需要对本文方法所涉及的关键参数取值问题进行进一步的研究和调整，使其去噪和保幅效果更好。

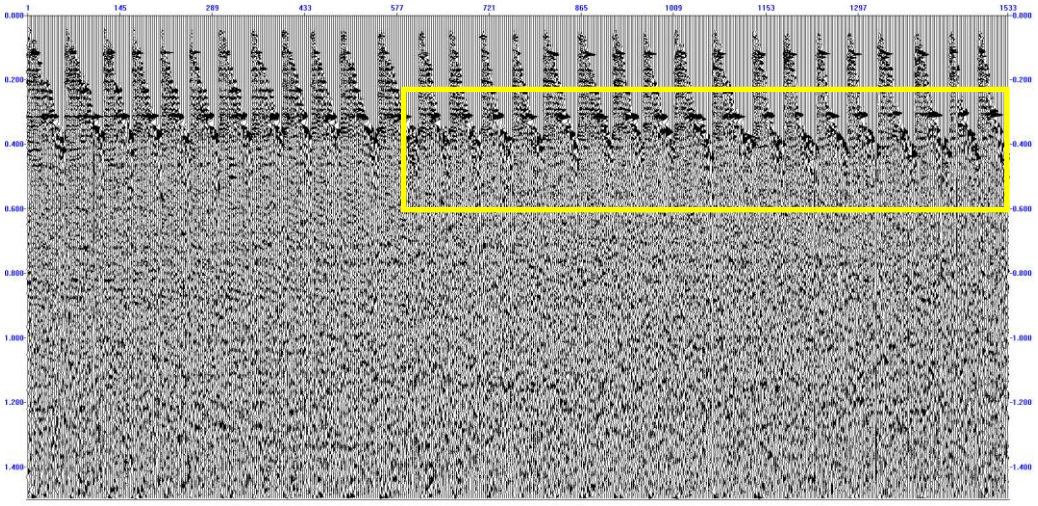


图 57 实际数据的 CDP 道集

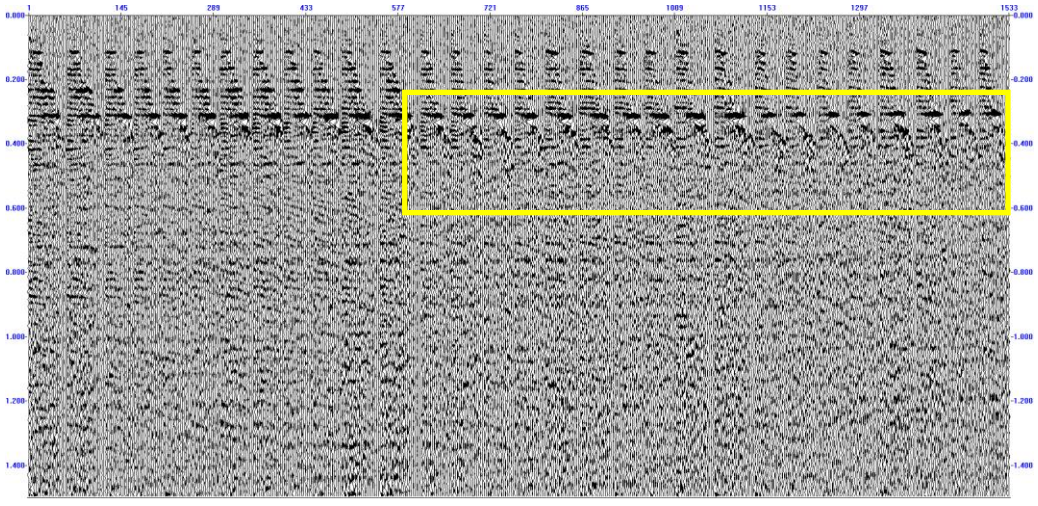


图 58 RPCA 方法去噪结果

将去噪后的数据与原始数据进行相减，得到去除的异常值剖面，如下图所示。

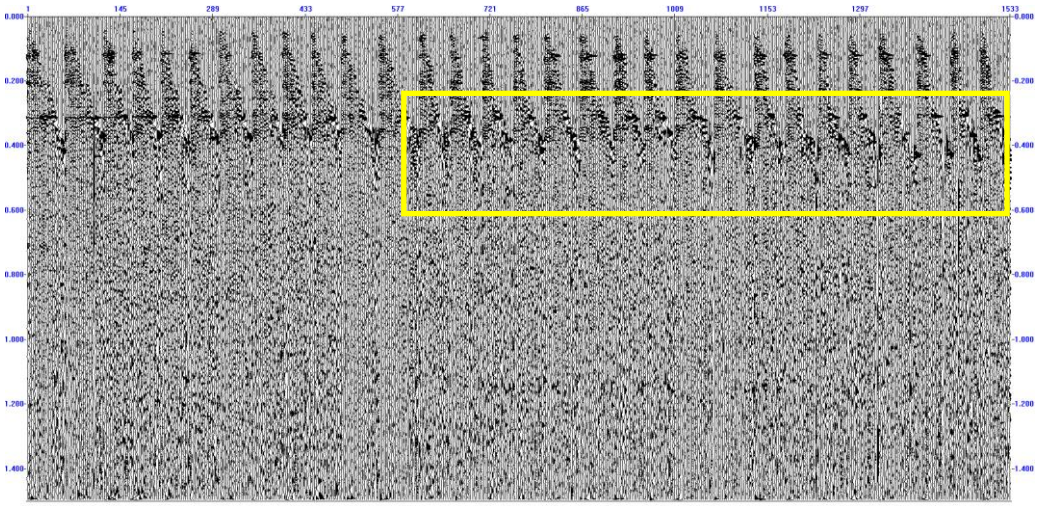


图 59 RPCA 方法去除的噪声

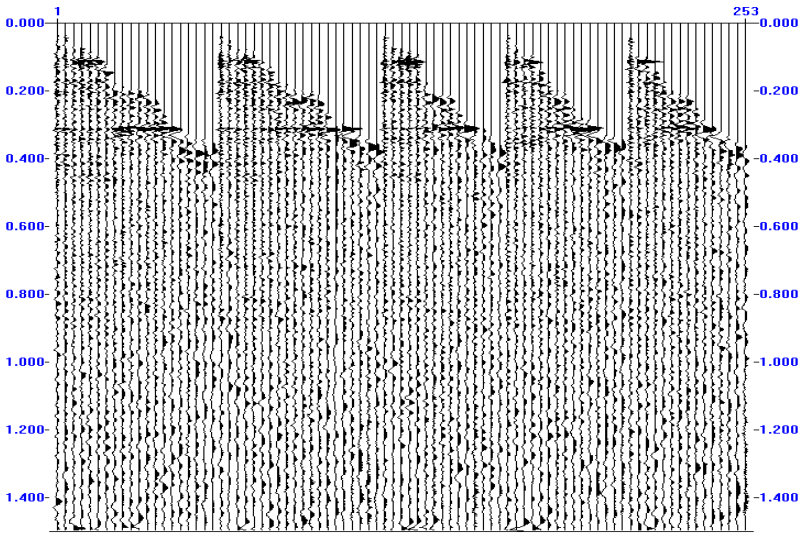


图 60 实际数据的放大显示

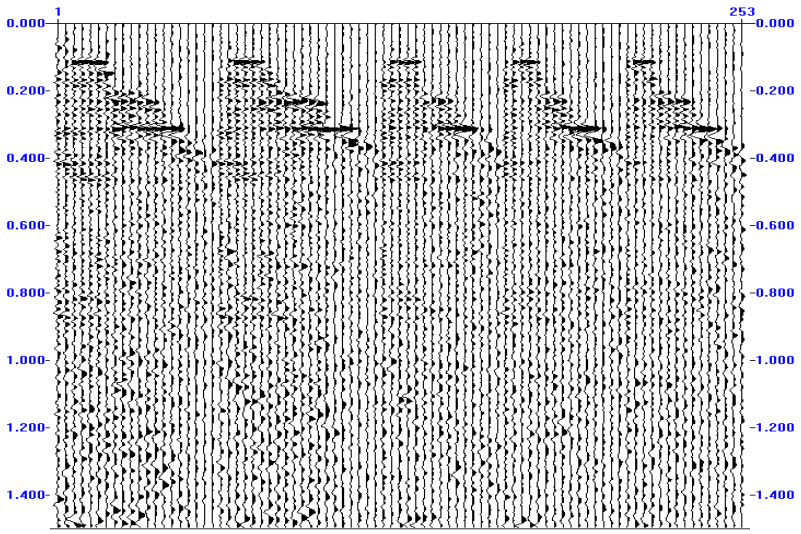


图 61 RPCA 去噪结果的放大显示

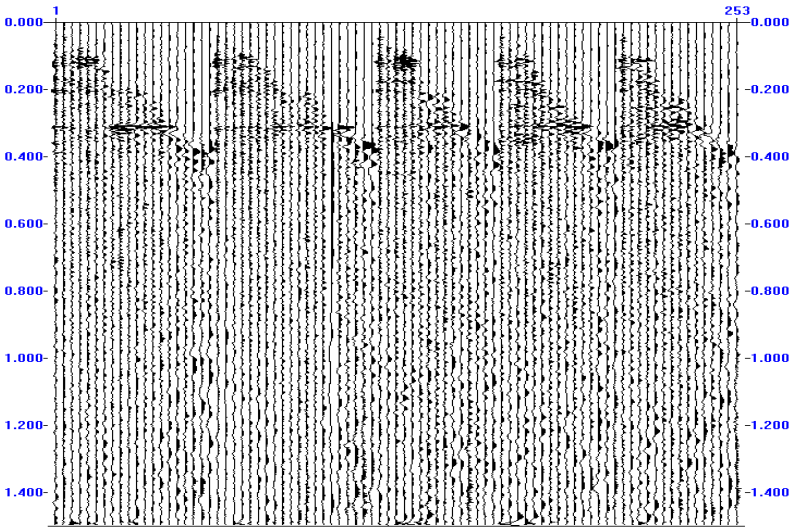


图 62 RPCA 去除的噪声放大剖面

结　论

理想的无噪声数据具有明显的低秩特征，稀疏噪声会增加数据矩阵的秩，噪声的去除可以近似为矩阵降秩，因此含噪声的数据通过稳健主成分分析来估计恢复无噪声数据是可行的。

使用稳健主成分分析算法对模型数据和实际数据进行测试时，线性同相轴、弯曲同相轴和实际数据中的异常值噪声都得到了压制，取得了良好效果。此外，相比于传统的 F-XY 预测滤波法，稳健主成分分析算法可以在有效压制异常值噪声和随机噪声的同时还能很好的保留有效信号。该算法仍存在如下有待研究和改进的地方：

（1）该算法的计算时间相对较长。为了达到更理想的效果，需要不断测试增大最大迭代次数，而当最大迭代次数较大时，稳健主成分分析算法的计算时间比传统的 F-XY 预测滤波法的计算时间长。

（2）该算法对随机噪声的压制效果不是很理想，由于目标函数中假设噪声数据是稀疏的，所以稀疏的异常值噪声可以得到有效的压制，而随机噪声的压制效果不是很理想，需要继续改进方法的数学模型。

（3）RPCA 算法中调优参数μ的计算公式有待改进，该公式不适用于所有数据体，本次模型数据μ的取值按照公式计算，实际数据μ的取值为人工调试。

综上，稳健主成分分析算法可以有效压制地震数据中的异常值噪声。此外该方法还可以同时用于缺失数据重建和去噪等工作，这是其他去噪方法所不具备的优势之一，而这些应用也是当前地震数据处理领域的热门话题。

致　谢

在大学的四年，本科毕设是我第一次接触与专业相关的研究。由于今年疫情的原因，本次毕业设计大部分在家里完成，由于在家学习的特殊性，高老师多次电话联系监督我们的学业。此外，高老师也多次开展视频会议为我进行知道答疑，我对高建军老师的知道表示深深的感谢！同时也对苑益军老师的指导表示感谢，感谢苑老师为我的毕业设计提供了实验用的实际数据！

在完成毕业论文期间，我多次在网络上查询文献、资料。前辈的研究结晶给了我很大的启发，我从他们的观点中吸收了很多有用的知识，并在其基础之上进行变动，加入我自己的想法。这里还要感谢学校老师对我们本科生毕业论文要求的指导和答辩时各位老师对我提出的批评和建议！

此外，衷心感谢大学四年以来为我传道、授业、解惑的老师和同学们，感谢你们的辛勤付出和热情帮助！感谢家人对我学业的不断支持！

最后，向在百忙之中对本论文进行审查的各位老师进行诚挚的感谢，恳请老师们的批评和指正！

参考文献

[1] Sacchi.M.D. FX Singular Spectrum Analysis segam[C], CSPG CSEG CWLS Convention, 2009, 392-395.

[2] Tao, M. , and X. Yuan, 2011, Recovering low-rank and sparse components of matrices from incomplete and noisy observations: SIAM Journal on Optimization, 21, no. 1, 57–81.

[3] Chen K., and M. D. Sacchi, 2015, Robust reduced-rank filtering for erratic seismic noise attenuation: Geophysics, 80, no. 1, V1–V11.

[4] Recht, B. M. Fazel, and P. Parrilo, 2010, Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization: SIAM Review, 52, no. 3, 471–501

[5] Candès, E. J., X. Li, Y. Ma, and J. Wright, 2011, Robust principal component analysis?: Journal of the ACM (Association for Computing Machinery), 58, no. 3, 28-30.

[6] Trickett, S. R., 2003, F-xy eigenimage noise suppression: Geophysics, 68, 751–759.

[7] Huang.W, R.Wang, Y.Chen,etal. Damped multichannel singular spectrum analysis for 3D random noise attenuation[J], Computers & Geosciences 95, 2016, 59-66.

[8] Chen.Y, W.Huang, D.Zhang,etal. An open-source Matlab code package for improved rank-reduction 3D seismic data denoising and reconstruction[J] , GEOPHYSICS, 2016, 81.

[9] L.Canales. Random noise reduction: 54th Annual International Meeting[C] , SEG, Expanded Abstracts, 1984, 525–527.

[10] Claerbout, J., and F. Muir, Robust modeling with erratic data[J]. Geophysics, 1973, 38, 826–844.

[11] Gao, J., M. Sacchi, and X. Chen, A fast rank reduction method for the reconstruction of 5D seismic volumes: 81st Annual International Meeting[C]. SEG, Expanded Abstracts, 2011, 3622–3627 .

[12] Cheng, J., and M. D. Sacchi, 2014, A dual domain algorithm for minimum nuclear norm deblending: 84th Annual International Meeting, SEG, Expanded Abstracts, 99–104.

[13] Ji, J. , Robust inversion using biweight norm[C]. 81st Annual International Meeting, SEG, Expanded Abstracts, 2011, 2717–2721.

[14] Al-Yahya, K., 1991, Application of the partial Karhunen-Loève transform to suppress random noise in seismic sections: Geophysical Prospecting, 39, no. 1, 77–93.

[15] Russell, B., D. Hampson, and J. Chun Noise elimination and the Radon transform, part 1[J]. The Leading Edge 9, 1990, 18–23.

[16] Russell, B., D. Hampson, and J. Chun. Noise elimination and the Radon transform, part 2[J]. The Leading Edge, 9, 1990, 31–37.

[17] Sacchi.M. FX singular spectrum analysis[C]. CSPG CSEG CWLS Convention, Abstracts, 2009, 392–395.

[18] Soubaras.R. Signal-preserving random noise attenuation by the F-X projection[C]. 64th Annual International Meeting, SEG, Expanded Abstracts, 1994, 1576–1579.

[19] Trickett.S. F-x eigenimage noise suppression[C]. 72nd Annual International Meeting, SEG, Expanded Abstracts, 2002, 2166–2169.

[20] Trickett.S. F-XY Cadzow noise suppression[C]. 78th Annual International Meeting, SEG, Expanded Abstracts, 2008, 2586–2590.

[21] Trickett.S. and L. Burroughs. Prestack rank-reduction-based noise suppression[J]. CSEG Recorder, 2009, 34(9), 24–31.

[22] Trickett.S. F-XY eigenimage noise suppression[J], Geophysics, 2003, 68, 751–759.

[23] 潘军, 刘鸿, 栾锡武等. 异常振幅衰减技术在多道地震数据处理中的应用[J], 地球物理学进展, 2016, 31(4): 1639-1645.

[24] 李帆. 基于加权多道奇异谱分析的地震异常值噪声压制[C]. 中国地球科学联合学术年会论文集专题

47, 2018, 31-33.

[25] 余建华, 李丹丹, 黄天辰. 地震事件实时检测中野值的辨识与替代[J]. 国外电子测量技术, 2011, 30 (07): 24-27.

[26] 谢佥. 随机和相干噪声衰减的研究[D]. 中国石油大学（北京）, 2017.

[27] 丁虎, 井间地震资料多域异常噪声压制方法技术研究[M]. 长安大学, 2012.

[28] 陈志德, 郑锡娟, 关昕等. 长垣油田地震异常值噪声分频压制技术[J]，大庆石油地质与开发, 2010, 29-30.

中国地质大学（北京）本科毕业设计（论文）开题报告

专业	勘查技术与工程	班级	10101631	学号	1010163122
姓名	贾昊	导师姓名	高建军	导师职称	副教授
课题性质	◉a. 设计 ○b. 论文		课题来源	自拟课题	
设计（论文）题目	基于稳健主成分分析的地震数据噪音压制				

开题报告（阐述课题的目的、意义、研究现状、研究内容、研究方案、预期结果等）

一、研究目的和意义

地震勘探数据往往伴有噪声，因此提高信噪比在地震数据处理中起到了决定性的作用。传统的主成分分析（PCA）降秩方法由于缺乏对异常值噪声的稳定性，所以在实际数据问题中的应用受到了限制，采用基于稳健主成分分析（RPCA）的方法可以更加有效的去压制实际地震数据中的异常值噪声。本课题采用基于稳健主成分分析，该方法在频率-空间域操作且依赖于一个稳健的地震数据体的低秩近似。在使用 l1 范数限制去适当的估计异常值（稀疏）噪声时我们采用一个产生理想数据低阶近似值的核模约束，之后通过用两步软阈值转换的一阶梯度迭代方法处理，从而进一步达到提高信噪比的目的。

在进行稳健主成分分析之后，可以同时压制高斯噪声和异常值噪声。该方法有可能用于同步源地震数据去噪和重建。它可以有效减少由于噪声带来的不利影响，从而提高地震资料的信噪比，得到更精确的地质信息。

二、研究现状

早年，异常值噪声采用人工道编辑，手动剔除的方法来去除，但是随着现代地震数据越来越大，处理工作也更加复杂，人工地震道编辑变得不切实际，故而很多学者研究采用滤波的方法来压制异常值。压制异常值噪声具体的方法有的有小波变换、时频域加权中值法、降秩滤波法等。

1、基于小波变换的异常值噪声压制

小波变换是一种应用数学分支，发展于上个世纪，继承和发展了短时傅立叶变换的思想，可以聚焦到信号的任意细节，具有多分辨率、多尺度的特点。最早是用于信号和图像的处理，后来用在了地震资料处理领域。

Donoho 和 Johnston 等人在 1997 年研究并提出了的软阈值和硬阈值信号去噪方法，给出了通用阀值的计算公式，并且从理论上证明了该阀值是最优的。

Chang 等人在 2000 年提出了一种自适应小波阀值去噪方法，用于处理图像空域，该方法将平移不变去噪思想和自适应阀值结合在一起，根据图像特征阀值可以自适应地变化。

郝雪等人在 2006 年提出了一种基于奇异值分解（SVD）和小波阀值的处理方法，先使用混沌振子法找到有效信号，然后通过线性时移将同相轴校正到同一方位，再使用奇异值分解滤波，然后反线性时移将同相轴变回原始位置，最后用小波逆变换重构信号。

2、基于中值滤波的异常值噪声压制

中值滤波对脉冲噪声有良好的压制作用，特别是在滤除噪声的同时，能够保护信号的边缘。中值滤波实现方式比较简单，通过一定的窗口观察数据，用几个采样点的中值代替原来某一个点的采样值，滤波器效益上它属于一种低通滤波。

陈志德等人在 2010 年提出了一种基于中值滤波的异常振幅噪声分频压制技术，根据异常值振幅噪声集中分布于检波点集而随机分布于炮集的特点，通过将炮集数据划分为不同的频率子集，在每个频率子集上使用中值滤波进行噪声压制。

潘军等人在 2016 年提出了一种异常振幅衰减技术的应用，在指定的某个频带内，当信号的振幅大于某个阀值时，认为该信号是异常的，并用相邻道的插值来代替。

3、基于降秩滤波的异常值噪声压制

降秩滤波又被称为 Cadzow 滤波，是奇异谱分析（SSA）在地震数据处理领域的应用。奇异谱分析是近年来兴起的一种无模型技术，源自对一维时间序列的研究。它根据所观测到的时间序列构造出轨迹矩阵，并对轨迹矩阵进行分解、重构，从而提取出代表原时间序列不同成分的信号。SSA 的早期应用主要集中在动力系统分析上，用于识别时间序列中的自由度，并以此找出数据中存在的主要物理过程。

Broomhead 和 King（1986）对 SSA 的发展作出了重要贡献，他使用 Takens（1981）提出的延迟方法，使用多元统计分析研究动力系统。Fraedrich（1986）也将 SSA 应用于古气候海洋记录的空间分析。 Vautard 等人（1992）更深入地研究了奇异谱分析，他将其作为分析短、嘈杂和混沌信号的工具，他们调查了应用 SSA 产生的四个主要问题：比如嵌入维度这样的参数如何影响分析，结果的稳定性和统计置信度如何，噪声识别的可能应用以及如何解释每个奇异分量给出的信息。Elsner 和 Tsonis（1996）和 Golyandina 等人（2001）在其著作中总结和解释了 SSA 的基本原理，并且使用了不同的例子和应用来说明。

SSA 的应用可以同时扩展到多个时间序列，被称为多变量或多道奇异谱分析（MSSA）。Read（1993）首次应用这种方法，与 SSA 的区别在于，轨迹矩阵包括来自所有时间序列分析的信息。在他的研究中，MSSA 用于和时间相关的实验温度测量的相位分析，仍旧主要应用于气候记录研究。Plaut 和 Vautard（1994）使用这种技术来研究北半球中纬度地区的气候低频振荡。MSSA 也被用于时间序列的信号重建和预测（Golyandina 和 Stepanov，2005）以及数字地形模型的滤波（Golyandina 等，2007）。

结合 SSA 在动力学系统研究中的应用，发现它对于时间序列中的噪声衰减是有用的。

这是通过在数据分解后恢复较少数量的奇异值来进行的。Broomhead 和 King（1986）观察到这一特性，并在许多研究中得到实施。据说 SSA 作为去噪技术比作为动力学分析工具更有效（Mees 等，1987; Palus 和 Dvor'ak，1987）。使用 SSA 进行噪声衰减的主要挑战来自选择恢复数据的奇异值的数量，这取决于信号和噪声之间的相关程度。一般认为，含有效信号的奇异值是最大的（Elsner 和 Tsonis，1996），但当噪声不是白色或信噪比太低时，情况将不同。大多数将 SSA 应用于动力系统的文章也将其应用于噪声消除扩展。

SSA 的应用包括四个主要步骤。第一步是将时间序列嵌入轨迹矩阵中。第二步是通过使用奇异值分解（SVD）在这个矩阵的奇异谱中进行分解。第三步包括通过从分解中回收更少量的奇异值来将轨迹矩阵降秩。最后，从降秩的轨迹矩阵恢复时间序列。

奇异谱分析通过将空间数据以给定的单一频率嵌入到轨迹矩阵中而在频域空间（f-x）中操作。由于噪声或者缺失道的存在，矩阵的秩会增加，那么，可以从噪声观测的轨迹矩阵的低秩近似（Oropeza 和 Sacchi，2011）中估计在没有噪声的情况下可能形成的理想轨迹矩阵。奇异谱分析（SSA）重建也可以通过形成多层次的轨迹矩阵来应用于多维地震数据。在这种情况下，通过奇异值分解（SVD）、Lanczos 双对角化或通过随机 QR 分解来执行大的多级轨迹矩阵的降秩。

传统的多道奇异谱分析无法有效地压制异常值噪声，故而 Trickett 在 2012 年提出了一种稳健的降秩滤波方法，基于截断奇异值分解（TSVD）设计了一个双平方重加权因子，通过降秩后的频率切片和原始频率切片加权迭代降秩来压制异常值噪声，并且使用该方法对模型数据和实际数据进行了处理，取得了很好的效果。

Chen 和 Sacchi 认为奇异值分解（SVD）是一种非稳健的矩阵分解技术，当地震数据受到不稳定的噪声的污染时，它会导致不理想的结果，在 2014 年提出了一种基于随机 QR 分解的稳健 SSA 方法，用于去除高斯噪声和不稳定噪声。

陈阳康等人在 2016 提出了一种阻尼多道奇异谱分析（DMSSA）的方法。他们认为截断奇异值分解（TSVD）将数据投影到一个信号-噪声域和一个噪声域，得到的结果是信号-噪声域中的数据，因此提出在其的基础上加入一个阻尼矩阵来进一步压制残留的噪声，并用改进的多道奇异谱分析方法同时进行缺失道重建和去噪。

三、研究内容

本课题在常规主成分分析的基础上，实现稳健主成分分析算法，对地震道进行去噪，使得地震资料的信噪比得到提升。对于一个三维地震数据，首先选定一个时间切片，再对其进行快速傅里叶变换，在频率域对该切片的数据进行稳健主成分分析，每个时间段都会有一个对应的频率，通过移动时间切片以固定的采样间隔内对各切片均进行稳健主成分分析，再将频率域的三维地震数据转换回时间域，完成整个地震数据时间与频率的对应关系。移动窗口，完成整个地震道数据时间与频率的对应关系，从而绘制出时频谱，进行频谱分析。从信噪比的角度比较经过常规主成分分析和稳健主成分分析的地震数据的不同，并得出结论。

四、研究方案

第一阶段，通过阅读文献，了解课题方法的发展历程和研究现状，明确课题研究的思路和方法，掌握基本的公式与算法原理。

第二阶段，学习 MATLAB 基础编程知识，掌握 MATLAB 程序的基本编程语句及绘图语句，进而研究分析每条语句的作用，通过绘制的图件，进而比较该方法与传统方法的区别。

第三阶段，结合方法的基本原理，进行 MATLAB 编程，实现稳健主成分分析算法，比较常规主成分分析与稳健主成分分析对异常值噪声压制的效果，得出初步结论。

第四阶段，利用已知含有异常值噪声的地震数据，分别对他们进行常规主成分分析与稳健主成分分析（RPCA），并进行去噪，绘制图件，比较两者的信噪比。

第五阶段，将该方法用于实际应用中，对地震数据进行处理，观察经过稳健主成分分析之后的地震数据信噪比的变化。

五、预期成果

（1）掌握稳健主成分分析的公式及原理，以及对应的 MATLAB 程序，通过绘图直观分析其特点了解其优缺点。

（2）在常规主成分分析的基础上，为了提高信噪比，进行稳健主成分分析。掌握稳健主成分分析的步骤，以及每个步骤的作用，掌握每个步骤的公式算法，能够独立分析 MATLAB 程序对应的语句，并加以运用。

（3）通过 MATLAB 编程，对比经过常规主成分分析与稳健主成分分析的地震数据，从图件中分析常规主成分分析与稳健主成分分析对地震信号的作用。

（4）将该方法运用到实际中，对已知的地震数据资料进行稳健主成分分析，分析地下的结构特点，评价是否能通过该方法更精准地分析地下的地质信息。

实验安全落实情况：

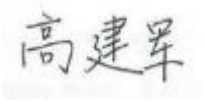
（1）设计（论文）工作中是否设计实验操作：○是 ◉否

（2）是否参加安全教育培训并通过考试：○是 ◉否

（3）是否与指导教师进行安全风险分析并确通过：◉是 ○否

指导教师意见：

同意开题。

指导教师签名： 

2020 年 1 月 5 日

评议小组意见：

同意开题

审 查 结 果：☑同 意 □ 不 同 意

评议小组组长 ： 高建军 成员：王赟、 苑益军、 芦俊

2020 年 1 月 6 日

中国地质大学（北京）本科毕业设计（论文）中期检查表

专业	勘查技术与工程	班级	10101631	学号	1010163122
姓名	贾昊	导师姓名	高建军	导师职称	副教授
设计（论文）题目	基于稳健主成分分析的地震数据噪音压制				
已完成内容	1、 文献阅读 2、 文献翻译 3、 三维地震数据生成 4、 异常值噪声数据生成 5、RPCA 程序的编写				
下一步进展计划	1、 调整程序参数，寻找最佳消除异常值噪声的参数； 2、 对比分析 RPCA 方法与传统方法的优缺点； 3、 将该方法用于更多实际数据中，分析比较稳健主成分分析算法的优势； 4、 阅读文献，综合整理稳健主成分分析在地震领域中的应用； 5、 撰写毕业论文，为最终答辩做准备。				
中期检查意见（指导教师填写）	贾昊同学编程实现了 RPCA 算法并用模型数据进行了方法效果测试，取得初步结果，建议下一步分析方法优缺点，并用实际资料进行方法效果测试。 指导教师签名：高建军 2020 年 4 月 15 日				

中国地质大学（北京）

本科毕业设计（论文）评语表（指导教师用）

专业	勘查技术与工程	班级	10101631	学号	1010163122
姓名	贾昊	导师姓名	高建军	导师职称	副教授
设计（论文）题目	基于稳健主成分分析的地震数据噪音压制				

序号	评价项目	评　价　内　容	满分	评分
1	调研与综合	能独立查阅文献和从事其他调研；有综合、收集、加工各种信息及获取新知识的能力。	10	9.0
2	设计、实验方案，分析与技能	设计、实验方案科学合理；数据可靠、计算、处理正确；结构合理、工艺可行；分析、论证充分；具有较强的独立分析、解决实际问题的能力；绘图符合国家标准及规范。	40	35.0
3	工作量、工作态度	按期圆满完成规定的任务，难易程度和工作量符合教学要求；工作努力，遵守纪律；工作作风严谨务实；善于与他人合作。	20	18.0
4	论文（说明书）质量	综述简练完整，行文重点突出，有见解；立论正确，论据充分，结论严谨合理；文理通顺，技术用语准确；图表规范；论文结果有应用价值。	20	18.0
5	译　　文	翻译准确、通顺、文笔流畅，译文数量符合要求。	5	4.0
6	创　　新	工作中有创新意识；对前人工作有改进、突破，或有独特见解。	5	4.0
是否同意参加答辩：是			总分	88.0

评语：

论文对地震数据中的异常值噪声问题进行研究，采用基于稳健主成分分析方法用于压制异常值噪声，模型数据和实际数据测试结果验证了方法的有效性，达到了预期毕设的目标和要求。论文工作量充实，数据分析可靠，计算正确，论证充分。该生在毕设推进过程中，能及时调整心态，克服疫情影响，努力学习，积极思考和解决毕设中遇到的各种算法实验问题，表现出较强的动手能力和独立思考能力。论文结构完整，结论合理，图表规范，翻译通顺流畅，符合毕设要求，同意其参加最终论文答辩。

指导教师签字：高建军

2020 年 5 月 28 日

中国地质大学（北京）
本科毕业设计（论文）评议表（评阅人用）

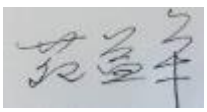
专业	勘查技术与工程	班级	10101631	学号	1010163122
姓名	贾昊	导师姓名	高建军	导师职称	副教授
设计（论文）题目	基于稳健主成分分析的地震数据噪音压制				

序号	评价项目	评　价　内　容	满分	评分
1	调研与综合	能独立查阅文献和从事其他调研；有收集、加工及综合各种资料、信息及获取新知识的能力。	10	9.0
2	设计、实验方案，分析与技能	设计、实验方案科学合理，数据采集可靠；综合分析的正确、合理性；计算的正确性；方案论证的充分性；解决实际问题的能力；图纸的绘制与技术要求符合国家标准、规范及要求。	40	36.0
3	工作量、	工作量饱满，有一定难度。	20	18.0
4	论文（说明书）质量	综述简练完整，有见解；立论正确，论据充分，结论严谨合理；文理通顺，技术用语准确；图表规范；论文结果有应用价值。	20	16.0
5	译　　文	翻译准确、通顺、文笔流畅，译文数量符合要求。	5	4.0
6	创　　新	对前人工作有改进、突破，或有独特见解。	5	4.0
是否同意参加答辩:是			总分	87.0

评语：贾昊同学针对地震数据中的异常振幅噪声,开展了基于稳健主成分分析的地震数据噪音压制方法研究。通过查阅参考文献，了解了目前现有异常振幅噪声压制方法的方法原理及其优缺点。在此基础上，通过方法研究及Matlab 编程实现了基于稳健主成分分析的地震数据噪音压制方法，并通过模型试算，验证了方法的可行性。模型试算与实际数据处理结果表明，基于稳健主成分分析的地震数据噪音压制方法能够去除地震数据中异常振幅噪声，并能获得优于传统 F-X 预测滤波方法的去噪效果。

本论文实验方法合理，实验数据可靠，对比分析客观。论文工作量饱满，研究方法实现有一定难度。论文撰写较规范，语言逻辑性较强，文理通顺，技术术语基本准确。译文翻译较准确，文笔舒畅，数量符合要求。对前人研究工作有独特见解。

评阅人签字：



2020 年 5 月 29 日

中国地质大学（北京）
本科毕业设计（论文）答辩评审表

专业	勘查技术与工程	班级	10101631	学号	1010163122
姓名	贾昊	导师姓名	高建军	导师职称	副教授
设计（论文）题目	基于稳健主成分分析的地震数据噪音压制				
答辩日期	2020 年 5 月 30 日		答辩地点	教 5 楼 403	

序号	评价项目	评　价　内　容	满分	评分
1	报告内容	思路清晰；语言表达准确，概念清楚，论点正确，重点突出，内容完整；实验方法科学，分析归纳合理；结论严谨；论文结果有应用价值。	50	46.0
2	创　　新	对前人工作有改进或突破，或有独特见解。	10	8.0
3	报告过程	准备工作充分，时间符合要求；个人言行、仪表恰当。	10	8.0
4	答　　辩	回答问题有理论依据，基本概念清楚。主要问题回答准确、有深度。	30	26.0
			总分	88.0

评语：

贾昊同学针对基于稳健主成分分析的地震数据噪音压制研究内容进行了汇报。报告思路清晰，语言表达准确，实验方法科学，实验效果明显，实验结果可信，论文研究有独特见解。报告准备工作充分，能客观回答评委提出的问题。

答辩小组组长 ：　　成员：



毕业设计（论文）总成绩

指导教师评分	88. 0	评阅人评分	87.0	答辩评分	88.0
综合评定成绩(3:3:4 比例)			88.0	五级分制记分	良好

学院公章

_____年 _____月 _____ 日

文本复制检测报告单(简洁)

№:BC20200528154146258736499　　检测时间:2020-05-28 15:41:46

检测文献:　贾昊-毕业论文-最终版

作者:　贾昊

检测范围:　中国学术期刊网络出版总库

中国博士学位论文全文数据库/中国优秀硕士学位论文全文数据库

中国重要会议论文全文数据库

中国重要报纸全文数据库

中国专利全文数据库

图书资源

优先出版文献库

大学生论文联合比对库

互联网资源(包含贴吧等论坛资源)

英文数据库(涵盖期刊、博硕、会议的英文数据以及德国Springer、英国Taylor&Francis 期刊数据库等)

港澳台学术文献库

互联网文档资源

CNKI大成编客-原创作品库

时间范围:　1900-01-01至2020-05-28

检测结果

总文字复制比：17.4%　　跨语言检测结果：0%

去除引用文献复制比：17.4%　　去除本人已发表文献复制比：17.4%

单篇最大文字复制比：16%（基于加权多道奇异谱分析算法的地震异常值噪声压制）

重复字数：[3470]　　总段落数：[3]

总字数：[19922]　　疑似段落数：[2]

单篇最大重复字数：[3188]　　前部重合字数：[1509]

疑似段落最大重合字数：[3208]　　后部重合字数：[1961]

疑似段落最小重合字数：[262]



指　标：□疑似剽窃观点　☑疑似剽窃文字表述　□疑似自我剽窃　□一稿多投　□疑似整体剽窃　□过度引用　□重复发表

表格：0　　公式：-　　疑似文字的图片：0　　脚注与尾注：0

0%（0）　贾昊-毕业论文-最终版_第1部分（总1710字）

35.3%（3208）　贾昊-毕业论文-最终版_第2部分（总9080字）

2.9%（262）　贾昊-毕业论文-最终版_第3部分（总9132字）

1. 贾昊-毕业论文-最终版_第1部分　　总字数：1710

相似文献列表　文字复制比：0%(0)　疑似剽窃观点：(0)

2. 贾昊-毕业论文-最终版_第2部分　　总字数：9080

相似文献列表　文字复制比：35.3%(3208)　疑似剽窃观点：(0)

1	基于加权多道奇异谱分析算法的地震异常值噪声压制 李帆 -《大学生论文联合比对库》- 2018-06-04	32.6%（2956） 是否引证：否
2	基于加权多道奇异谱分析算法的地震 异常值噪声压制 李帆 -《大学生论文联合比对库》- 2018-05-21	23.1%（2094） 是否引证：否
3	基于广义奇异值分解的图像去噪算法 杨洁;魏平俊;张旭初; -《中原工学院学报》- 2019-10-25	1.5%（136） 是否引证：否
4	工业过程模型挖掘及并行检索研究 甘婷婷(导师：程良伦) -《广东工业大学硕士论文》- 2019-05-26	0.6%（56） 是否引证：否
5	多通道雷达干扰抑制与目标检测算法研究 郭小路(导师：陶海红) -《西安电子科技大学博士论文》- 2017-09-01	0.6%（51） 是否引证：否

3. 贾昊-毕业论文-最终版_第3部分

总字数：9132

相似文献列表　文字复制比：2.9%(262)　疑似剽窃观点：(0)

1	基于加权多道奇异谱分析算法的地震异常值噪声压制 李帆 - 《大学生论文联合比对库》- 2018-06-04	2.5%（232） 是否引证：否
2	膜技术在木醋液纯化工艺中的应用 乔玉彦(导师：任保增;王宏力) - 《郑州大学硕士论文》- 2010-05-01	0.3%（29） 是否引证：否

说明：1.总文字复制比：被检测论文总重合字数在总字数中所占的比例

2.去除引用文献复制比：去除系统识别为引用的文献后，计算出来的重合字数在总字数中所占的比例

3.去除本人已发表文献复制比：去除作者本人已发表文献后，计算出来的重合字数在总字数中所占的比例

4.单篇最大文字复制比：被检测文献与所有相似文献比对后，重合字数占总字数的比例最大的那一篇文献的文字复制比

5.指标是由系统根据《学术论文不端行为的界定标准》自动生成的

6.红色文字表示文字复制部分;绿色文字表示引用部分

7.本报告单仅对您所选择比对资源范围内检测结果负责

amlc@cnki.net
http://check.cnki.net/
http://e.weibo.com/u/3194559873/

CNKI知网诚信管理系统研究中心

中国地质大学（北京）

本科毕业设计外文资料翻译

学　　院： 地球物理与信息技术学院

专　　业： 勘查技术与工程

姓　　名： 贾昊

学　　号： 1010163122

外文出处： 2015 SEG Annual Meeting Abstract

附　　件： 1.外文资料翻译译文；2.外文原文。

完成日期： 2020 年 3 月 5 日

稳健主成分分析压制地震记录中异常值噪声的应用

Jinkun Cheng*, Ke Chen 和 Mauricio D.Sacchi, 阿尔伯塔大学

摘要

地震数据常含有噪声。因此，增强信噪比在地震数据处理中起着重要作用。本文阐述了一种稳健主成分分析（RPCA）方法来抑制被污染地震数据中的异常值噪声。该方法在频率-空间域中通过对地震数据体实施稳健低秩近似来实现。我们采用核范数最小化约束来产生理想的低秩近似数据，同时使用 $\ell 1$ 范数约束来估计异常值（稀疏）噪声。然后，运用具有两步软阈值的一阶梯度迭代方法解决该问题。最后，我们通过综合实例说明了该方法的有效性。

介绍

主成分分析（PCA）是统计中进行多元分析的重要工具。这个想法是在减少数据体的维数的同时保留尽可能多的数据变量的可变性（Jolliffe，2010）。让我们考虑从观测数据中恢复低秩矩阵 **L**

$$\mathbf{D} = \mathbf{L} + \mathbf{E}, \tag{1}$$

其中，矩阵 **E** 代表额外误差。我们假设 **E** 由小的随机扰动组成，则可以通过以下优化问题获得 **L** 的最优估计

$$\min \|\mathbf{E}\|_F^2$$
$$\text{s.t.} \quad \text{rank}(\mathbf{L})=k, \quad \mathbf{D} = \mathbf{L} + \mathbf{E}. \tag{2}$$

该问题可以通过奇异值分解（SVD）有效地解决(Golub 和 van Loan, 1996)。观测数据 **D** 可以通过 SVD 被分解为一组本征图像。低秩分量 **L** 可以用与最大奇异值相关联的一些本征图像表示。然而，误差 **E** 将使能量散布在所有本征图像上（Trickett，2003）。

在地震数据处理中已经开发了多种基于 PCA 的方法。例如，Ulrych 等(1999）提出了一种时间域矩阵降秩的方法来消除地震记录中的非相干噪声。同属于该类的一种 K-L 变换方法也被提出以增强叠前地震道的信噪比（Al-Yahya，1991）。对于倾斜同相轴，可以通过在 *f-x-y* 域中应用特征图像滤波来处理（Trickett，2003）。

同样，Cadzow 去噪（Trickett 和 Burroughs，2009）或奇异频谱分析（SSA）（Sacchi，2009；Oropeza 和 Sacchi，2011）也在频率-空间域运行并且能够在保留相干倾角的同时衰减随机噪声。与传统本征图像方法（Ulrych 等，1999）不同，Cadzow 和 SSA 去噪方法不是对空间数据本身进行操作而是对由 *f-x* 域或 *f-x-y* 域的数据形成的汉克尔矩阵进行操作。

尽管上述降秩方法对衰减高斯型随机噪声非常有效，但是由于缺乏稳健性，对异常值噪声的压制失效。在地震数据处理中，异常值噪声包括涌浪噪声，电源线噪声和由记录仪器故障引起的设备噪声。异常值噪声往往表现为不遵循高斯分布的强振幅孤立信号。因此，PCA 采用的传统的最小二乘误差准则去噪效果表现不佳（Golub 和 van Loan，1996；Trickett 等人，2012；Chen 和 Sacchi，2014）。在本文，假设异常值噪声是稀疏信号，我们采用 $\ell 1$ 范数约束来代替最小二乘约束。在 $\ell 1$ 范数约束不适定项的条件下，寻找低阶近似矩阵可以看做一个非凸优化问题（Wright 等，2009）。本文提出一种简便算法，可以将非凸优化问题替换为基于梯度优化凸算法。该算法称为稳健主成分分析（RPCA）（Candes 等，2011）。我们将展示 RPCA 能够抑制异常值噪声。合成数据测试结果验证该方法可以有效压制数据中的异常值噪声。

稳健主成分分析

假设稀疏矩阵 **S** 来表示异常值噪声。**S** 中仅有少数项是非零元素并且振幅是可以任意大的（Zhou 等，2010）。 稳健主成分分析提出了以下优化问题：

$$\min \|\mathbf{S}\|_0$$

$$\text{s.t.} \quad \text{rank}(\mathbf{L})=k, \quad \mathbf{D}=\mathbf{L}+\mathbf{S} \tag{3}$$

其中，$\|\mathbf{S}\|_0$ 表示 **S** 的 $\ell 0$ 范数，即 **S** 中非零元素的个数。等式（3）是一个 NP-hard 问题。为使问题可解，我们使用由矩阵 **S** 中所有元素绝对值之和定义的 L1 范数来代替 L0 范数。同时，我们考虑用 **L** 的核范数代替低秩约束，其中 **L** 的核模定义为矩阵 **L** 的所有非零奇异值的和。可以证明 $\ell 1$ 范数是 $\ell 0$ 范数最严格的凸松弛。（Donoho，2006）。同理，核范数是对低秩约束的紧凸松弛（Fazel，2002）。我们还引入了 Frobenius 范数约束，$\|\mathbf{D}-\mathbf{L}-\mathbf{S}\|_F^2$ 来约束高斯噪声。产生的目标函数可以写成如下形式，

$$\min J = \frac{1}{2\mu}\|\mathbf{D}-\mathbf{L}-\mathbf{S}\|_F^2 + \lambda\|S\|_1 + \|\mathbf{L}\|_* \tag{4}$$

λ为平衡稀疏性和低阶约束的折衷因子。μ是一个取值较小的常数，用来控制高斯噪声。

我们考虑用迭代法来求取在最小化等式（4）时的低秩数据 **L** 以及稀疏异常值噪声矩阵 **S**。基于子梯度方法我们将目标函数分为两个子问题。等式（4）的解等价于以下目标函数的解，

$$\min J_S = \lambda\|\mathbf{S}\|_1 + \left\|\mathbf{S}-\hat{\mathbf{S}}^k\right\|_F^2 \tag{5a}$$

$$\min J_L = \|\mathbf{L}\|_* + \left\|\mathbf{L}-\hat{\mathbf{L}}^k\right\|_F^2 \tag{5b}$$

仅当$\hat{\mathbf{L}}^k$和$\hat{\mathbf{S}}^k$收敛于，

$$\min J_0 = \frac{1}{2\mu}\|\mathbf{D}-\mathbf{L}-\mathbf{S}\|_F^2 \tag{6}$$

因此，我们可以通过在 J0 梯度的相反方向上更新当前估计来计算$\hat{\mathbf{L}}^k$和$\hat{\mathbf{S}}^k$

$$\hat{\mathbf{S}}^k = \mathbf{S}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$$

$$\hat{\mathbf{L}}^k = \mathbf{L}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D}) \tag{7}$$

等式（5a）在压缩感应领域中十分常见。它通过对$\hat{\mathbf{S}}^k$的所有元素项实施软阈值操作来更新解（Beck 和 Teboulle，2009）。 方程（5b）的解也可以利用最新的矩阵补全研究进展来找到。在这里，不是将软阈值直接应用于输入项，而是对矩阵$\hat{\mathbf{L}}^k$的奇异值实施软阈值操作来实现（Cai 等，2010; Recht 等，2010）（参阅算法（1））。

算法 1 RPCA

输入：

观测数据 **D**，权衡参数λ和截断误差ε

初始化：

$\mathbf{L}^0 = 0; \mathbf{S}^0 = 0; k = 1$

重复

$$\hat{\mathbf{S}}^k = \mathbf{S}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$$

$$\hat{\mathbf{L}}^k = \mathbf{L}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$$

$$\mathbf{S}^{k+1} = \max(\left|\hat{S}_k(i,j)\right| - \frac{\lambda\mu}{2}, 0)$$

$$[\mathbf{U}, \Sigma, \mathbf{V}] = \text{svd}\left[\hat{\mathbf{L}}^k\right]$$

$$\hat{\Sigma} = \max(|\Sigma(i,i)| - \frac{\lambda\mu}{2}, 0)$$

$$\mathbf{L}^{k+1} = \mathbf{U}\hat{\Sigma}\mathbf{V}^*$$

$$k = k+1$$

until $\left\|\mathbf{D} - \mathbf{L}^k - \mathbf{S}^k\right\|_F^2 < \varepsilon$

输出：

Low-rank estimation $\mathbf{L}^{k+1}$;

Estimated erratic noise $\mathbf{S}^{k+1}$.

RPCA 方法的实现过程如算法（1）所示。在每次迭代中，我们都会根据二次项的梯度，在反方向上修改低秩矩阵与异常值噪声的当前估计值。然后，我们应用软阈值二步法得到修改后的估算值。Zhou 等（2010 年）证明选择 $\lambda = 1/\max(m,n)$ 可以保证高质量的恢复矩阵 **L**，其中 m 和 n 是输入矩阵 **D** 的大小。可以根据下式计算参数 μ：$\mu = 0.1\sqrt{\max(m,n) + 8\sigma\sqrt{\max(m,n)}}$（Tao and Yuan，2011），其中，$\sigma$ 是数据中噪声标准误差的估计值。

RPCA 地震数据噪声衰减

采用稳健主成分分析来压制地震数据中存在的异常值噪声。我们考虑将 RPCA 算法应用于从高维地震数据集中提取的 3D 数据 $D(t,x,y)$。我们注意的是，将数据从 *t-x-y* 域映射到 *f-x-y* 域的傅里叶变换可以表示为，

$$\tilde{D}(\omega,x,y) = \int D(t,x,y)e^{i\omega t}d\omega \tag{8}$$

在给定的频率下 ω，空间数据可以通过频谱矩阵 $\mathbf{D}_\omega$ 表示。所需信号沿两个空间方向是相干的。因此，$\mathbf{D}_\omega$ 是一个低阶矩阵（Trickett，2003；Cheng 和 Sacchi，2014）。应用于 *f-x-y* 域三维数据体频率切片的稳健矩阵降秩降噪算法如算法（2）所示。

算法 2 RPCA 去噪

输入：

三维地震数据体 $\mathcal{D}$

权衡参数 λ

$\tilde{D}(\omega, x, y) \leftarrow D(t, x, y)$

for $\omega = \omega_{\min} : \omega_{\max}$ **do**

$\mathbf{D}_{\omega} \leftarrow \tilde{D}(\omega, :, :)$

$[\mathbf{L}, \mathbf{S}] = \mathrm{RPCA}[\mathbf{D}_{\omega}]$

$\tilde{\tilde{D}}(\omega, :, :) \leftarrow \mathbf{L}$

end for

$\tilde{D}(t, x, y) \leftarrow \tilde{\tilde{D}}(\omega, x, y)$

例子

异常值噪声压制

一个合成数据集被用来测试所提出的降噪方法的稳健性。图 1（a）显示了三维 *t-x-y* 域数据体，该数据具有 30×30 道，总时间为 1 秒。如图 1（b）所示，我们添加了高斯噪声，使数据的信噪比达到 3。我们也添加了稀疏异常值噪声，其最大振幅约为信号最大振幅的 3 倍。处理的频带范围是 1 到 40 Hz。比较了 *f-x-y* 本征图像滤波和 RPCA 去噪的结果。我们通过质量因子 Q 评估算法的性能，

$$Q = \frac{\left\| \tilde{D} - D \right\|_F^2}{\left\| D \right\|_F^2},$$

其中 D 是无噪声数据，而 $\tilde{D}$ 表示去噪后的数据。图 1（c）显示出了 *f-x-y* 本征图像滤波的结果。取秩为 3。图 1（d）显示了滤波后数据与真实数据之间的差异。从图上可以看出异常值噪声未能完全压制，差剖面上存在明显的信号残留。图 1（e）是 RPCA 去噪后的结果。高斯噪声和异常值噪声均得到成功抑制。这表明所提出的方法能有效地压制非相干噪声。图 1（f）显示了 RPCA 去噪结果与原始无噪数据的差剖面。最终，含噪数据的质量因子从 Q = −6.7 dB 提高到了 Q = 11.9 dB。

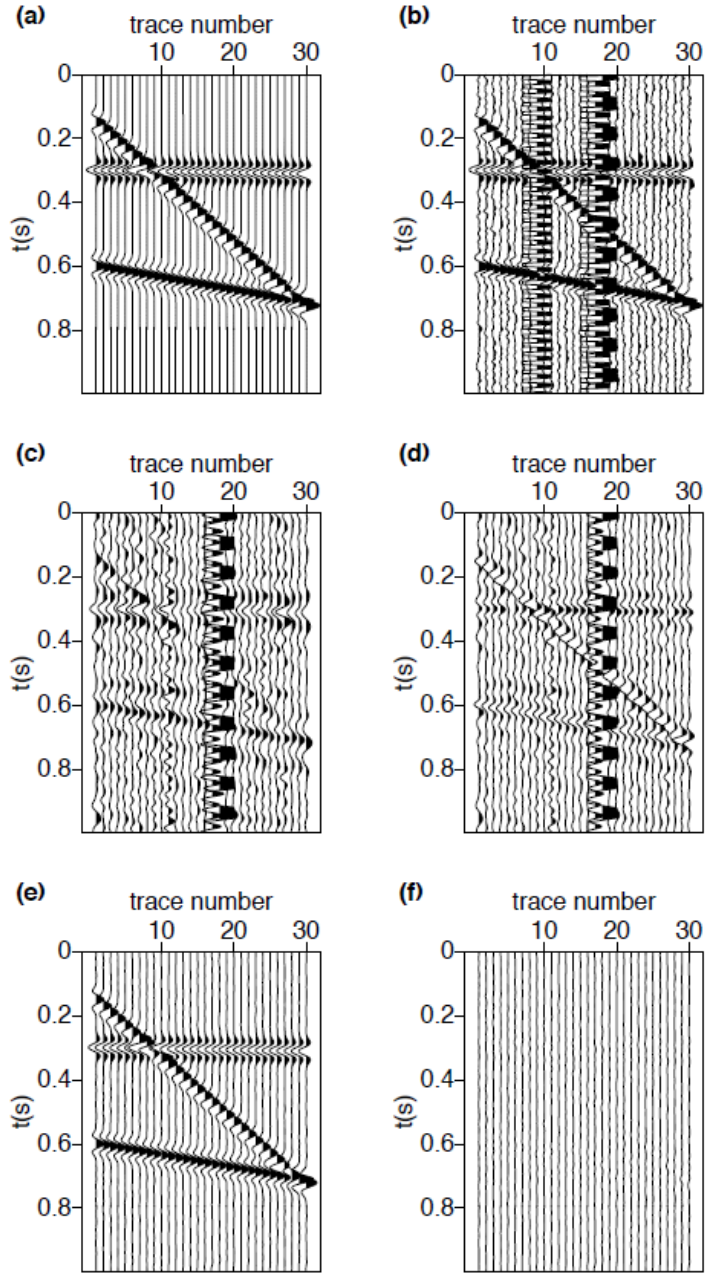


图 1：合成数据稳健主成分分析法去噪结果。（a）3 维数据数据体的所需 CMP 道集。（b）被高斯噪声和不稳定噪声污染的 CMP 道集。（c）通过 *f-x-y* 本征图像滤波进行去噪的道集。（d）（a）与（c）之间的差异。（e）RPCA 去噪后的 CMP 道集。（f）（a）与（e）之间的差异。

我们也使用了实际数据测试 RPCA 方法。图（2）显示了一小块（50×50 道）偏移距-共中心点叠后道集。时间维总长度为 1 秒。我们向孤立道中添加余弦信号来模仿电源线引起的异常值噪声。图（2）显示 RPCA 去噪方法在有效地抑制异

常值噪声的同时还能较好的保留所需信号。在此例中，数据的质量因从 $Q=4.7$dB 提高到 $Q=9$dB。

同时激发震源的噪声压制

我们还将该算法应用于混叠震源的共接收点道集噪声压制。我们采用了人工合成的 3D 垂直地震剖面数据来模拟混叠炮数据的采集。数据集包含 205 条源线，每条线上 205 个震源。每个震源间隔为 16.67m，行距也为 16.67m（O'Brien，2010 年）。在 1600m 深度提取了一个常见的共接收点道集。我们假设数据在自动同步激发条件下采集的。只有一条船激发，炮与炮激发的时间间隔服从均匀随机延迟。期望的时间延迟是传统炮间隔时间长度的 70％。图 3（b）显示了共接收点域伪混叠道集，其中包含有混叠噪声。在此例中，我们假定通过该采集方式能够节省了 30％的采集时间。图 3（c）显示了所提出方法的去噪结果。 RPCA 算法能够消除干扰并使得质量因子达到 $Q=10.2$。该例子表明基于稳健去噪技术能压制混叠炮噪声（Huo 等，2009；Ibrahim 和 Sacchi，2014）。但是，需要指出的是混叠数据分离也可以通过基于秩约束的反演方法来解决（Cheng 和 Sacchi，2014）。

结论

我们提出了一种稳健的主成分分析方法来压制地震数据中经常出现的异常值噪声。我们假设理想数据可以用频率-空间域中的低秩矩阵来表示，且异常值噪声可以通过稀疏矩阵来表示。核范数约束和 $\ell 1$ 模约束被用于同时恢复地震信号和异常值噪声。 我们通过一阶梯度法解决该问题。通过合成数据测试，表明所提出的 RPCA 去噪方法能够消除高斯和异常值噪声。此外，该方法还可应用于同时激发震源混叠炮数据的去噪和重建。最后，用高维数组反演来代替本文的矩阵反演可以实现频率域高维数据空间切片的去噪处理。

致谢

全体作者感谢阿尔伯塔大学信号分析与成像研究组（SAIG）的支持。

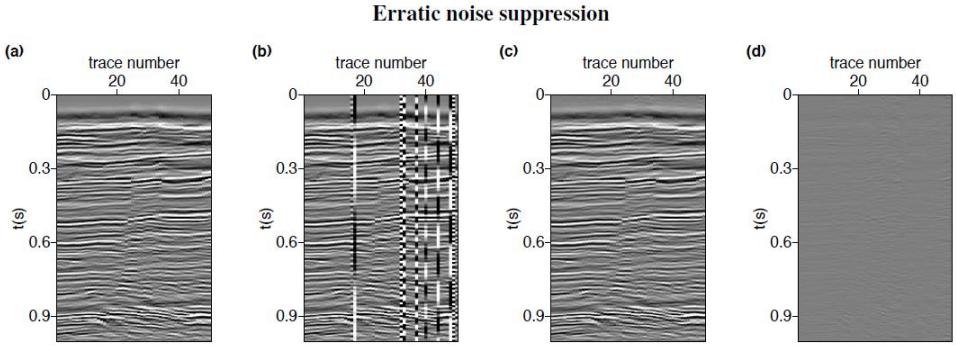


图 2：实际三维叠后数据体的稳健去噪结果。（a）三维数据中理想 CMP 道集。（b）含异常值噪声的 CMP 道集。（c）RPCA 去噪后的 CMP 道集。（d）图（a）与图（c）的差。

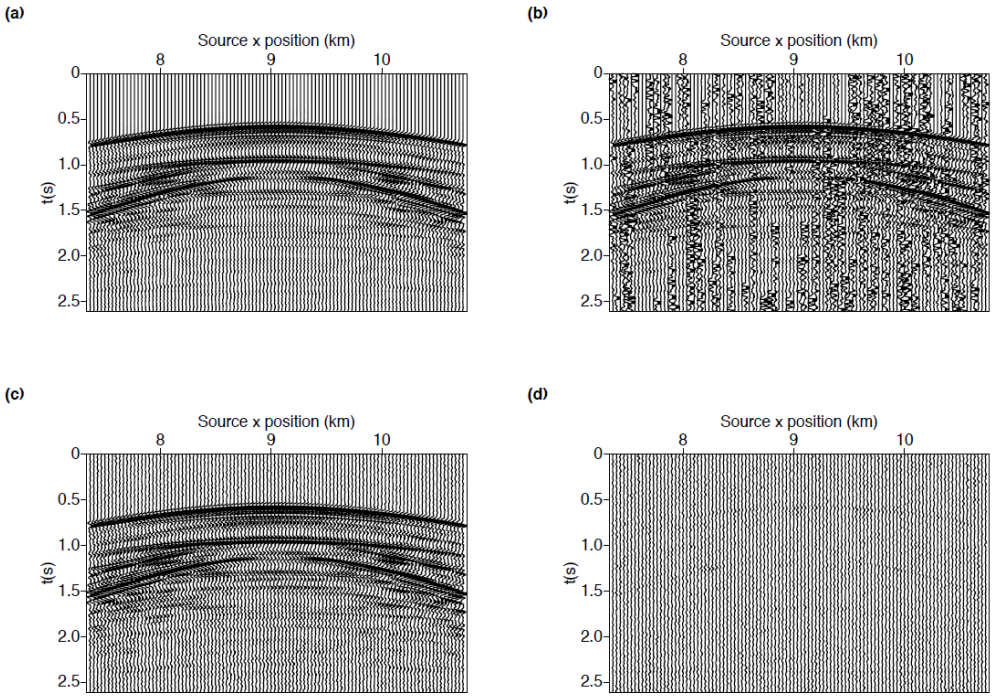


图 3：（a）理想的非混叠情况下的共接收点道集。（b）伪混合后的共接收点道集，在此例中，我们按节省 30％采集时间来设计随机延迟激发。（c）用 RPCA 去噪后的混叠共接收点道集。（d）图（a）和（c）节之间的差。

Application of Robust Principal Component Analysis (RPCA) to suppress erratic noise in seismic records

Jinkun Cheng, Ke Chen and Mauricio D. Sacchi, University of Alberta*

Downloaded 12/23/19 to 60.247.51.37. Redistribution subject to SEG license or copyright; see Terms of Use at http://library.seg.org/

SUMMARY

Seismic data are always contaminated with noise. Therefore, signal-to-noise ratio enhancement plays an important role in seismic data processing. This paper illustrates a robust principal component analysis (RPCA) method to suppress erratic noise that contaminates seismic data. The method operates in the frequency-space domain and relies on a robust low-rank approximation of the seismic data volume. We adopt a nuclear norm constraint that yields the low-rank approximation of the desired data while using an ℓ_1 norm constraint to properly estimate the erratic (sparse) noise. The problem is then tackled via the first-order gradient iteration method with two steps of soft-thresholding. We illustrate the effectiveness of this method via synthetic examples.

INTRODUCTION

Principal component analysis (PCA) is an important tool for multivariate analysis in statistics. The idea is to reduce the dimensionality of a data set while preserving as much variability of data variables as possible (Jolliffe, 2010). Let us consider to recover a low-rank matrix $\mathbf{L}$ from the observed data

$$\mathbf{D} = \mathbf{L} + \mathbf{E}, \tag{1}$$

where $\mathbf{E}$ is a matrix representing the additive error. If we assume $\mathbf{E}$ is composed by small random perturbations, an optimal estimate of $\mathbf{L}$ can be acquired via the following optimization problem

$$\begin{aligned} &\min \ \|\mathbf{E}\|_F^2 \\ &s.t. \quad \text{rank}(\mathbf{L}) = k, \quad \mathbf{D} = \mathbf{L} + \mathbf{E}. \end{aligned} \tag{2}$$

The problem can be efficiently solved via singular value decomposition (SVD) (Golub and van Loan, 1996). The observed data $\mathbf{D}$ can be decomposed into a group of eigen-images via the SVD. The low-rank component $\mathbf{L}$ can be described with a few eigen-images that are associated to the largest singular values. The error $\mathbf{E}$, however, will have energy spread over all the eigen-images (Trickett, 2003).

A variety of methods based on PCA have been developed in seismic data processing. For instance, Ulrych et al. (1999) introduced a time domain matrix rank reduction method to eliminate incoherent noise from seismic records. A related family of methods, the Karhunen-Loeve transform, has also been introduced for the enhancement of the signal-to-noise ratio of prestack gathers (Al-Yahya, 1991). Dipping events can be handled by applying eigen-image filters in the $f-x-y$ domain (Trickett, 2003). Similarly, Cadzow de-noising (Trickett and Burroughs, 2009), or singular spectrum analysis (SSA) (Sacchi, 2009; Oropeza and Sacchi, 2011) also operates in the frequency-space domain and are capable of preserving coherent dips while attenuating random noise. Cadzow and SSA de-noising, unlike traditional eignen-images methods (Ulrych et al., 1999), do not operate on the spatial data themselves but on Hankel matrices that are formed from data in the $f-x$ or $f-x-y$ domain.

Although the aforedescribed rank reduction methods are very effective techniques for attenuating random Gaussian noise, their applications to real data problems are limited due to lack of robustness to erratic noise. In seismic data processing, erratic noise includes swell noise, power line noise and artifacts caused by glitches in recording instruments. Outliers tend to manifest as high-amplitude isolated signals that do not obey the Gaussian distribution. Therefore, the conventional least-squares error criterion utilized by PCA will perform poorly (Golub and van Loan, 1996; Trickett et al., 2012; Chen and Sacchi, 2014). In this article, we replace the least-squares constraint by an ℓ_1 norm constraint where we have assumed that the erratic noise is a sparse signal. Finding a low-rank approximation matrix subject to an l_1 misfit constraint is a non-convex optimization problem (Wright et al., 2009). A practical algorithm can be developed by simply replacing the non-convex optimization problem by a convex one where a gradient based optimization method is used. The resulting algorithm is named robust principal component analysis (RPCA) (Candès et al., 2011). We will show that that RPCA is capable of suppressing erratic noise. We tested the proposed algorithm with synthetic examples to de-noise erratic noise present in seismic records.

ROBUST PRINCIPAL COMPONENT ANALYSIS

We assume that the erratic noise can be represented using a sparse matrix $\mathbf{S}$. Only a few entries of $\mathbf{S}$ are non-zero elements and can be arbitrarily large in amplitude (Zhou et al., 2010). Robust principal component analysis suggests the following optimization problem:

$$\begin{aligned} &\min \ \|\mathbf{S}\|_0 \\ &s.t. \quad \text{rank}(\mathbf{L}) = k, \quad \mathbf{D} = \mathbf{L} + \mathbf{S}, \end{aligned} \tag{3}$$

where $||\mathbf{S}||_0$ denotes the ℓ_0 norm of $\mathbf{S}$, which means the number of non-zero elements in $\mathbf{S}$. Equation (3) is a NP-hard problem. To make the problem tractable, we use the ℓ_1 norm, which is defined by the summation of absolute values of the elements of the matrix $\mathbf{S}$, to replace the ℓ_0 norm. In the meantime, we consider to replace the the low-rank constraint by the nuclear norm of $\mathbf{L}$, which is defined as the sum of all singular values of the matrix $\mathbf{L}$. One can show that the ℓ_1 norm is the tightest convex relaxation of the ℓ_0 norm (Donoho, 2006). Similarly, the nuclear norm is the tightest convex relaxation to the low-rank constraint (Fazel, 2002). We also introduce a *Frobenius* norm constraint, $||\mathbf{D}-\mathbf{L}-\mathbf{S}||_F^2$, to tolerate the inclusion of Gaussian noise. The resulting cost function can be written as follows

$$\min J = \frac{1}{2\mu}||\mathbf{D}-\mathbf{L}-\mathbf{S}||_F^2 + \lambda||\mathbf{S}||_1 + ||\mathbf{L}||_*. \tag{4}$$

© 2015 SEG
DOI http://dx.doi.org/10.1190/segam2015-5869427.1

Downloaded 12/23/19 to 60.247.51.37. Redistribution subject to SEG license or copyright; see Terms of Use at http://library.seg.org/

λ is a trade-off parameter that balances the sparsity and low rank constraints. The scalar μ is a small constant that controls the inclusion of Gaussian noise.

We consider to minimize Equation (4) via an iterative scheme to estimate the low-rank data $\mathbf{L}$ as well as the sparse erratic noise $\mathbf{S}$. We split the cost function into two sub-problems based on the sub-gradient method. The solution of Equation (4) is equivalent to the solution of the following system of equations

$$\min J_S = \lambda||\mathbf{S}||_1 + ||\mathbf{S} - \hat{\mathbf{S}}^k||_F^2 \tag{5a}$$
$$\min J_L = ||\mathbf{L}||_* + ||\mathbf{L} - \hat{\mathbf{L}}^k||_F^2 \tag{5b}$$

only if $\hat{\mathbf{L}}^k$ and $\hat{\mathbf{S}}^k$ converge to the solution of

$$\min J_0 = \frac{1}{2\mu}\|\mathbf{D} - \mathbf{L} - \mathbf{S}\|_F^2 . \tag{6}$$

Therefore, we can calculate $\hat{\mathbf{L}}^k$ and $\hat{\mathbf{S}}^k$ by updating a current estimation in the opposite direction of the gradient of J_0

$$\begin{aligned} \hat{\mathbf{S}}^k &= \mathbf{S}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D}) \\ \hat{\mathbf{L}}^k &= \mathbf{L}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D}) . \end{aligned} \tag{7}$$

Equation (5a) are commonly seen in the field of compressive sensing. It leads to a soft-thresholding step to all the entries of the updated solution $\hat{\mathbf{S}}^k$ (Beck and Teboulle, 2009). The solution to Equation (5b) can also be found in recent developments of matrix completion. In this case, instead of applying soft-thresholding directly to the entries, a soft-thresholding step are performed to the singular values of the matrix $\hat{\mathbf{L}}^k$ (Cai et al., 2010; Recht et al., 2010) (see algorithm (1)).

Algorithm 1 RPCA

Inputs:

Observed data $\mathbf{D}$, trade-off parameter λ and stopping criterion ε

Initialize:

$\mathbf{L}^0 = 0$; $\mathbf{S}^0 = 0$; $k = 1$

repeat

$\hat{\mathbf{S}}^k = \mathbf{S}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$

$\hat{\mathbf{L}}^k = \mathbf{L}^k - \frac{1}{2\mu}(\mathbf{L}^k + \mathbf{S}^k - \mathbf{D})$

$\mathbf{S}^{k+1} = \max(|\hat{S}_k(i,j)| - \frac{\lambda\mu}{2}, 0)$

$[\mathbf{U}, \Sigma, \mathbf{V}] = \text{svd}[\hat{\mathbf{L}}^k]$

$\hat{\mathbf{\Sigma}} = \max(|\Sigma(i,i)| - \frac{\lambda\mu}{2}, 0)$

$\mathbf{L}^{k+1} = \mathbf{U}\hat{\mathbf{\Sigma}}\mathbf{V}^*$

$k = k + 1$

until $\|\mathbf{D} - \mathbf{L}^k - \mathbf{S}^k\|_F^2 < \varepsilon$

Outputs:

Low-rank estimation $\mathbf{L}^{k+1}$;
Estimated erratic noise $\mathbf{S}^{k+1}$.

The RPCA method is summarized in Algorithm (1). In each iteration, we modify the current estimate of the low-rank data and erratic noise in the opposite direction to the gradient of the quadratic term. Then, we apply two steps of soft-thresholding to the modified estimators. Zhou et al. (2010) have proved that the selection of $\lambda = 1/\max(m,n)$ can guarantee high quality recovery of the matrix $\mathbf{L}$, where m and n are the size of the data matrix $\mathbf{D}$. The tuning parameter μ can be chosen according to $\mu = 0.1\sqrt{\max(m,n) + 8\sigma\sqrt{\max(m,n)}}$ (Tao and Yuan, 2011) where σ is an estimator of the standard error of the additive noise in the data.

RPCA SEISMIC DATA NOISE ATTENUATION

The Robust Principal Component Analysis can be adopted to suppress erratic noise present in the seismic data. We consider to apply the RPCA algorithm to a 3D volume $\mathcal{D}(t,x,y)$ extracted from a multi-dimensional seismic data set. We remind the reader that the Fourier transform that maps data from $t-x-y$ domain to $f-x-y$ domain can be expressed by

$$\tilde{\mathcal{D}}(\omega,x,y) = \int \mathcal{D}(t,x,y)e^{i\omega t}\, d\omega . \tag{8}$$

At a given frequency ω, the spatial data can be denoted via a spectral matrix $\mathbf{D}_\omega$. The desired signal is coherent along the two spatial directions. Therefore, $\mathbf{D}_\omega$ is a low-rank matrix (Trickett, 2003; Cheng and Sacchi, 2014). The de-noising method, which applies robust matrix rank reduction to each frequency slice of the $f-x-y$ data cube, is shown in Algorithm (2).

Algorithm 2 RPCA de-noising

Inputs:

3D seismic volume $\boldsymbol{\mathcal{D}}$
trade-off parameter λ

$\tilde{\mathcal{D}}(\omega, x, y) \leftarrow \mathcal{D}(t, x, y)$ (FFT)

for $\omega = \omega_{min} : \omega_{max}$ **do**

$\mathbf{D}_\omega \leftarrow \tilde{\mathcal{D}}(\omega, :, :)$

$[\mathbf{L}, \mathbf{S}] = \text{RPCA}[\mathbf{D}_\omega]$ (Algorithm 1)

$\hat{\tilde{\mathcal{D}}}(\omega, :, :) \leftarrow \mathbf{L}$

end for

$\hat{\mathcal{D}}(t, x, y) \leftarrow \hat{\tilde{\mathcal{D}}}(\omega, x, y)$ (IFFT)

EXAMPLES

Erratic noise elimination

A synthetic data set is utilized to test the robustness of the proposed de-noising method. Figure 1 (a) shows the 3D $t-x-y$ data set, which has 30×30 traces and a total time of 1 second. As is shown in Figure 1 (b), we added Gaussian noise with signal-to-noise ratio equals to 3. We also added isolated traces with erratic noise with an amplitude that is about 3 times of the maximum amplitude of desired signal. The processing

© 2015 SEG
DOI http://dx.doi.org/10.1190/segam2015-5869427.1

frequency band ranges from 1 to 40 Hz. The results of the $f-x-y$ eigen-image filtering and the RPCA de-noising were compared. We evaluate the performance of the algorithm via a quality factor

$$Q = \frac{\|\hat{\mathcal{D}} - \mathcal{D}\|_F^2}{\|\mathcal{D}\|_F^2},$$

where $\mathcal{D}$ is the noise-free data and $\hat{\mathcal{D}}$ denotes the de-noised data. Figure 1 (c) shows the result of $f-x-y$ eigen-image filtering. The rank was set to 3. Figure 1 (d) shows the difference between the filtered data and the true data.The erratic noise was not properly removed and the estimated data shows noticeable artifacts. Figure 1 (e) is the result of the RPCA de-noising. Both the Gaussian noise and the erratic noise are successfully suppressed. The proposed method effectively suppressed the incoherent noise. Figure 1 (f) shows the error panel corresponding to RPCA de-nosing. We improve the quality of the data from $Q = -6.7$ dB to $Q = 11.9$ dB.

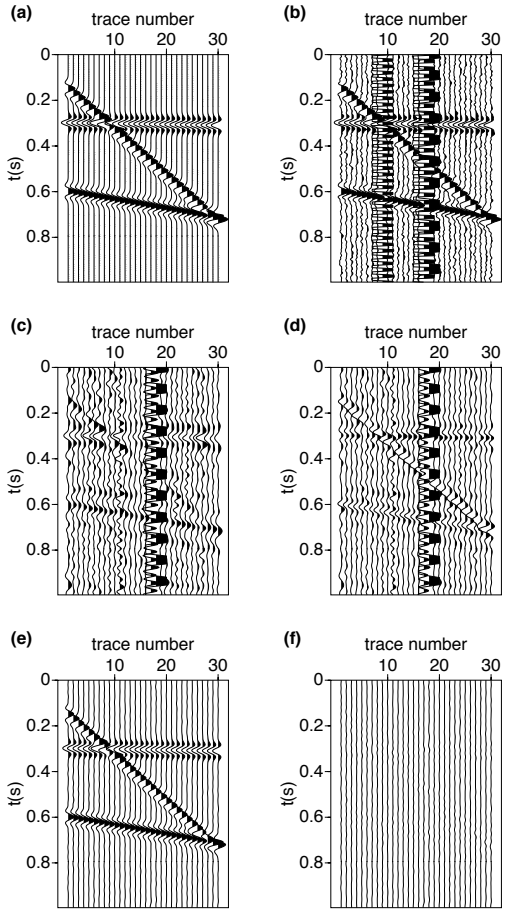


Figure 1: Results of Robust de-noising for the synthetic data set. (a) The ideal CMP gather of the 3D data cube. (b) The CMP gather contaminated with Gaussian and erratic noise. (c) De-noised gather with $f-x-y$ eigen-image filtering. (d) Differences between (a) and (c). (e) CMP gather after RPCA Denoising. (f) Difference between (a) and (e).

We tested the RPCA de-noising method with a real data set. Figure (2) shows a small patch (50×50 traces) from an offset-midpoint gather of a post-stack seismic volume. The total time length of the patch is 1 second. We added erratic noise to isolated traces with cosine signals that mimic power line noise. Figure (2) shows that the RPCA de-noising method has effectively suppressed the erratic noise while preserving the desired signal. In this example, the quality factor of data was improved from $Q - 4.7$ dB to $Q = 9$ dB.

Simultaneous source noise suppression

We also applied the proposed algorithm to solve the deblending problem in common receiver domain. We adopted a synthetic 3D vertical seismic profile to mimic a simultaneous source acquisition. The data set contains 205 source lines with 205 source positions on each line. The interval of each source position is 16.67m and the line spacing is also 16.67m (O'Brien, 2010). One common receiver gather has been extracted at depth 1600m. We assume that the data are blended with the self-simultaneous shooting technique. Only one vessel fires with small random time delays generated via a uniform distribution. The expected time delays are 70% of one conventional shot record length. Figure 3 (b) shows the center shot line of the pseudo-deblended common gather which contains the blending noise. In this example, we assume that 30 % of the acquisition time is saved via the proposed acquisition design. Figure 3 (c) shows the de-noising result with the proposed method. The RPCA algorithm is able to remove the interferences and yields a value $Q = 10.2$. This example portrays a deblending technique based on robust de-noising (Huo et al., 2009; Ibrahim and Sacchi, 2014). However, it is important to mention that deblending methods that are based on rank constrained inversion could also be adopted (Cheng and Sacchi, 2014).

CONCLUSIONS

We presented a robust principal component analysis method for suppressing erratic noise that is often present seismic data. We assume the ideal data can be represented via low-rank matrices in the frequency-space domain and that the erratic noise can be represented via a sparse matrix. A nuclear norm constraint as well as an l_1 norm constraint are used to simultaneously recover the data and the erratic noise. We tackled the problem via first order gradient method. Through tests with synthetic examples, the proposed RPCA de-noising method is shown to be able to remove both Gaussian and erratic noise. The method has the potential to be adapted for simultaneous source seismic data de-noising and reconstruction. Furthermore, higher dimensional version of the algorithm could be developed by interchanging matrices by multilinear arrays (tensors) to represent multi-dimensional spatial data at a given temporal frequency.

ACKNOWLEDGMENTS

The authors would like to thank the sponsors of Signal Analysis and Imaging Group (SAIG) at the University of Alberta.

Downloaded 12/23/19 to 60.247.51.37. Redistribution subject to SEG license or copyright; see Terms of Use at http://library.seg.org/

© 2015 SEG
DOI http://dx.doi.org/10.1190/segam2015-5869427.1

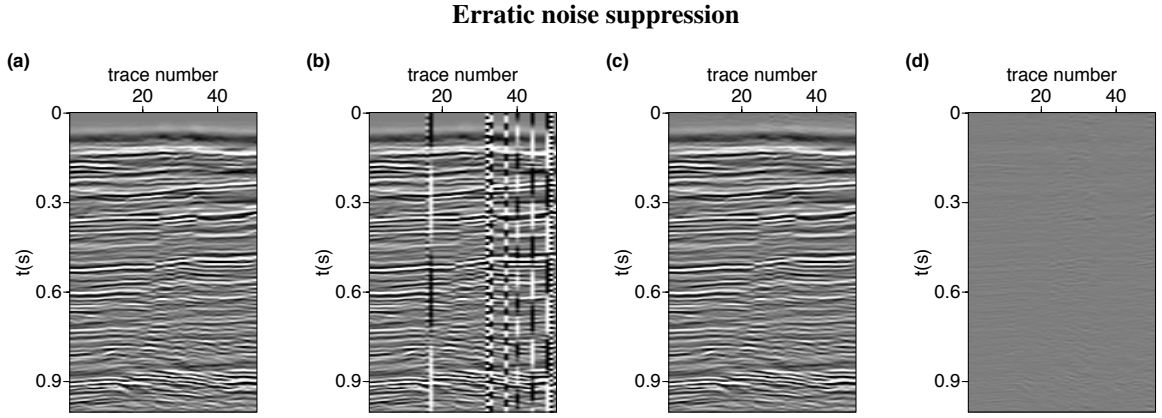


Figure 2: Results of Robust de-noising for a real 3D data set (post-stack). (a) An ideal CMP gather of the 3D data cube. (b) The CMP gather contaminated with erratic noise. (c) CMP gather after RPCA de-noising. (d) Differences between (a) and (c).

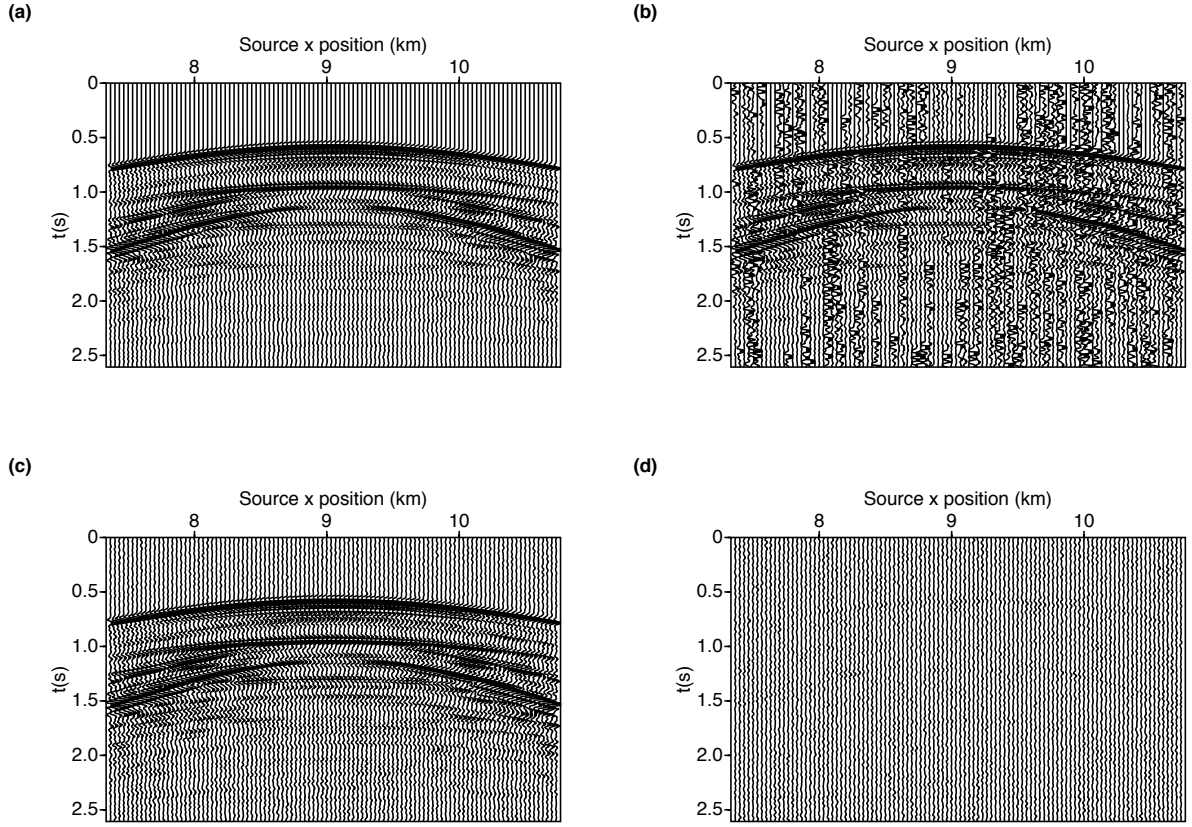


Figure 3: (a) The center shot line of the ideal unblended common receiver gather. (b) The center shot line of a pseudo-deblended common receiver gather, in this example, we save 30 % of acquisition time. (c) The center shot line of the deblended common receiver gather after RPCA de-noising. (d) The difference between section (a) and (c).

Downloaded 12/23/19 to 60.247.51.37. Redistribution subject to SEG license or copyright; see Terms of Use at http://library.seg.org/

© 2015 SEG
DOI http://dx.doi.org/10.1190/segam2015-5869427.1

Downloaded 12/23/19 to 60.247.51.37. Redistribution subject to SEG license or copyright; see Terms of Use at http://library.seg.org/

EDITED REFERENCES

Note: This reference list is a copyedited version of the reference list submitted by the author. Reference lists for the 2015 SEG Technical Program Expanded Abstracts have been copyedited so that references provided with the online metadata for each paper will achieve a high degree of linking to cited sources that appear on the Web.

REFERENCES

Al-Yahya, K., 1991, Application of the partial Karhunen-Loève transform to suppress random noise in seismic sections: Geophysical Prospecting, **39**, no. 1, 77–93, http://dx.doi.org/10.1111/j.1365-2478.1991.tb00302.x.

Beck, A., and M. Teboulle, 2009, A fast iterative shrinkage-thresholding algorithm for linear inverse problems: SIAM Journal on Imaging Sciences, **2**, no. 1, 183–202, http://dx.doi.org/10.1137/080716542.

Cai, J.-F., E. J. Candès, and Z. Shen, 2010, A singular value thresholding algorithm for matrix completion: SIAM Journal on Optimization, **20**, no. 4, 1956–1982, http://dx.doi.org/10.1137/080738970.

Candès, E. J., X. Li, Y. Ma, and J. Wright, 2011, Robust principal component analysis?: Journal of the ACM (Association for Computing Machinery), **58**, no. 3, Article 11, doi:10.1145/1970392.1970395.

Chen, K., and M. D. Sacchi, 2015, Robust reduced-rank filtering for erratic seismic noise attenuation: Geophysics, **80**, no. 1, V1–V11, http://dx.doi.org/10.1190/geo2014-0116.1.

Cheng, J., and M. D. Sacchi, 2014, A dual domain algorithm for minimum nuclear norm deblending: 84th Annual International Meeting, SEG, Expanded Abstracts, 99–104.

Donoho, D., 2006, For most large underdetermined systems of linear equations the minimum l1-norm solution is also the sparsest solution: Communications on Pure and Applied Mathematics, **59**, no. 6, 797–829, http://dx.doi.org/10.1002/cpa.20132.

Fazel, M., 2002, Matrix rank minimization with applications: Master's thesis, Stanford University.

Golub, G. H., and C. F. van Loan, 1996, Matrix computations, 3rd ed.: The Johns Hopkins University Press.

Huo, S., Y. Luo, and P. Kelamis, 2009, Simultaneous sources separation via multi-directional vector-median filter: 79th Annual International Meeting, SEG, Expanded Abstracts, 31–35.

Ibrahim, A., and M. D. Sacchi, 2014, Simultaneous source separation using a robust Radon transform: Geophysics, **79**, no. 1, V1–V11, http://dx.doi.org/10.1190/geo2013-0168.1.

Jolliffe, I. T., 2010, Principal component analysis, 2nd ed.: Springer.

O'Brien, M. J., 2010, Mounting an offense against poor-quality shear data: 80th Annual International Meeting, SEG, Expanded Abstracts, 177–181.

Oropeza, V., and M. Sacchi, 2011, Simultaneous seismic data denoising and reconstruction via multichannel singular spectrum analysis: Geophysics, **76**, no. 3, V25–V32, http://dx.doi.org/10.1190/1.3552706.

Recht, B., M. Fazel, and P. Parrilo, 2010, Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization: SIAM Review, **52**, no. 3, 471–501, http://dx.doi.org/10.1137/070697835.

Sacchi, M. D., 2009, FX singular spectrum analysis: Presented at the CSPG/CSEG/CWLS Convention, 392–395.

Tao, M., and X. Yuan, 2011, Recovering low-rank and sparse components of matrices from incomplete and noisy observations: SIAM Journal on Optimization, **21**, no. 1, 57–81, http://dx.doi.org/10.1137/100781894.

Trickett, S. R., 2003, *F-xy* eigenimage noise suppression: Geophysics, **68**, 751–759, http://dx.doi.org/10.1190/1.1567245.

Trickett, S. R., and L. Burroughs, 2009, Prestack rank-reducing noise suppression: 79th Annual International Meeting, SEG, Expanded Abstracts, 3332–3336.

Trickett, S., L. Burroughs, and A. Milton, 2012, Robust rank-reduction filtering for erratic noise: 82nd Annual International Meeting, SEG, Expanded Abstracts, doi:10.1190/segam2012-0129.1.

Ulrych, T. J., M. D. Sacchi, and S. L. M. Freire, 1999, Eigenimage processing of seismic sections, *in* R. L. Kirlin and W. J. Done, eds., Covariance analysis for seismic signal processing: SEG, 241–274.

Wright, J., A. Ganesh, S. Rao, Y. Peng, and Y. Ma, 2009, Robust principal component analysis: Exact recovery of corrupted low-rank matrices via convex optimization: Proceedings of the 23rd Annual Conference on Advances in Neural Information Processing Systems (NIPS), **22**, 2080–2088, http://papers.nips.cc/paper/3704-robust-principal-component-analysis-exact-recovery-of-corrupted-low-rank-matrices-via-convex-optimization.

Zhou, Z., X. Li, J. Wright, E. Candès, and Y. Ma, 2010, Stable principal component pursuit: Proceedings of the International Symposium on Information Theory (ISIT), IEEE, 1518–1522.

Downloaded 12/23/19 to 60.247.51.37. Redistribution subject to SEG license or copyright; see Terms of Use at http://library.seg.org/